

中图分类号: V328.1
学科分类号: 083700

论文编号: 1028707 20-S091

硕士学位论文

基于飞行数据的 颠簸飞行状态估计初步研究

研究生姓名	王 冉
学科、专业	安全科学与工程
研 究 方 向	航空器安全
指 导 教 师	高振兴 副教授

南京航空航天大学

研究生院 民航学院

二〇二〇年三月

Nanjing University of Aeronautics and Astronautics

The Graduate School

College of Civil Aviation

Preliminary Research on Turbulent Flight State Estimation Based on Flight Data

A Thesis in

Safety Science and Engineering

by

Wang Ran

Advised by

Associate Prof. Gao Zhenxing

Submitted in Partial Fulfillment

of the Requirements

for the Degree of

Master of Engineering

March, 2020

承诺书

本人声明所呈交的硕士学位论文是本人在导师指导下进行的研究工作及取得的研究成果。除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得南京航空航天大学或其他教育机构的学位或证书而使用过的材料。

本人授权南京航空航天大学可以将学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

(保密的学位论文在解密后适用本承诺书)

作者签名: 王冉
日 期: 2020.04.03

高 振 兴

摘 要

湍流等大气扰动现象严重影响民航飞机的飞行安全、乘坐感受和飞行品质。考虑到飞行数据记录器记录的飞行参数中有状态冗余，基于飞行数据准确估计飞行状态和湍流扰动风成为一种理论上可行的技术途径。本文在研究多种状态估计算法之上，充分利用了飞行数据的记录特点，选取了一种基于极大似然准则的自适应扩展卡尔曼滤波算法，对飞机状态进行估计。在此基础上，采用扩展卡尔曼滤波器对三维空间扰动风进行估计。本文研究内容概括如下：

(1) 飞行数据的记录、特点及其着陆安全影响因素分析。研究了飞行数据的记录系统、记录格式、记录特点及其状态冗余，采用基于时间序列的灰色接近关联分析和灰典型相关分析方法，寻找关键飞行阶段的飞行状态参数与重着陆和长着陆事件之间的定量关联性。

(2) 对飞机状态估计算法进行研究，并以飞行器运动状态估计为例进行效果对比。基于扩展卡尔曼滤波、无迹卡尔曼滤波两种算法的分析，考虑到系统动态变化以及飞行数据的噪声统计特性未知，研究了一种基于极大似然准则的自适应扩展卡尔曼滤波算法，以对飞行器运动状态估计为例，对该算法进行性能分析，并对比三种算法的估计效果。

(3) 飞机气流角估计。考虑到各飞行参数采样频率不同，基于飞行动力学模型，将非等间隔理论和基于极大似然准则的自适应卡尔曼滤波算法进行融合，对飞机迎角、侧滑角进行估计，同时与扩展卡尔曼滤波、无迹卡尔曼滤波算法估计结果进行对比。

(4) 建立颠簸飞行中扰动风三维空间估计模型。根据 von Karman 大气湍流模型和真空速、地速与风速之间的矢量三角形关系建立估计方程，通过扩展卡尔曼滤波器，分别对轻度、中度和重度三种不同程度颠簸下的扰动风进行三维空间估计。

结果表明，针对飞行器的运动状态和气流角估计，基于极大似然准则的自适应扩展卡尔曼滤波算法的估计效果均优于另外两种算法；扰动风三维空间估计模型在轻度和中度颠簸飞行情况下能够实现对扰动风的初步估计。

关键词：飞行数据，飞行动力学，自适应卡尔曼滤波，飞行状态估计，扰动风估计

Abstract

Atmospheric disturbances such as turbulence seriously affect the flight safety, ride experience and flight quality of civil aviation aircraft. Considering the state redundancy in flight parameters recorded by the flight data recorder, it is a theoretically feasible technical approach to estimate aircraft state and turbulence accurately based on flight data. After researching several state estimation algorithms, this paper made full use of the recorded characteristics of flight data, and selected an adaptive extended Kalman filtering algorithm based on the maximum likelihood criterion to estimate the aircraft state. Furthermore, the extended Kalman filter was used to estimate the three dimensional spatial turbulent wind. The research contents are summarized as follows:

(1) The recording and characteristics of flight data, and the factors affecting landing safety were analyzed. The flight data recording system, format, characteristics and its status redundancy were studied. After that, the grey close correlation analysis based on time series and the gray canonical correlation analysis were used to find the quantitative relationship between flight parameters and unsafe events including long landing and hard landing in approach and landing procedure.

(2) The aircraft state estimation algorithms were studied. Based on the analysis of extended Kalman filter and unscented Kalman filter, considering the changes of system model and the unknown statistical characteristics of flight data, an adaptive extended Kalman filtering algorithm based on maximum likelihood criterion was studied. The aircraft motion state estimation was taken as an example to analysis algorithm performance and compare the results of three algorithms mentioned.

(3) The airflow angle of aircraft was estimated. Taking the different sampling frequency of each flight parameter into account, the non-equal interval theory and the adaptive Kalman filtering algorithm based on the maximum likelihood criterion were used to estimate the attack angle and sideslip angle of aircraft based on the flight dynamics model. What's more, the estimated results were compared with the results of extended Kalman filter and unscented Kalman filter.

(4) A three-dimensional spatial estimation model of turbulence was established based on the von Karman atmospheric turbulence model and the vector triangle relationship between the airspeed, ground speed and wind speed. Three-dimensional turbulent wind with different degrees of light, moderate and severe were estimated by extended Kalman filter.

The results show that the effect of adaptive extended Kalman filter algorithm based on the maximum likelihood criterion is better than the other two algorithms for the estimation of aircraft's

motion state and airflow angle. Furthermore, the three-dimensional spatial estimation model of turbulence can achieve preliminary estimation of turbulent wind with the degrees of light and moderate.

Keywords: Flight Data, Flight Dynamics, Adaptive Kalman Filtering, Flight State Estimation, Turbulent Wind Estimation

目 录

第一章 绪论	1
1.1 研究背景和意义	1
1.2 国内外研究现状	2
1.2.1 飞行数据应用	2
1.2.2 飞机状态估计	4
1.2.3 大气扰动研究	6
1.2.4 颠簸研究现状	8
1.3 本文研究内容及章节安排	9
第二章 飞行数据及其在飞机着陆安全中的应用	11
2.1 飞行数据的记录	11
2.1.1 飞行数据记录系统	11
2.1.2 飞行数据的记录格式	12
2.2 飞行数据的特点及其状态冗余	14
2.2.1 飞行数据的特点	14
2.2.2 飞行数据的状态冗余	16
2.3 基于飞行数据的着陆安全影响因素分析	17
2.3.1 着陆模型与参数选取	17
2.3.2 灰色接近关联分析及其试验	19
2.3.3 灰典型相关分析及其试验	22
2.4 本章小结	24
第三章 飞行状态估计算法研究	25
3.1 状态估计概述	25
3.1.1 估计理论基础	25
3.1.2 最小二乘估计	25
3.2 扩展卡尔曼滤波算法	27
3.2.1 标准卡尔曼滤波	27
3.2.2 扩展卡尔曼滤波	29
3.3 无迹卡尔曼滤波算法	30
3.3.1 无迹变换	31

3.3.2 无迹卡尔曼滤波	32
3.4 自适应扩展卡尔曼滤波算法	34
3.4.1 自适应扩展卡尔曼滤波算法的极大似然估计准则	34
3.4.2 基于极大似然准则的自适应扩展卡尔曼滤波算法	35
3.5 飞行器运动状态跟踪	36
3.5.1 建立运动状态方程和量测方程	37
3.5.2 滑动窗口长度的选取	38
3.5.3 衰减因子的选取	39
3.5.4 MLC-AEKF 算法品质分析	40
3.5.5 状态跟踪结果分析	42
3.6 本章小结	43
第四章 基于 MLC-AEKF 算法的飞机气流角估计	44
4.1 非线性飞行动力学模型	44
4.1.1 飞行动力学方程	44
4.1.2 飞行动力学模型参数值	45
4.2 气流角估计模型	46
4.2.1 建立系统状态方程	47
4.2.2 建立系统量测方程	48
4.3 融合非等间隔理论的 MLC-AEKF 算法	48
4.4 估计结果分析	49
4.5 本章小结	51
第五章 颠簸飞行中扰动风估计初步研究	52
5.1 扰动风估计概述	52
5.2 von Karman 湍流估计模型	52
5.3 矢量三角形建立估计量测方程	54
5.3.1 计算真空速和地速的三轴分量	54
5.3.2 建立量测方程	55
5.4 扰动风估计结果分析	57
5.5 本章小结	59
第六章 总结与展望	60
6.1 本文研究内容总结	60
6.2 未来研究工作展望	61

参考文献	62
致 谢	68
在学期间的研究成果及发表的学术论文.....	69

图表清单

图 1.1 2018 年 1-6 月事故征候原因分布	1
图 1.2 各阶段飞行事故率.....	3
图 1.3 状态估计的一般架构.....	4
图 1.4 航空公司颠簸预报一般流程.....	8
图 1.5 论文结构安排.....	10
图 2.1 飞行数据记录器.....	12
图 2.2 ARINC 542 格式一帧结构	13
图 2.3 ARINC 573 格式一帧结构	13
图 2.4 filloutliers 函数异常值处理效果图	16
图 2.5 两种方法计算空速结果对比图.....	17
图 2.6 进场着陆航迹简化模型.....	18
图 2.7 标准着陆模型.....	19
图 2.8 典型着陆航段与标准着陆航段模型对比.....	20
图 2.9 部分阶段因参数关联度分析结果.....	21
图 2.10 平飘距离和接地载荷的各阶段因参数关联度条形图.....	22
图 3.1 卡尔曼滤波算法原理图.....	27
图 3.2 UKF 算法原理图.....	31
图 3.3 MLC-AEKF 算法流程图	36
图 3.4 稳态下不同滑动窗口的位置误差对比图.....	38
图 3.5 数据突变下不同滑动窗口的位置误差对比图.....	39
图 3.6 稳态和数据突变下位置估计性能随滑动窗口长度的变化曲线.....	39
图 3.7 滑动窗口内衰减权重的变化曲线.....	40
图 3.8 位置误差性能随衰减因子的变化曲线.....	40
图 3.9 EKF 和 MLC-AEKF 算法的 C_{rk} 、 K_k 、 Q 、 R 、 P_k 对比图.....	41
图 3.10 EKF/UKF/MLC-AEKF 三种算法目标轨迹跟踪图.....	42
图 3.11 位置、速度、加速度估计误差图.....	43
图 4.1 协调转弯状态仿真图.....	46
图 4.2 迎角/侧滑角 MLC-AEKF 结果与真实轨迹、EKF、UKF 结果对比图.....	50
图 4.3 迎角/侧滑角估计误差	51

图 4.4 迎角/侧滑角 EKF 和 MLC-AEKF 的 C_{rk} 、 P_k 对比图.....	51
图 5.1 扰动风估计原理框架图.....	52
图 5.2 真空速与地速三维量测及其差值.....	56
图 5.3 平稳飞行下速度三角形计算的水平风与 QAR 记录的水平风对比图.....	56
图 5.4 颠簸飞行下速度三角形计算的水平风与 QAR 记录的水平风对比图.....	56
图 5.5 轻度颠簸下扰动风三维估计结果图.....	57
图 5.6 中度颠簸下扰动风三维估计结果图.....	58
图 5.7 重度颠簸下扰动风三维估计结果图.....	58
图 5.8 轻度、中度、重度颠簸下扰动风三维估计误差对比图.....	58
表 2.1 本文主要飞行参数及其记录特点.....	15
表 2.2 50ft-0ft 阶段因参数与果参数灰典型载荷量统计结果.....	24
表 2.3 灰典型相关系数的显著性检验.....	24
表 3.1 标准卡尔曼滤波与扩展卡尔曼滤波算法过程对比.....	30
表 4.1 某型飞机结构参数.....	45
表 4.2 各状态量配平初始值.....	46

注释表

符号	含义	符号	含义
x	平飘距离	P_k	估计误差协方差矩阵
n_z	接地载荷	A_k	状态矩阵
m	飞机重量	H_k	量测矩阵
$C_{L,Ap}$	飞机进场阶段升力系数	w_k	状态噪声
V_{REF}	飞机进近基准速度	v_k	量测噪声
V_{Gp}	飞机进场地速	Q_k	状态噪声方差
d_{Rp}	飞机进场下降率	R_k	量测噪声方差
θ	俯仰角	\hat{x}	状态估计值
ϕ	滚转角	L_k	系统噪声驱动阵
δ_c	驾驶杆位移	M_k	量测噪声驱动阵
δ_t	油门杆角位移	$W_m^{(i)}$	Sigma 点权值
ε	灰色接近关联度	G_k	控制输入矩阵
GS	灰序列	Φ_k	离散状态转移矩阵
WS	白序列	r_k	新息
$GCov(S_i, S_j)$	灰协方差	C_{rk}	新息协方差
$\rho_g(S_i, S_j)$	灰相关系数	N	滑动窗口长度
GM	灰协方差矩阵	\mathcal{G}	指数衰减权重
$x(k)$	状态向量	Υ	衰减因子
$z(k) \ y(k)$	观测向量	xkf	滤波器状态向量
K_k	卡尔曼滤波增益	p	滚转角速率
J_k	代价函数	q	俯仰角速率
$\varepsilon_{x,k}$	真实值与估计值之间的误差	r	偏航角速率
Y	侧力	α	迎角

V	空速	β	侧滑角
δ_a	副翼偏转量	\bar{c}	平均弦长
δ_e	升降舵偏转量	g	重力加速度
δ_r	方向舵偏转量	S	机翼总面积
$T_x \ T_y \ T_z$	发动机推力三轴分量	$a_x \ a_y \ a_z$	三轴加速度分量
\bar{L}	滚转力矩	L_f	升力
\bar{M}	俯仰力矩	D	阻力
\bar{N}	偏航力矩	Y	侧力
\bar{q}	动压	$V_{Tx} \ V_{Ty} \ V_{Tz}$	真空速在机体系上的分量
b	翼展	$V_{Gx} \ V_{Gy} \ V_{Gz}$	真空速在机体系上的分量
σ	湍流强度	W	风速
L	湍流尺度	$G(s)$	传递函数

缩略词

缩略词	英文全称	中文名称
FAA	Federal Aviation Administration	美国联邦航空局
NTSB	National Transportation Safety Board	美国国家运输安全委员会
FDR	Flight Data Recorder	飞行数据记录器
QAR	Quick Access Recorder	快速存取记录器
FOQA	Flight Operations Quality Assurance	飞行品质监控
EKF	Extended Kalman Filter	扩展卡尔曼滤波
UKF	Unscented Kalman Filter	无迹卡尔曼滤波
IRS	Inertial Reference System	惯性基准系统
NASA	National Aeronautics and Space Administration	美国国家航空航天局
INS	Inertial Navigation System	惯性导航系统
GPS	Global Positioning System	全球定位系统
LPV	Linear Parameter Varying	线性变参数
FDM	Flight Dynamics Model	飞行动力学模型
PIREPs	Pilot Reports	飞行员报告
WAFS	World Area Forecast System	世界区域预报系统
MXSH	Maximum Wind Shear	最大风切变指数
EDR	Eddy Dissipation Rate	湍流耗散率
NACA	National Advisory Committee for Aeronautics	美国国家航空咨询委员会
FDAU	Flight Data Acquisition Unit	飞行数据采集单元
WQAR	Wireless Quick Access Recorder	无线快速存取记录器
ARINC	Aeronautical Radio Inc.	美国航空无线电通信公司
ICAO	International Civil Aviation Organization	国际民用航空组织
LS	Least Squares	最小二乘
UT	Unscented Transform	无迹变换
MLC-AEKF	Maximum Likelihood Criterion -Adaptive Extended Kalman Filter	基于极大似然准则的自适应 扩展卡尔曼滤波

第一章 绪论

1.1 研究背景和意义

风切变、大气湍流等大气扰动现象对民航飞机的飞行安全和飞行品质有着重大影响。在中国民用航空局发布的《2018 年民航行业发展统计公报》中，2018 年全年共发生运输航空事故 568 起，其中运输航空严重事故征候 16 起，1-6 月导致事故征候的原因分布如图 1.1 所示，其中包括大气扰动在内的恶劣天气导致的不安全事件约占总数的 76%^[1]。根据美国联邦航空局 (Federal Aviation Administration, FAA) 和美国国家运输安全委员会 (National Transportation Safety Board, NTSB) 数据库统计，在 1960 年到 2000 年的 40 年间，41% 的民航飞行事故由大气扰动造成^[2]。据中国民用航空局统计，由大气扰动及伴随的恶劣天气造成的灾难性事故和一般事故至少占事故总量的 30%；2000-2016 年，中国民航共发生颠簸导致的不安全事件 580 起，其中 43 起运输航空事故征候^[3]。由此可见，大气扰动的观测、飞行颠簸的预防在避免飞行颠簸对机组和乘客造成伤害、预防飞行事故和提高民航飞行乘坐舒适性等方面起着极为重要的作用。




图 1.1 2018 年 1-6 月事故征候原因分布

大气湍流是一种飞机在飞行过程中会遇到的 10 米至 1 公里范围内的四维大气乱流现象^[4]。飞行颠簸直接由大气湍流诱发，尽管其危害性可能没有发生在机场终端区的低空风切变造成的危害高，但在航路飞行过程中发生飞机颠簸仍然会严重影响民航飞机的乘坐舒适性，重度颠簸可能对机组和乘客身体造成伤害，还可能导致飞机机体结构疲劳损伤。据统计，湍流伤害每年给航空公司带来了巨额的经济损失：超过 1000 万美元的乘客赔偿、超过 7000 天的受伤机组人员工作时长损失以及飞机的巨额维护费用等^[4]。大气湍流还会影响空中交通管制员的工作量，

因为在已知的湍流区域，飞行员可能会为避开该区域，而改变原来的飞机计划，从而对空域的容量和效率产生负面作用。由于湍流的影响，每年预计有 5% 的航班无法使用最佳航线，造成了高达 1600 万美元以上的额外成本^[5]。颠簸也会一定程度上扰乱机组人员和乘客的行程，并消耗额外的燃料；同时，颠簸可能会给旅客留下航空旅行不安全的印象。

飞行数据记录了飞机从点火起飞到降落熄火整个阶段的 1000 多个参数，包括飞机飞行状态、发动机状态、飞行操作、飞行管理等参数，反映了飞机的时间属性、空间属性、发动机属性、飞行员操作属性等多个维度的序列信息，飞机设备的工作状态以及相关性能的变化情况均蕴含在其中^[6]。飞行数据在飞机飞行状态监控、品质分析、事故调查、维修诊断等方面都发挥着极其重要的作用。

考虑到飞行数据记录的飞行参数中有状态冗余，基于飞行数据准确估计气流角和湍流扰动风成为一种理论上可行的技术途径。鉴于大气扰动对飞行安全的严重危害，本课题在国家自然科学基金“风切变诱发飞行失控的包线估计及保护控制研究”(U1533120)和“基于飞行数据的民机飞行颠簸机理及短时预测研究”(U1733122)的资助下，研究飞机飞行状态和湍流估计问题。课题主要研究思路是基于飞行数据建立飞行状态系统方程和飞行数据观测方程，对飞机飞行状态进行估计，并在此基础上估计三维空间扰动风。

1.2 国内外研究现状

1.2.1 飞行数据应用

飞机的飞行数据最初存储在所谓的“黑匣子”里面，这个黑匣子就是飞行数据记录器(Flight Data Recorder, FDR)。而 FDR 数据提取较为复杂耗时，且易发生传输错误和数据缺失，只有在飞机发生重大事故，才会去读取相关数据。后来，出现了快速存取记录器(Quick Access Recorder, QAR)，该记录装置可以更加方便高效地记录飞行参数。与 FDR 相比，QAR 记录参数包括飞机状态、发动机状态、自动飞行系统状态、驾驶舱操纵和系统交互记录等多个方面，且记录格式也更加灵活自主^[7]。

中国民航基于 QAR 数据开展飞行品质监控(Flight Operations Quality Assurance, FOQA)工作始于 1997 年^[8]。2013 年，中国民用航空局正式批复中国民航飞行品质监控基站建设项目，指定由中国民航科学技术研究院(航科院)负责收集、处理和分析中国民航系统的全部 QAR 飞行数据。全行业每天 1 万多个航段数据。国内飞行品质监控基站的建立，首次实现了全行业数据的汇集，累积了海量的飞行数据，为研究飞行风险和提升飞行安全提供了大数据基石。

目前，飞行数据被广泛应用于飞行超限事件分析、飞机性能监控和飞行品质评估等多个方面，尤其在飞行安全性能和超限事件的监控与分析方面应用最为广泛，对飞行过程中的空中颠簸事件、飞机过载着陆事件、飞机故障维修诊断及排除、飞机性能监控以及飞行安全风险

等发挥着重要作用。关于飞行数据的应用可总结为以下四个方面。

(1) 利用飞行数据对超限事件进行分析。由图 1.2 可知, 起飞爬升和进近着陆阶段虽然只占总飞行时间的 6%, 但 61% 的事故包括很多超限事件均发生在这两个阶段。QAR 超限事件的探测主要是分析航班飞行过程中产生的相关参数是否符合某一个或某几个参数的正常范围, 如着陆垂直载荷过大、平飘距离过长等均是经常发生的超限事件。文献[9,10,11,12]基于飞行数据, 对长着陆和重着陆时飞行员的操作特征进行研究, 通过方差分析、回归建模等数理统计方法得到了长着陆和重着陆的关键影响因素。随着大数据时代的发展, 飞行数据的分析也开始使用一些数据挖掘算法。在传统的飞行数据分析中加入了机器学习和智能算法的相关理论和方法, 可以更好地对飞行数据进行分析, 得到更多和更有用的知识发现。文献[13]利用 3 种机器学习模型来检测着陆阶段发生的超限事件与飞行参数之间的联系, 结果表明在着陆阶段发生超限事故的主要危险因素是着陆距离过长和减速阶段过早松开刹车。国内在飞行数据挖掘应用方面也取得一些新的进展, 有学者基于飞行数据采用人工神经网络^[14]、K-means 聚类^[15]、多核支持向量机^[16]等方法建立重着陆事件的诊断与预测模型, 提高重着陆的预测成功率等。

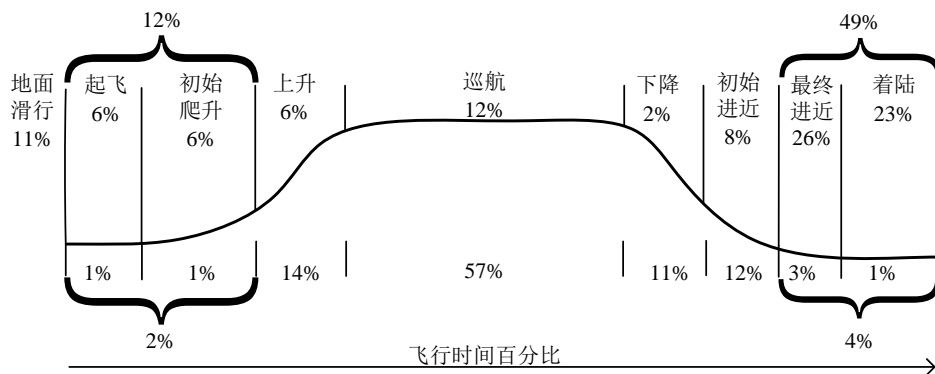


图 1.2 各阶段飞行事故率

(2) 通过飞行数据检测飞机性能。根据 QAR 记录的数据, 建立飞行参数数据库, 用于分析飞机性能, 对飞机状态进行监控; 建立性能监控数据库, 可辅助地面人员诊断飞机故障, 提高维修效率, 保障飞行安全。发动机是飞机的“心脏”, 从 20 世纪 50 年代开始, 围绕发动机开展的状态监控和智能诊断技术不断发展, 基于飞行数据建立的故障预测与健康管理系统逐渐成熟。文献[17]基于该系统, 研究航空发动机防喘控制设计, 运用基于威布尔分布、支持向量回归机、人工蜂群、隐马尔可夫和粒子群优化等多种算法, 在设备可靠性分析、状态预测和剩余寿命预测等方面取得了较为可人的研究成果, 提高了系统安全性和维修保障效率。文献[18]提出了一种基于飞行数据, 运用自组织映射和主成分分析相结合的机器学习方法, 对飞机结构健康监测环境下的损伤进行检测。文献[19]基于飞行过程中的发动机数据, 建立并分析了基于信标异常分析的飞机健康监测与故障诊断模型, 该模型最大程度上提高了故障诊断的效率, 同时也最大

程度地降低了误报率，并简化了系统范围内故障的诊断。

(3) 飞行数据与飞行操作密切相关，通过飞行数据可以对飞行员的飞行操作进行风险建模和风险管理。影响飞行员操作行为的因素是多样的，包括年龄、工龄、性别、性格以及技术级别等自然属性和社会属性，同时与飞机机型、飞行性能以及外部环境等也密切相关，这些因素相互之间也存在着关联性。通过分析每个飞行员的航班飞行数据，并结合各自相应的特征，从众多因素中寻找出造成风险的主要因素，并确定其影响程度，从而对飞行员进行品质分析和风险管理。很多航空公司基于飞行数据，通过模拟软件实现对飞行过程的复现。QAR 为航空公司内部对飞行机组的状态监控提供了相应的数据基础，同样也可以提供相应的飞行辅助训练，这对航空公司机队的建设与管理是非常有意义的。国内也有学者，从 QAR 数据出发，分析飞行员操作对飞行安全的影响。文献[9,10]基于 QAR 数据，分析了着陆过程中飞行员的拉平操作对着陆安全的影响。文献[12]在给出影响重着陆和长着陆因素的基础上，结合分析结果给出了飞行员在操作飞机着陆的过程中要防止下降率和地速过大，必须柔和地操作驾驶杆和油门，防止长着陆和重着陆事故的发生等操作建议。

(4) 飞行数据为飞行事故调查提供相关数据参考。飞行数据系统最初始就是为飞行事故调查而设计的。当发生不安全事件或严重事故后，事故发生时间段内的飞机相关的飞行参数以及飞行员的操纵与语音数据，均记录在飞行数据之中，相关专家通过分析这些数据可以调查事故背后的真正原因^[20]。特别是当飞机发生严重事故导致飞机坠毁时，由于飞机损坏，QAR 数据已无法传至陆地，此时 FDR 记录的当时的飞行数据与语音就会显得尤为重要。专家将 FDR 中记录的数据通过转录译码后，通过飞行模拟器可以重现事故的发生。因此，FDR 记录的数据是分析飞行事故原因最可靠、最有效的手段。

1.2.2 飞机状态估计

飞机的飞行状态估计问题历来是飞控系统设计与仿真、机动目标跟踪以及飞行器系统辨识等领域关心的重大问题。飞机状态估计是气动参数估计的前提，最常用的算法基本上都是卡尔曼滤波及其相应的改进、推广与发展^[21]。状态估计的一般架构流程如图 1.3 所示。




图 1.3 状态估计的一般架构

六十年代初，卡尔曼滤波算法的概念由美国学者 R.E.Kalman 提出，该算法是一种高效率的自回归滤波器。由于量测仪器或量测方式导致的误差，量测值一般是不准确的，含有或大或小的测量噪声，卡尔曼滤波算法可以通过该时刻的量测值，和上一时刻的状态估计值，衡量两者

之间的信任度大小,来获得当前时刻更为准确的估计值。标准卡尔曼滤波器是在线性系统的情况之下推导出的,不适用于非线性的状态系统,因此后来又有学者提出了扩展卡尔曼滤波(Extended Kalman Filter, EKF)以及更高精度的无迹卡尔曼滤波(Unscented Kalman Filter, UKF)、自适应滤波(Adaptive Filter, AF)、粒子滤波(Particle Filter, PF)等相关算法。

飞行状态一般是指飞机在某一瞬间的运动情况,可用飞机速度、飞行高度、迎角、侧滑角、俯仰角、滚转角、偏航角等状态来表示。飞行记录器本身只是收集了来自飞机不同传感器系统的数据,而传感器实质上是各类飞行状态的观测器。从现有 QAR 记录器规范来看,来自飞机惯性基准系统(Inertial Reference System, IRS)的地速、姿态、载荷类数据最准确,且不受环境影响;而在大气扰动情况下,迎角传感器等大气数据系统是难以准确测量出迎角、侧滑角等气流角的值^[6]。

美国国家航空航天局(National Aeronautics and Space Administration, NASA)最早提出基于飞行记录数据的飞行状态估计问题,该文章中提到了一种由艾姆斯研究中心开发的进行飞机状态估计的 SMACK(Smoothing for Aircraft Kinematics)程序,该程序具有收敛性容易监控、计算过程简单、建立完整的先验估计时可以避免设置偏置参数等优点。文章通过建立飞行状态系统方程和飞行数据观测方程,以加速度、角速度、空速和气流角为观测量,利用 SMACK 程序进行扰动风矢量、姿态角的估计。结果表明,估计状态与飞机实际飞行时间序列有较好的一致性^[22]。该算法实际上是卡尔曼滤波算法的雏形,适用于早期飞行参数记录不全的情况,且不能进行实时递推计算。此后,麻省理工提出了基于多传感器的微下击暴流风场危险性估计的数据融合模型^[23],结合飞行数据,并采用统计获得的微下击暴流风场参数,建立了扩展卡尔曼滤波数据融合模型,对微下击暴流风场下的状态进行估计。

国内关于飞机状态估计特别是姿态估计和气流角估计的研究也较多。早期有文献提出鲁棒自适应推广卡尔曼滤波^[24]应用于飞行器状态估计问题。随着卡尔曼滤波的发展,具有更高估计精度和鲁棒性的无迹卡尔曼滤波^[25]被应用于飞机的飞行状态估计问题。也有文献应用惯性导航系统(Inertial Navigation System, INS)和全球定位系统(Global Positioning System, GPS)记录的数据辅助其他数学模型进行气流角估计^[26]或者将两个系统输出的参数信息与飞行控制系统的输出量进行融合,通过扩展卡尔曼滤波器来估计迎角、侧滑角^[27]。这些文献中的方法都需要建立飞机的动力学模型。实际上,对于大多数飞机的准确建模,特别是国外生产的大型客机,还有诸多问题需要解决。

近年来,有关无人机的研究越来越受到人们的关注,其应用也越来越广泛。除了军事领域,无人机在地质勘探、环境监测、电力巡检、农业种植等民用领域中也迅速拓展。因此,关于无人机状态估计的研究也日益丰富和深入。文献[28]利用惯性测量单元、全球导航卫星系统接收机和全静压系统的数据,结合运动学、气动和随机风模型,对固定翼无人机的局部风速、迎角

和升力系数进行了估计。结果表明,该算法在风速和迎角估计方面都有很好的效果。随着卡尔曼滤波算法的发展与改进,更多的研究还是采用卡尔曼滤波算法及其推广来实现无人机的状态估计。文献[29]通过四元数的 EKF 算法对无人飞行器的三个姿态角进行估计,也有学者采用欧拉角建立估计模型,通过 UKF 算法获得飞行器姿态估计^[30]。

卡尔曼滤波及其推广是解决状态估计问题比较通用的算法,随着研究的发展,针对不同的系统与模型,也有一些其他的算法应用于飞行状态估计问题。文献[31]采用模糊逻辑建模方法,对某喷气运输机坠毁飞行记录的最后 59 秒数据进行了分析,从飞行数据中可以得到三个加速度、欧拉角、飞行速度、迎角和高度的值,利用生成的气动系数模糊逻辑模型,预测飞行轨迹的稳定性和控制导数,结果表明在飞行事故初始阶段存在较大的襟翼角和中等迎角的不稳定俯仰阻尼。在最新的一篇研究中,作者提出了一种最大后验状态估计方法,该方法同时考虑过程和测量噪声,利用多架飞机的飞行数据来估计飞机的飞行轨迹和迎角变化的模型参数。在估计过程中,采用迎角变化的气动导数模型来逼近非线性仿真模型。结果表明,在动态模型不确定性存在的情况下,当指定适当的模型置信度时,最大后验法可以获得准确的参数估计^[32]。

另外,有学者通过几何方法对飞机状态进行估计。文献[33]提出通过地速、空速和风速之间的速度矢量三角形关系以及坐标系之间的相互转换关系对飞机的侧滑角状态进行估计,文章将迎角值认为是精确测量的,该方法不需要建立动力学模型。中国空气动力学研究开发中心基于 QAR 数据,对高原机场的着陆飞机进行空气动力学建模和参数估计,通过速度投影、坐标转换等几何方法估计出气流角;然后利用 EKF 算法与改进的 Bryson-Frazier 平滑器方法进行民航飞机接近高原机场时的气动力参数辨识,采用径向基函数神经网络方法建立气动力模型;最后使用增量法对气动力控制导数进行估计^[34]。文章中均给出了相应的应用实例,表明了方法的可行性,但该迎角和侧滑角估计方法也仅适用于有轻微垂直风的情况。

1.2.3 大气扰动研究

风切变、阵风、湍流等非均匀气流的大气扰动现象严重影响民航飞机的性能与品质。大气湍流是大气中存在的一种随机的、不规则的运动,它与大气中的温度、不连续变化的密度层等因素密切相关。大气湍流主要分为两大类:一类是与强对流活动有关的低频小尺度灾害性天气,如雷暴、微下击暴流风切变等,飞行中一般采取规避措施;另一类是天气晴朗时,出现在 6000m 以上高空的高频大气湍流,该类型湍流与大气中的对流活动没有直接的关系。大气湍流伴随着能量、动量以及物质的传递和交换,其速度和能量传递均远远大于层流^[4]。因此,大气湍流对飞行器的飞行性能、结构载荷、飞行安全的影响很大。飞机在大气湍流中飞行时会发生颠簸,给乘客带来不适和恐惧感等。因此,飞行员应通过气象预报或相关预测等手段,尽量避免飞机穿越大气湍流等区域。

在湍流飞行条件下,迎角传感器等大气数据系统难以准确测量迎角、侧滑角, QAR 不能准确记录湍流飞行中的风速风向,这是 QAR 研究人员的共识。由于 QAR 记录的飞行参数中有状态冗余,某些不能准确记录的参数可以通过其他准确记录的参数计算获得,因此基于 QAR 数据准确估计气流角和扰动风成为一种理论上可行的技术途径。

早期 NASA 的研究人员基于空管数据和记录的飞行数据,获得飞机的实时位置、三轴角速度和发动机推力,通过建立气动力系数和上述参数的力学方程,采用牛顿-拉弗森迭代优化非线性方程获得迎角、侧滑角,然后利用文献[22]提到的 SMACK 程序进行实时扰动风估计,并结合实际风场进行了验证研究^[35]。后来基于大气观测数据,出现了用于研究扰动风的 Dryden 湍流模型和 von Karman 湍流模型^[36],两个模型都基于功率谱密度理论,对飞机采用质点假设,将其结合到动态仿真过程中,可以预测飞机对湍流的响应。此外,也有学者采用基于 QAR 数据的状态估计的研究思路,分析研究扰动风影响下飞机下洗延迟气动效应^[37]、起落架及刹车系统状态参数辨识^[38]等内容。

近年来,有国外学者利用扩展卡尔曼滤波器将惯性信息与外部传感器数据融合在一起,例如皮托管与光流传感器的数据,通过随机游走(Random Walk, RW)模型来预测飞行器的风场状态。但大气数据传感器在某些情况下会无法使用或高度不准确^[39,40]。为了改善大气数据传感器的情况,文献[41]提出了一种基于多目标优化的算法,该算法从惯性单元、GPS 传感器和控制输入获取信息,以估计最适合给定模型结构的风速。但该估计方法也仅适合于机身较轻和飞行缓慢的微型飞行器。最新的一篇文献中描述了两种方法——Allan 偏差方法和 Weibull 方法,来确定不同随机风模型——RW 模型和高斯·马尔可夫(Gauss Markov, GM)模型的相关参数,以得到更准确的风场状态。结果表明,采用上述两种方法优化 GM 模型得到的风速比 RW 模型得到的风速更为准确^[42]。

国内最新关于扰动风场的研究也较多。文献[43]根据 Dryden 大气紊流模型建立了飞行器所处的风场环境,利用牛顿-欧拉方法推导出有扰动风下的飞行动力学方程和飞行器的惯性信息,计算得到飞行器所处的扰动风场状态。文献[44]分析了在高原特殊机场下的扰动风对飞行的影响机理,在气流坐标系下建立了含扰动风动力学模型,并考虑 QAR 数据中的气流角、欧拉角、空间位置等记录参数,计算获得实时扰动风场。文献[45]基于风能发电来精确估计有效风速,通过未知的输入扰动观测器准确估算气动力矩,然后基于非线性输入输出映射的极限学习机模型,估算风力涡轮机的空气动力学特性,最终得到有效风速。另有文献[46]从控制角度研究风切变,该文献采用线性变参数(Linear Parameter Varying, LPV)建模与控制方法,研究飞机在风切变条件下的扰动抑制问题。文章建立了一个基于函数代换的 LPV 控制器和考虑了风切变效应的飞行动力学模型(Flight Dynamics Model, FDM),并用遗传算法对 LPV 分解函数进行了优化;在 LPV FDM 的系统矩阵中明确包含了风的扰动,以风扰动为外部不确定性,提出了基于 LPV FDM

的鲁棒 LPV 控制方法。

1.2.4 颠簸研究现状

本课题主要研究由晴空湍流造成的飞行颠簸。晴空湍流区有明显的边界，飞机进入后将突然产生颠簸，一般用气象学的切变不稳定理论来解释其形成的原因。该理论认为，当风出现垂直方向的切变且超过某一最大限定值时，就会导致产生的 Kelvin-Helmholtz 重力波波形破碎，大气气流的状态就会由层流转为湍流运动，从而形成晴空湍流，并直接诱发飞行颠簸^[47]。因此，晴空湍流造成飞机颠簸的实质是垂直风影响飞机沉浮和俯仰运动。大多数的晴空湍流没有目视征兆，如果湍流强度较大，对飞行的危害非常大。

文献[48]从气象机理的角度深入分析了造成飞行颠簸的大气湍流和高空急流等天气诱因。文献[49]则基于飞机气象数据转播数据，深入分析了飞行颠簸的水平分布特征、颠簸强度的时间分布特征、颠簸与飞行高度的关系、与冷暖半年风速风向的关系等内容。文献[50]深入分析了气流经过高原山脉地形区产生的山脉重力波所诱发的飞行颠簸机理情况，并进行了数值模拟。这对我国高原山区地形的飞行颠簸问题研究具有重要的指导意义。

当前，湍流观测和颠簸预报的主要方式有两种：制定飞行计划时，根据重要的天气情报向机组做出提醒；飞行过程中，飞行员根据飞行状态发出飞行员报告(Pilot Reports, PIREPs)提醒后方机组注意和绕飞^[51]。航空公司颠簸预报的一般流程如图 1.4 所示。

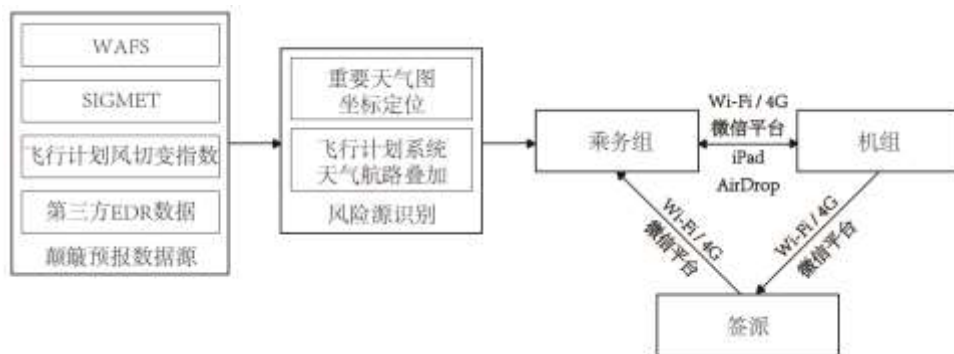


图 1.4 航空公司颠簸预报一般流程

第一种方式根据气象预报做出预测提醒。在飞行前准备时，使用世界区域预报系统(World Area Forecast System, WAFS)提供的气象数据、重要气象资料等，提醒机组在航路中的哪些区域和范围存在何种程度的颠簸。例如某航空公司是使用杰普逊公司 JetPlan 软件，可根据 WAFS 的颠簸区和急流轴，计算最大风切变指数(Maximum Wind Shear, MXSH)。在做飞行计划时，针对 MXSH 较大(MXSH>9)的情况进行提醒，并考虑增加备份油量；超过一定值(MXSH>15)则修改航路，从而对机组作出提醒。但该种方式存在以下问题：基于 WAFS 等气象数据进行颠簸预测有时不准确，常用的商用软件存在虚警和漏警现象。究其原因，WAFS 等数据来自于大尺度

天气系统预报,经 JetPlan 等商用软件给出颠簸强度预测。而中高空湍流层属中小尺度天气系统,通过大尺度天气观测,难以对中小尺度的湍流云层进行准确定位。

第二种方式的 PIREPs 由于其在空间和时间上的广覆盖性而被广泛的使用。通过飞行员自愿或强制的飞行报告,地服人员可以获知航线上的湍流情况并在一定程度上进行颠簸预报,同一航线飞机的飞行员、调度员和空中交通管制员可以以此策略性的避开可能导致人员受伤、飞机损伤的强湍流区域。但是,在实际 PIREPs 中飞行员使用轻、中、重三项主观指标来评估飞机遭遇的湍流颠簸强度,使 PIREPs 具备了高度的主观性,其对遭遇的湍流强度,颠簸时间和位置等方面的报告存在高度的不确定性。在受到飞机自身因素严重影响的同时缺乏定量的分析,无法为后续航班提供较为精确的颠簸预报。一个显而易见的事实是,不同的飞机以不同的空速穿越湍流,产生的颠簸是不同的,中型飞机所遭遇的轻微颠簸对于后续小型飞机而言可能就是严重颠簸。

飞行颠簸产生的最为直接的原因是大气湍流,但目前的颠簸预测方法没有考虑湍流对飞机的影响机理。而 MXSH 等指数的计算方法只是通过两个高度层的风向风速的变化,通过一简单公式计算获得。由此也造成目前对颠簸严重程度仅有轻度(light)、中度(moderate)、严重(severe)三级的描述,缺少进一步的科学量化指标。

相比于定性的 PIREPs,通过飞行数据分析,有三种指标可以用来估计湍流强度:垂直加速度、湍流耗散率(Eddy Dissipation Rate, EDR)和等效垂直阵风速度。垂直加速度是早期使用的量化飞行中遭遇大气湍流的指标,高度依赖于飞机自身参数,能精确反映当前飞机的颠簸程度,但是数据通用性极差,不同飞机间获取的数据很难互相参考。鉴于湍流的统计性能只由湍流动能涡旋耗散率决定,所以在垂直加速度指标之后,EDR 被选取作为估计湍流强度的指标。考虑机型因素进行机型特化后, Sherman 在垂直加速度的基础上进一步推导后得到不同机型下的等效垂直阵风速度^[52]。在这三种指标中,EDR 由于其通用性和对机型信息依赖相对较小的优点得到了广泛的使用。目前,EDR 是已被国际民用航空组织选为衡量湍流强度的代表性指标^[53]。美国国家航空咨询委员会(National Advisory Committee for Aeronautics, NACA)就曾通过整合航线上大量的 EDR 数据,生成了一个近乎实时的航路湍流强度地图,从而提高了其航线网络对湍流的态势感知能力。

1.3 本文研究内容及章节安排

本文基于飞行数据对飞机状态估计进行研究,运用 EKF 算法、UKF 算法以及基于极大似然准则的自适应扩展卡尔曼滤波(Maximum Likelihood Criterion-Adaptive Extended Kalman Filter, MLC-AEKF)算法对飞机状态进行估计,并对比三种算法的估计效果,最后建立湍流模型,对三维空间扰动风进行估计。本文具体研究结构如图 1.5 所示:

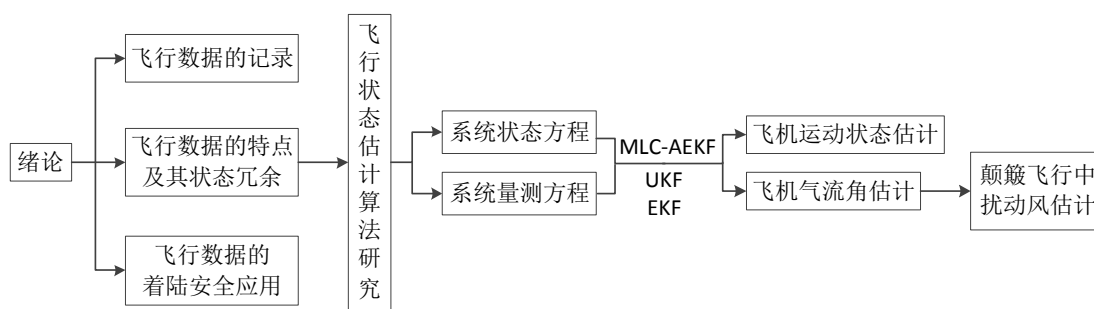


图 1.5 论文结构安排

本文各章节内容安排如下：

第一章，绪论。阐述本文的研究背景和意义，分别总结了飞行数据应用、飞行状态估计、大气扰动以及颠簸预报四个方面的研究和应用现状，并对其中存在的问题进行分析。

第二章，飞行数据及其着陆安全应用。主要研究了飞行数据记录系统的组成，以及主要存在的三种飞行数据记录格式；总结和分析了飞行数据的特点及其状态冗余；对飞行数据进行应用，研究了影响重着陆和长着陆事件发生的主要飞行参数。

第三章，飞行状态估计算法研究。基于对 EKF、UKF 两种非线性滤波算法分析之上，主要研究了一种基于极大似然准则的自适应扩展卡尔曼滤波算法；并应用三种算法对飞机的位置、速度、加速度状态进行估计，对比三种算法的估计性能。

第四章，飞机气流角估计。由于飞行数据不能准确记录气流角数据，基于非线性飞行动力学模型，考虑飞行数据的记录特点，将非等间隔理论和 MLC-AEKF 算法相融合，对飞机状态跟踪，同时与 EKF、UKF 算法估计结果进行对比，估计飞机迎角、侧滑角的值。

第五章，颠簸飞行中的湍流扰动风估计初步研究。考虑到飞行数据中只记录了水平风，没有垂直风的记录，根据 von Karman 大气湍流模型以及真空速、地速与风速之间的矢量关系，建立扰动风估计模型，采用扩展卡尔曼滤波器对轻、中、重度三种不同颠簸程度下的三维空间扰动风进行估计。

第六章，总结与展望。对本文研究的主要工作及其创新之处进行总结，并进一步分析本文研究过程中存在的不足以及对今后的工作和研究方向的展望。

第二章 飞行数据及其在飞机着陆安全中的应用

本章主要对基于 QAR 的飞行数据进行系统地介绍、分析和应用。介绍了飞行数据记录的相关内容；分析了飞行数据以及本文涉及到的主要飞行参数的记录特点以及存在的野值、缺失值的处理方法，并以空速为例，研究了飞行数据的状态冗余情况；对 QAR 数据进行应用，研究了飞机重着陆和长着陆两个不安全事件的影响因素。

2.1 飞行数据的记录

飞行数据的记录最初是伴随着事故调查的需求而不断完善和发展的。随着记录技术的不断提高，目前的飞行数据记录的航班飞机 1000 多个参数，飞机设备的工作状态以及相关性能均蕴含在其中。随着大数据时代的到来，数据可以被用来做越来越多的事情。飞行数据主要通过飞行数据记录系统进行收集和传输，其数据记录形式也会随着记录系统的不同而不同。

2.1.1 飞行数据记录系统

最初的飞行数据记录器由金属箔组成，只能记录 5 个参数：时间、高度、航向、过载和空速。随着事故调查的要求和需求不断增加，20 世纪 60 年代出现的以磁带为记录媒介的 FDR，能记录 100 多种参数，但磁带式记录器容量有限，抗破坏性能也较差。到 90 年代，数字保存技术高速发展，出现的固态存储器已经能够记录 1000 多个参数，且存储量大、抗破坏性能好^[8]。

目前的飞行数据记录系统基本上都以固态存储器作为存储介质，按照航班运行的时间顺序，通过飞机的状态监控系统 and 机载电子设备，将飞机的时间、空间、设备等各性能参数传输到机载数据存储设备上，主要由输入数据源、飞行数据采集单元(Flight Data Acquisition Unit, FDAU)、机载数据存储设备组成，其中 FDAU 是整个飞行数据记录系统的核心^[54]。FDAU 是从飞机上的传感器和电子设备接收各种模拟参数，然后传输到机载存储设备上。目前的机载数据存储设备主要包括两种：数字式飞行数据记录器 FDR 和快速读取记录器 QAR。

FDR 虽被俗称为“黑匣子”，但其实并不是黑色的，而是比较鲜艳的桔红色，FDR 的外观也都不尽相同，几种不同样式的 FDR 如图 2.1 所示。FDR 相比于 QAR，数据提取工作相对比较复杂，需要首先将 FDR 从飞机上取出来，然后用专门的读取软件进行转录和传输，转录所需时间较长且十分复杂，转录和传输的过程也易发生数据缺失和错误。因此，FDR 只有在发生飞行事故后才会被使用，根据飞机事故前记录的数据和语音，经过转录等解码处理后，将数据输入飞行模拟器来重现事故发生的过程^[55]。



图 2.1 飞行数据记录器

QAR 最大的特点就是通过 USB、网络连接或存储卡，就可以方便、快速地访问原始飞行数据。近年来，民航产业飞速发展，航空公司在运营过程中越来越看重工作的快速性和及时性。所以，目前的民用飞机特别是客机，基本上都安装了无线快速存取记录器(WQAR)。WQAR 是当今信息时代发展的产物，它可以存储飞机飞行过程中监控系统实时传输过来的数据，航班运行结束后可以通过两种方式获得飞行数据：一种是通过移动网络自动上传获得，第二种是地面取卡获得数据。WQAR 除了上传数据，也可以上传数据。WQAR 的信息存储类型也更广泛，不仅包括飞行状态、发动机、空管等常规的飞行数据，还可以记录飞机健康管理的相关机载监控信息和事件报文信息^[8,56]。


2.1.2 飞行数据的记录格式

随着飞行数据记录器的发展，相应的记录格式也在不断变化。飞行数据记录器从模拟式 FDR 到数字式 FDR，再从光盘记录式 QAR 到无线上传式 QAR。数据记录格式标准也从 ARINC 542 到 ARINC 573 到最新的 ARINC 717。目前飞行数据记录格式的适用标准基本上均为 ARINC 717。注意，这里 ARINC 代表美国航空无线电通信公司(Aeronautical Radio Inc., ARINC)的简称——爱瑞克公司，它是联邦通信管理委员会唯一授权的独立于政府之外的协调管理和认证航空公司无线电通信工作的公司^[57]。

在飞行数据记录中，帧是信息记录的单位。每个帧的开头都会记录一个同步字，用于避免与其他帧的结构混淆及记录错误，确保记录有序进行。下面介绍一下这三种记录格式：


1. ARINC 542 格式

ARINC 542 规范记录格式是根据前期的 FDR 进行制定的。前期发展的 FDR 记录参数少，帧的结构也很简单，记录参数仅包括飞行高度、空速、加速度以及航班日期等，利用这些数据也只能简单地对事故进行分析，满足国际民航组织规定的最低要求。以国外某公司型号的 FDR 为例，其一帧记录结构如图 2.2 所示。



2. ARINC 573 格式

ARINC 573 格式的记录规范与上述规范不同，它为四秒为一帧，每帧包含 4 个运行一秒的副帧，每个副帧记录的字数由 1 个变为 64 个，每个字依然 12 个字节。每个副帧的开头为同步字。由上可知，ARINC 573 格式相较于 ARINC 542 格式，其记录数量得到大幅度提升。图 2.3 为 ARINC 573 格式的记录结构。



3. ARINC 717 格式

航空事业快速发展，记录的飞行参数越来越多，ARINC 573 规范也已不能满足需求。这个时期，QAR 和 WQAR 设备也逐渐出现，他们所记录的参数已达上千个。因此，ARINC 公司又制定了新的数据记录规范，也就是现在运输类飞机使用最为广泛的 ARINC 717 数据记录格式。

ARINC 717 数据记录格式采用了以下两种方式来增加记录参数的数量和容量：

(1) 增加了每个副帧的记录字数。

ARINC 573 格式每个副帧的记录字数为 64 个字，而 ARINC 717 数据记录格式的每个副帧可以提高到 128、256 或 512 个字等。波音 737-MAX 机型的记录字数已达到 1024 个。

(2) 采用超级帧。

原来的记录格式一个字或多个字只能记录一个参数，而 ARINC 717 数据记录格式一个字槽可以记录多个参数，这样的帧被称为超级帧。但这样会容易导致数据记录混乱，所以超级帧采用分时顺序记录这 16 个参数，但这样就会使参数的采样率大大降低。因此，超级帧只适用于航班号、飞机重量等变化缓慢或不变的参数的记录，一些较为重要的飞行状态参数不适宜采用该方法^[6]。

2.2 飞行数据的特点及其状态冗余

由于 FDR 数据只有在发生飞机事故的时候才会被使用，而在日常中是使用 QAR 数据来对飞机进行状态监控和品质分析等应用。因此，本文只对 QAR 数据进行分析和研究。

2.2.1 飞行数据的特点

飞行数据记录系统记录的数据都是通过压力传感器、温度传感器等各种功能传感器进行测量获得有关飞机飞行状态的参数。飞行数据有以下两个基本特点：

(1) 量大。全行业所有航空公司共有 3000 多架飞机，每天共有 10000 多个航班飞行，每个航班 1000 多个参数，每个参数每秒记录 1-16 次。根据某型飞机飞行参数记录手册^[6]，本文研究过程中需要用到的各飞行参数及其记录特点如表 2.1 所示。从表中可以看出，并不是所有参数的采样频率都是一样的，相关人员会根据参数的重要程度和使用情况来选择合适的采样频率。每天都有这些海量数据传送到航科院进行处理分析，因此这些庞大的数据对传输数据的服务器以及储存数据的设备均有较高要求，对处理和分析批量数据的模型和系统的要求更高。

(2) 低质。飞行数据在传感器测量、记录、传输的过程中，由于外部环境干扰或者仪器工作不稳定、发生故障等原因，存在数据突变、数据缺失等各种异常情况，因此出现数据失真的情况也很常见。本文的数据研究基础是 CSV 格式的 QAR 数据，这些航班数据中不可避免的具有“低质”的特点，所以在进行应用之前，要先对这些 QAR 数据进行预处理。

表 2.1 本文主要飞行参数及其记录特点

飞行参数名称	数值范围	采样频率	分辨率	精度	单位
计算空速	0~512	4	0.25	+/-1	knot
地速	0~1024	4	1.0	+/-3	knot
俯仰角	+/- 32	4	0.0625	无	deg
滚转角	+/- 32	4	0.0625	无	deg
横向加速度	+/-1	16	0.00203649	+/-1.0%	g/s
纵向加速度	+/-1	16	0.00203649	+/-1.0%	g/s
垂直加速度	-3~6	16	0.00228938	+/-1.0%	g/s
滚转角速率	+/-128	8	0.0625	无	deg/s
俯仰角速率	+/-128	8	0.0625	无	deg/s
偏航角速率	+/-128	8	0.0625	无	deg/s
下降率	+/-16384	4	8.0	40	feet/min
迎角	+/-90	4	0.17578125	无	deg
风速	0~256	1	0.5	+/-2	knot
风向	+/-180	1	0.3515625	+/-2	deg
总温	+/-128	1	0.25	+/-1	deg C
飞机重量	0~327680	1	80.0	无	pounds
马赫数	0~1.024	1	0.001	无	mach
气压高度	+/-65536	8	128.0	+/-15	feet
无线电高度	+/-2048	8	1.0	2%	feet
驾驶杆位置	-13.75~14.75	8	0.02202473	+/-20	deg

目前,对于飞行数据中异常值和空缺值的基本处理方法,包括差分法、多项式滑动拟合法、曲线拟合和样条插值等,其中最常用的算法为多项式滑动拟合和样条插值。随着数据挖掘算法的发展,神经网络等机器学习算法可以更好地对异常值进行处理。当异常值、空缺值航班数量较多、较严重时,可以采用机器学习相关的算法进行处理。而一般 QAR 数据出现的异常值和空缺值相对于海量的数据参数还是很少的,所以采用一般的多项式滑动拟合法和插值基本可以解决。

Matlab 中自带的 filloutliers 函数就可以对异常值进行处理,该函数可以通过多种方法来替换数据中的离群值。图 2.4 为飞机在整个飞行时间内气压高度的处理效果图。原始数据中,由于传感器传输或记录等其他错误,导致很多接近于零的异常值出现。使用 Matlab 中的 filloutliers 函数,定义滑动窗口长度为 20,进行样条插值,从而消除异常值。从图中可以看出,该函数能

够有效处理异常值。




图 2.4 filloutliers 函数异常值处理效果图

2.2.2 飞行数据的状态冗余

QAR 中共记录了 1000 多个飞行参数，参数之间不可避免的存在数据冗余，也就是某一个数据参数，也可以通过其他的几个记录参数计算获得；或者飞行数据记录器里面由于某参数的不便记录而没有该参数的数据，可以通过其他记录的参数计算得到。例如，QAR 数据里面只记录了计算空速 V_c ，而没有真空速 V_t 的记录，那么便可以通过其他参数的记录来计算真空速。本文后续需要通过真空速来计算湍流扰动风，因此这里对真空速的状态冗余进行分析计算。

根据 QAR 记录的数据，可以采用两种方法来计算真空速。

第一种是利用飞机温度计算音速，再根据马赫数得到真空速，计算公式如下所示：

$$\begin{cases} a = \sqrt{kgRT} \\ V_{Ta} = M \times a \end{cases} \quad (2.1)$$

式中， V_{Ta} 为根据音速得到的真空速； a 为音速； k 为绝热指数； g 为重力加速度； R 为气体常数。

第二种方法是将 QAR 数据中记录的计算空速 V_c 消除密度误差后，得到真实空速，其计算公式为：

$$V_{Tp} = V_c \sqrt{\frac{\rho_0}{\rho_H}} \quad (2.2)$$

式中， V_{Tp} 为消除密度误差得到的真空速； ρ_H 为根据气压高度得到的大气密度； ρ_0 为空气密度。

选取某一航班 QAR 记录的数据，根据两种方法计算得到的空速对比如图 2.5 所示。可以看出，两种算法在飞机初始起飞与最后降落阶段稍有不同，在高空巡航阶段基本上是无差别的。

由于本文研究的是高空晴空湍流，因此两种算法均是可以采取的。考虑到根据 QAR 数据记录的温度与马赫数来计算真空速较为方便，而第二种方法的气压密度需要查表得到，因此，本文采用第一种方法来计算真空速。




图 2.5 两种方法计算空速结果对比图

2.3 基于飞行数据的着陆安全影响因素分析

飞机进场着陆阶段由于近地面气流紊乱、飞行速度变化范围大、操作程序复杂，是飞行任务中的事故多发阶段。在这一阶段发生的不安全事件中，重着陆事件占很大比例。重着陆事件一般不会造成严重的人员伤亡，但会降低乘坐舒适性，且会对飞机本身的结构，特别是起落架，造成疲劳损伤，降低飞机使用寿命。冲出跑道和偏出跑道是着陆过程中另一多发事件，而长着陆，也就是通常所说的平飘距离过长，是导致飞机冲出跑道的重要因素^[58]。长着陆会减少跑道的可用比例，同时增加管制员指挥与放飞的难度，如果控制不得当，飞机则可能会冲出跑道，造成难以预料的后果。因此，对重着陆和长着陆事件的影响因素进行探究具有重要意义。

考虑飞行数据的时间序列信息，运用灰色接近关联分析方法和融合灰色系统理论、统计分析的灰典型相关分析方法，来寻找重要飞行参数与两个不安全事件之间定量的关联性。

2.3.1 着陆模型与参数选取

判断长着陆的主要参数是平飘距离 x ，判断重着陆的主要参数是接地载荷 n_z ，因此接地前的飞行员操作对是否会造成重着陆和长着陆事件具有关键的作用。飞行员一般在通过决断高度后接管飞机，通过拉平操作使飞机安全柔和着陆。飞机决断高度一般在 200ft 左右，因此本文选择 200ft 为本文数据研究起始点，50ft 一般为飞机跑道入口点高度，选取 50ft 为第二个节点。根据着陆模型将着陆过程中的所有参数均划分为 2 个阶段：200ft-50ft 和 50ft-0ft（跑道入口至接地段即为 50ft-0ft）。

本文选用同一航班的一批飞行数据为试验基础，包括 3500 个正常航段，650 个长着陆航段、

520 个重着陆航段，数据一致性较好，能够为获得准确的分析结果提供数据保证。

飞机进场着陆过程一般分为两个部分：进场阶段与拉平飘落阶段，结合着陆阶段动力学分析，分别计算两个空中阶段的地面距离^[59]。如图 2.6 所示，进场阶段的地面距离 x_{Ap} 可近似为：

$$x_{Ap} = (h_{Rp} - h_f) / \tan \gamma_{Ap} \quad (2.3)$$

拉平飘落阶段的着陆路径简化成曲线圆弧，下滑角度 γ_{Ap} 从 3° 逐渐变为 0° ，拉平阶段的升力 L_f 可近似为：

$$L_f = m + (m / g) V_{Ap}^2 / R_f \quad (2.4)$$

$$L_f = (1 / 2) C_{L,Ap} \rho V_{Ap}^2 S \quad (2.5)$$

$$m = (1 / 2) C_{L,m,Ap} \rho V_{S,Ap}^2 S \quad (2.6)$$

$$L_f / m = (C_{L,Ap} / C_{L,m,Ap}) (V_{Ap} / V_{S,Ap})^2 \quad (2.7)$$

式中， m 为飞机重量； g 为重力加速度； V_{Ap} 为进近空速； $C_{L,Ap}$ 为升力系数； $C_{L,m,Ap}$ 为最大升力系数； ρ 为空气密度； $V_{S,Ap}$ 为飞机进场失速速度； S 为机翼面积。




图 2.6 进场着陆航迹简化模型

固定机型的 $C_{L,Ap}$ 和 V_{Ap} 是已知的，结合本文试验机型和相关气动参数有： $C_{L,Ap} = 0.64 C_{L,m,Ap}$ ， $V_{Ap} = 1.3 V_{S,Ap}$ 。根据式(2.7)，有 $L_f / W_{Ap} = 0.64 (1.3)^2 = 1.08$ ，将其带入式(2.4)，得：

$$R_f = V_{Ap}^2 / (0.08g) \quad (2.8)$$

根据图 2.5 有：

$$x_f = R_f \sin \gamma_{Ap} = [V_{Ap}^2 / (0.08g)] \sin \gamma_{Ap} \quad (2.9)$$

由式(2.9)可知， x_f 与 V_{Ap} 即进近空速有关，飞行员控制 V_{Ap} 主要参考飞机进近基准速度 V_{REF} ，而 V_{REF} 只与飞机重量 m 有关，因此本文根据每个航段飞机着陆时的重量建立标准的进场着陆模型。图 2.7 是根据某一航段飞机着陆重量建立的 50ft 至接地段标准着陆模型。




图 2.7 标准着陆模型

飞机在实际飞行的过程中会受到很多因素的影响，包括环境因素、飞机自身性能与重量、飞行员操作等，而这些因素影响的结果最终都会反映在飞机的运动学变化上，即造成飞行状态的变化。本文根据着陆过程理论分析并结合其他文献^[14,16]给出的参考因素，选取无线电高度 h_{Rp} 、地速 V_{Gp} 、进近空速 V_{Ap} 、下降率 d_{Rp} 、俯仰角 θ 、滚转角 ϕ ，同时加入了关于飞行员操作的两个参数驾驶杆位移 δ_c 和油门杆角位移 δ_t 共 8 个因参数进行分析，其中 δ_c 、 δ_t 分别表示相对于相应标准着陆参数序列的上下位移浮动值。

2.3.2 灰色接近关联分析及其试验

飞行数据的记录偏差与传感器误差、不同机场的进场航路设计、当时的天气和扰动风、驾驶员的操纵习惯等密切相关，具有显著的不确定性，即数据灰度较大，整体的飞行数据可以看作一个灰色系统^[60]。首先选用灰色接近关联分析方法进行典型航段分析，以验证模型与方法的有效性；然后使用该方法找出在时间序列上对平飘距离和接地载荷影响较大的关键阶段参数。每个参数被分成 2 个阶段后，分析每个参数的这两个阶段参数之间的关联序，即关联度的大小次序。最优参考序列为每个航段标准着陆模型中飞行参数的时间序列值。

灰色接近关联度计算公式如下^[61]：

$$\varepsilon(X_i, X_j) = \frac{I}{I + |S_i - S_j|} \quad (2.10)$$

式中， $X_i = (x_i(1), x_i(2), \dots, x_i(n))$ 、 $X_j = (x_j(1), x_j(2), \dots, x_j(n))$ 为两个系统行为序列； $S_i - S_j = \int_1^n (X_i - X_j) dt$ 。当 X_i 、 X_j 为两个同型系统行为矩阵时，即 $X_i = X_p = (a_{i,j})_{M \times N}$ 、 $X_j = X_q = (b_{i,j})_{M \times N}$ ，则 $S_p - S_q = \int_1^M \int_1^N (X_p - X_q) dx dy$ 。

需要说明的是，灰色关联分析关注的是关联序，而不是关联度的数值大小。即便出现接近关联度的数值较小，也并不影响对关联序的分析。由于本文各飞行参数的量纲不同，因此本文所有参数均通过标准化处理后再进行分析。

在飞机重量 m 一致的情况下，本文分析两组实际典型航段，如图 2.8 所示。图 2.8(a)是相对于标准着陆航迹，着陆过程中无线电高度一直偏低，平飘距离也较短的一个典型航段，(b)是通过不断地调整最后基本能够按标准下滑轨迹下滑，但最终平飘距离稍大于标准航段的一个典型航段，这两个实际航段也验证了标准模型的合理性。通过灰色接近关联分析计算它们与标准模型之间的关联度值分别为 $\varepsilon(a)=0.6479$ 、 $\varepsilon(b)=0.8765$ ，关联序 $\varepsilon(a) < \varepsilon(b)$ 。根据实际过程，(b)图的着陆情形好于(a)图，所以关联序结果符合实际情况，说明了方法的有效性。

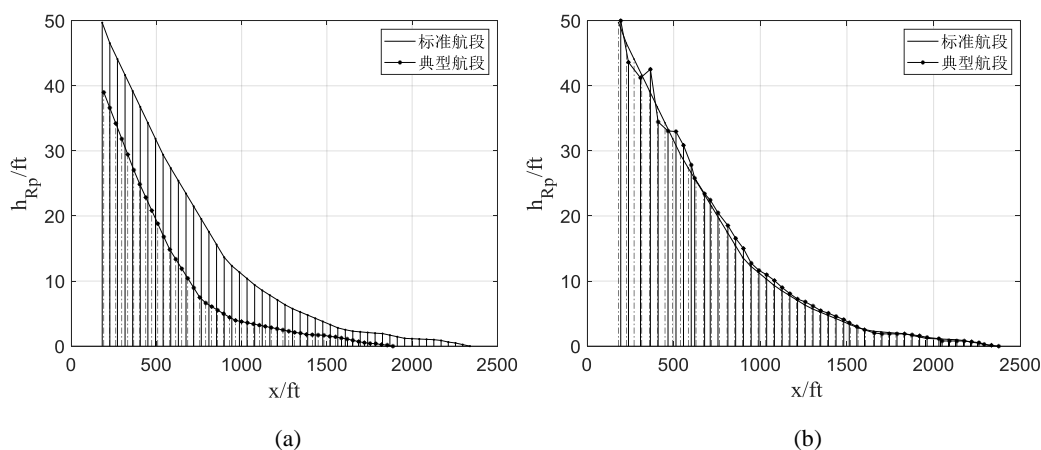


图 2.8 典型着陆航段与标准着陆航段模型对比

本文将 3500 个正常航段的平飘距离 x 从小到大依据直方图分为 10 个平飘距离区间，每个平飘距离区间中所包含的航段数量作为柱状图的高度，如图 2.9 所示。图 2.9(a)、(b)中横坐标表示平飘距离分布区间，左侧坐标轴表示各平飘距离区间的航段数量 N ，右侧坐标轴表示关联度值 ε 大小，两条折线表示两个阶段的关联度曲线，折线上的点为该区所有航段的 ε 的均值，可以看出，80%以上的航段分布在平飘距离 1400ft-2600ft 区间内。接地载荷 n_z 采样同样的方法分为 11 个分布区间，如图 2.9(c)、(d)所示，80%以上的航段集中分布在 1.05g-1.35g 区间内。8 个因参数，每个均分为 2 个阶段参数，由于参数较多，因此图 2.9 只列出部分因参数与平飘距离和接地载荷的分析结果。

从图 2.9(a)、(b)可知 h_{Rp} 和 V_{Gp} 在 50ft-0ft 阶段越接近于理想着陆平飘距离区间时，灰色关联度 ε 值越大，说明在着陆过程中越接近于标准参考序列，越能获得最优平飘距离。另外，50ft-0ft 阶段 ε 值明显大于 200ft-50ft 阶段，说明 50ft-0ft 阶段与平飘距离的关联性较大；同样，有关接地载荷的图(c)、(d)中 h_{Rp} 和 δ_i 的 ε 值 50ft-0ft 阶段也明显大于 200ft-50ft 阶段，且越接近于理想着陆区间时越趋于平稳。综上所述，图 2.9(a)、(b)、(c)、(d)，50ft-0ft 阶段的关联度值均明显大于 200ft-50ft 阶段，说明各参数在 50ft-0ft 阶段越接近于标准序列，对 x/n_z 影响越大。

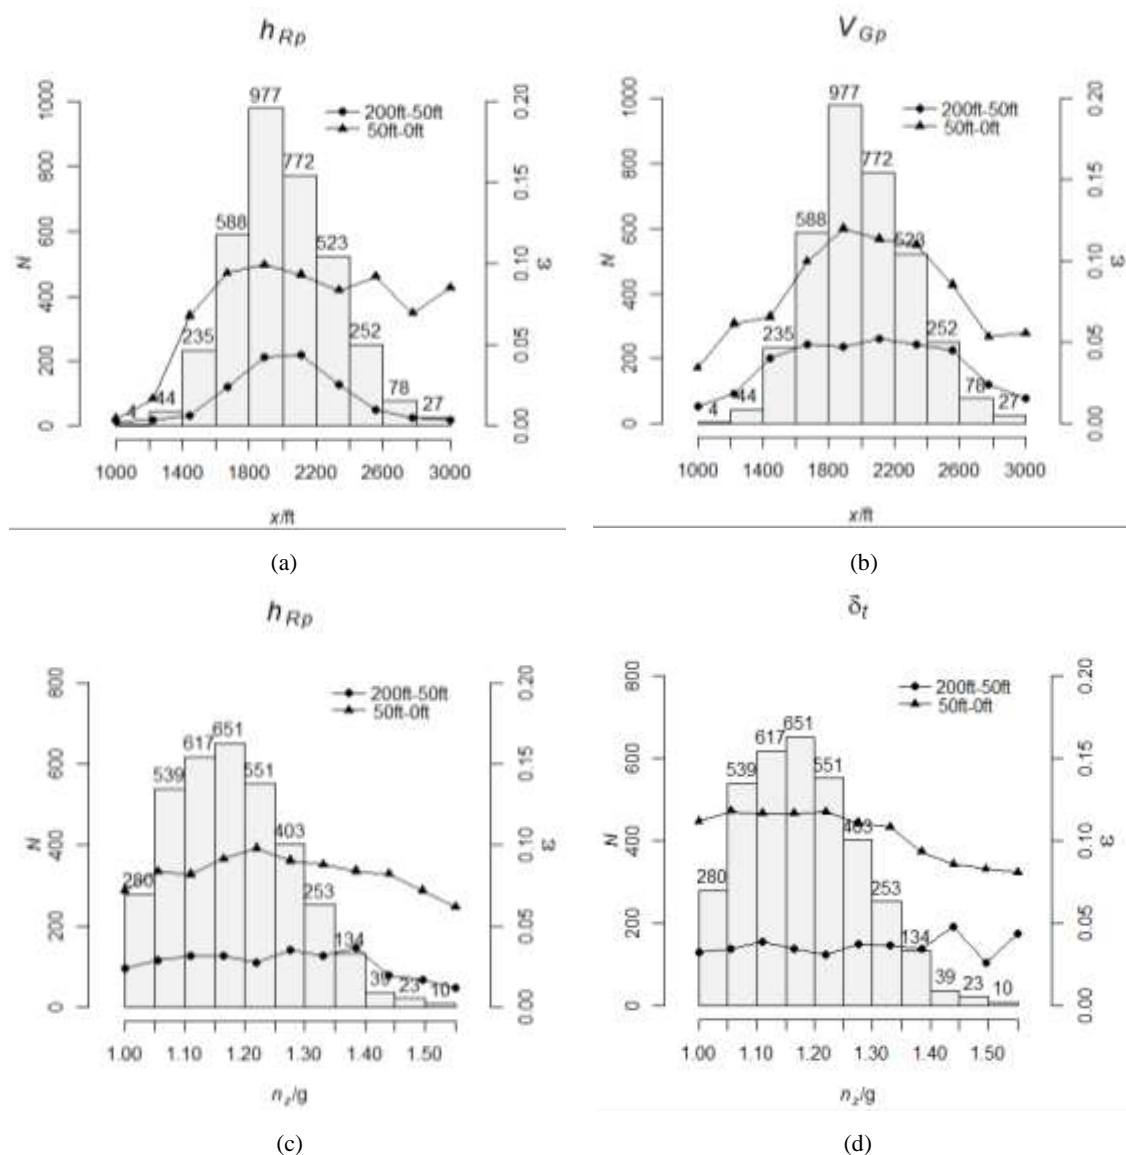


图 2.9 部分阶段因参数关联度分析结果

根据灰色接近关联度分析结果，对每一个参数的 2 个阶段参数对平飘距离和接地载荷的关联度计算均值，为减小误差，均去掉一个最大值和一个最小值，最后关联序结果展示在图 2.10 中。根据关联度数值大小次序，可以明显看出每个参数影响长着陆和重着陆的阶段因参数均在 50ft-0ft 阶段。通过研究实际飞机进近与着陆阶段数据发现，在飞行过程中，如果飞机在 200ft-50ft 通过不断调整，最后 50ft 按标准下滑道进行下滑，飞机也可以安全着陆。如果最后 50ft 操作不当，则长着陆和重着陆等不安全事件发生的概率就会大大增加。




图 2.10 平飘距离和接地载荷的各阶段因参数关联度条形图

2.3.3 灰典型相关分析及其试验

传统的典型相关分析不适用于解决时间序列问题，但可以提供变量载荷和典型相关系数等相关分析的定量分析手段，而灰色系统理论与时间序列分析关系密切，因此本文采用灰典型相关分析方法寻找 50ft-0ft 阶段因参数与长着陆和重着陆之间定量的关联性。

在实际飞行中，着陆性能由各个因参数共同决定，且因参数之间也相互影响制约，通过灰典型相关分析可以得到果参数与单个因参数以及整体因参数之间的关联性，这是单纯依靠灰色关联分析所不能得到的。

灰典型相关分析方法将灰色系统理论与传统典型相关分析结合，该模型能够抓住样本数据的时间序列特征，实时跟踪样本的动态变化^[62]。灰典型相关分析理论如下：

设序列 $S = \{s_1, s_2, \dots, s_n\}$ ，灰度 $G = \{g_1, g_2, \dots, g_n\}$ ，则 $GS = \{g_1 s_1, g_2 s_2, \dots, g_n s_n\}$ 称为一个灰序列，其中 $g_i = 1 / \ln(i), (i = 1, 2, \dots, n)$ 为序列 S 中的第 i 个元素 s_i 的灰度。灰序列的相关参数的统计特征是以白化序列为基础的，称 $w_i = 1 / g_i = \ln(i), (i = 1, 2, \dots, n)$ 为序列 S 中的第 i 个元素 s_i 的白度，对应的白序列为 $WS = \{w_1 s_1, w_2 s_2, \dots, w_n s_n\}$ 。白度在序列中随时间序列递增，对各元素的权值重新定义，突出了最新数据在时间序列中的影响。灰相关系数的计算公式为：

$$\begin{cases} E_G(S) = \sum_{i=1}^n w_i s_i / \sum_{i=1}^n w_i \\ V_G(S) = E_G[(S - E_G(S))^2] = \sum_{i=1}^n w_i (s_i - E_G(S))^2 / \sum_{i=1}^n w_i \\ GCov(S_i, S_j) = E_G[(S_i - E_G(S_i))(S_j - E_G(S_j))] \\ \rho_g(S_i, S_j) = GCov(S_i, S_j) / \sqrt{V_G(S_i) V_G(S_j)} \end{cases} \quad (2.11)$$

式中， $E_G(S)$ 表示序列 S 的灰数学期望； $V_G(S)$ 表示序列 S 的灰方差； $GCov(S_i, S_j)$ 均表示序列

S_i 与 S_j 之间的灰协方差； $\rho_g(S_i, S_j)$ 表示序列 S_i 与 S_j 之间的灰相关系数。

给定两组向量 x_1 与 x_2 ，其维度分别为 p 与 q ，并默认 $p \leq q$ ，样本的灰协方差记为：

$$GM = \begin{bmatrix} GCov(x_1, x_1) & GCov(x_1, x_2) \\ GCov(x_2, x_1) & GCov(x_2, x_2) \end{bmatrix} = \begin{bmatrix} GM_{11} & GM_{12} \\ GM_{21} & GM_{22} \end{bmatrix} \quad (2.12)$$

从 x_1 与 x_2 的整体考虑，定义式(2.13)，灰典型相关分析就是寻求最优组合 a 与 b ，使得两组灰序列变量有最大的相关性，每对线性组合称为灰典型相关变量，它们的相关系数称为灰典型相关系数，原始变量与灰典型变量间的相关关系的大小由灰典型载荷量来反映。

$$\begin{cases} Gu = a^T x_1 \\ Gv = b^T x_2 \end{cases} \quad (2.13)$$

灰典型相关分析的基本步骤为：

(1) 令 $W_1 = GM_{11}^{-1/2} GM_{12} GM_{22}^{-1} GM_{21} GM_{11}^{-1/2}$ ， $W_2 = GM_{22}^{-1/2} GM_{21} GM_{11}^{-1} GM_{12} GM_{22}^{-1/2}$ ，求解矩阵 W_1 、 W_2 的 p 个最大的特征值(两个矩阵的 p 个最大的特征值相同)： $\rho_{1g}^2 \geq \rho_{2g}^2 \geq \dots \geq \rho_{pg}^2$ ，以及 W_1 、 W_2 对应于 p 个特征值的特征向量 $e_{1g}, e_{2g}, \dots, e_{pg}$ 、 $f_{1g}, f_{2g}, \dots, f_{pg}$ 。

(2) 灰典型相关变量为： $Gu = e_k' GM_{11}^{-1/2} x_1$ 、 $Gv = f_k' GM_{22}^{-1/2} x_2$ ($k=1, 2, \dots, p$)，对应的灰典型相关系数为 ρ_{kg} 。

通过灰色接近关联分析找到细节分段后的飞行状态结果作为因参数，以 650 个长着陆航段、520 个重着陆航段的飞行数据为试验基础，取每一个长着陆或重着陆航段 50ft-0ft 阶段因参数组成的灰序列的加权平均值，与平飘距离和接地载荷分别进行灰典型相关分析。

表 2.2 是 50ft-0ft 因参数与长着陆和重着陆的灰典型载荷量统计结果。从统计表格中可以得出，在 50ft-0ft 的一系列参数中，对于长着陆，下降率 d_{Rp} 对长着陆的影响最大，载荷量大小为 0.9691，接近于 1；其次是俯仰角 θ 、驾驶杆位移 δ_c 、油门杆角位移 δ_t 的载荷量依次递减。在统计结果中，发现无线电高度 h_{Rp} 、俯仰角 θ 、滚转角 ϕ 的灰典型载荷量系数为负，说明这三个因参数为抑制变量，即随着 h_{Rp} 、 θ 、 ϕ 相对正常数值偏大，会引起长着陆与各个因参数的相关性的减弱，这与实际飞行操作是相符的，灰典型相关分析得出的灰典型相关系数是 0.8671。对于重着陆，地速 V_{Gp} 对重着陆的影响最大，载荷量为 0.7670，其次是无线电高度 h_{Rp} 、俯仰角 θ 。其中，下降率 d_{Rp} 、驾驶杆位移 δ_c 和油门杆角位移 δ_t 是抑制变量。实际飞行过程中，下降率、驾驶杆位移和油门杆角位移过于抖动会导致重着陆与相关因参数的相关关系不明显，这是符合实际情况的。整体因参数与重着陆之间的灰典型相关系数是 0.7547。

表 2.2 50ft-0ft 阶段因参数与果参数灰典型载荷量统计结果

参数	h_{Rp}	V_{Gp}	V_{Ap}	d_{Rp}	θ	ϕ	δ_c	δ_t
x	-0.2213	0.0465	0.3145	0.9691	-0.7157	-0.0412	0.5014	0.4849
n_z	0.4318	0.7670	0.0487	-0.2371	0.3321	0.1858	-0.0189	-0.1857

两个灰典型相关系数的显著性检验如表 2.3 所示，在给定的显著性水平 $\alpha=0.05$ 下，从表中可知，两个 $\text{Pr}(>F)$ 的值均小于 0.05，说明灰典型相关系数与 0 有显著差异，整体因参数与果参数之间的相关性较大。

表 2.3 灰典型相关系数的显著性检验

参数	Corr	F	Num df	Den df	$\text{Pr}(>F)$
x	0.8671	27.277	9	81	2.2e-16***
n_z	0.7547	1.470	9	27	0.0278**

综上所述，50ft-0ft 阶段下降率对长着陆的影响最大，其次是俯仰角、驾驶杆位移和油门杆角位移。对于重着陆，最为关键的影响因素是地速，无线电高度和俯仰角对重着陆的发生也有着较大的影响，且长着陆和重着陆与整体因参数之间的相关性也较大，说明着陆安全是由整体飞行状态参数共同决定。以上结论与飞行实践是相一致的，因此飞行员在操作飞机着陆的过程中要防止下降率和地速过大，必须柔和地操作驾驶杆和油门，防止长着陆和重着陆事故的发生。

2.4 本章小结

本章主要开展了以下研究：

(1) 对飞行数据的记录进行了详细研究与分析，包括飞行数据记录系统的结构以及飞行数据记录的格式规范；分析了飞行数据特点以及本文所涉及到的主要飞行参数的记录特点，对于飞行数据中存在的异常值、空缺值，主要采用滑动拟合和样条插值的方法进行处理；以空速为例，研究了飞行数据的状态冗余情况。

(2) 将 QAR 数据应用于着陆安全分析，运用灰色接近关联分析和灰典型相关分析两种算法，探究了影响飞机重着陆和长着陆两个不安全事件的影响因素。结果表明，50ft-0ft 阶段下降率对长着陆的影响最大，其次是俯仰角、驾驶杆位移和油门杆角位移；对于重着陆，最为关键的影响因素是地速，无线电高度和俯仰角对重着陆的发生也有着较大的影响。

第三章 飞行状态估计算法研究

本章将对飞机状态估计算法进行研究。目前,解决状态估计问题的常用的有效算法基本上都是卡尔曼滤波算法及其改进与推广。本章对卡尔曼滤波的理论基础——最小二乘估计进行分析,在充分研究了状态估计中最常用两种算法——扩展卡尔曼滤波算法和无迹卡尔曼滤波算法之上,探究了一种能够实时根据系统模型的变化进行调整的自适应扩展卡尔曼滤波算法。以对飞行器运动状态进行估计为例,对比三种算法的估计效果。

3.1 状态估计概述

3.1.1 估计理论基础

估计理论属于概率论和数理统计的范畴,就是根据某种准则,通过受到干扰的观测量来估计某种随机变量或随机过程,使其最大程度接近其真实值的一种数学方法。估计问题可描述为:假设 $X(t)$ 为被估计量, $Z(t)$ 是观测量,两者之间的关系可以如式(3.1)表示:

$$Z(t)=h[X(t),v(t),t] \quad (3.1)$$

式中, h 为 $X(t)$ 与 $Z(t)$ 之间的函数关系; $v(t)$ 是随机观测误差。可以将估计问题简述为:在一段时间内,通过对 $X(t)$ 观测得到其观测向量 $Z=\{Z(\tau),t_0 \leq \tau \leq t\}$,然后通过一个与观测量有关的函数 $\hat{X}(Z)$,对 $X(t)$ 进行估计,则称 $\hat{X}(Z)$ 为 $X(t)$ 的一个估计量^[63]。

估计问题分为状态估计和参数估计。状态估计是一个会随时间变化的动态估计过程,而参数估计是稳定的或者变化较为缓慢的静态估计过程。本文所涉及到的估计问题均是会随时间变化的状态估计问题。

通常,估计结果越接近于真实值,估计效果越好,那么就需要一个准则或者一个标准来衡量估计效果的优劣,这个准则或标准被称为估计准则。估计准则的目标是将估计结果最大程度上去接近真实值,两者之间的差距越小越好。因此,估计准则的选取与估计性能的优劣密切相关。估计准则多种多样,最小二乘准则、极大似然准则、极大验后准则等均为常用的准则,其中最小二乘估计是卡尔曼滤波算法的理论基础。

3.1.2 最小二乘估计

最小二乘(Least Squares, LS)估计是估计线性模型中状态量的一种方法,其基本思路为:选择合适的估计参数值使模型输出与观测输出的数据之差的平方和最小。

如果将 LS 估计归到最小方差估计中,那么最优估计主要分为最小方差估计和概率密度函数最大估计两种。概率密度函数最大估计具有估计精度高的优势,但需要知道状态和量测量的

概率分布密度函数，这在实际应用中是比较困难的，因此应用范围比较小。

最小二乘估计算法包括三种：古典最小二乘估计、加权最小二乘估计和递推最小二乘估计。古典最小二乘估计假设对所有的测量值的信任度是一样的，这样并不合理，因此算法精度也不高，后来演化成加权最小二乘估计。这两种最小二乘估计方法对当前状态进行估计时，都需要用到从初始时刻到当前时刻的所有测量值，不符合动态系统状态估计的需要，且占用内存大，不利于计算机递推计算。而后，提出了递推最小二乘估计，其核心思想是，在获得当前测量数据之后及时地进行处理，利用前一次得到的估计结果，对当前时刻的状态进行估计，而不必将数据全部重新计算一遍。

假设在得到 $k-1$ 个测量值之后，估计出了 \hat{x} ，然后又得到了 k 时刻的测量值 y_k ，则线性的递推估计值可以写成如下形式^[64]：

$$\begin{cases} y_k = H_k x + v_k \\ \hat{x}_k = \hat{x}_{k-1} + K_k (y_k - H_k \hat{x}_{k-1}) \end{cases} \quad (3.2)$$

式中， H_k 为 $k \times n$ 维矩阵； v_k 为 k 维量测误差向量，其方差为 R_k ； \hat{x}_{k-1} 为上一步的最优估计值， y_k 为 k 时刻新获得的测量值，从而对当前 \hat{x}_k 进行估计； K_k 为增益矩阵； $y_k - H_k \hat{x}_{k-1}$ 用来修正测量值的误差，被称为修正项。

线性递推估计器的估计误差均值可以表示为：

$$\begin{aligned} E(\varepsilon_{x,k}) &= E(x - \hat{x}_k) = E[x - \hat{x}_{k-1} - K_k (y_k - H_k \hat{x}_{k-1})] \\ &= E[\varepsilon_{x,k-1} - K_k (H_k x + v_k - H_k \hat{x}_{k-1})] \\ &= E[\varepsilon_{x,k-1} - K_k H_k (x - \hat{x}_{k-1}) - K_k v_k] \\ &= (I - K_k H_k) E(\varepsilon_{x,k-1}) - K_k E(v_k) \end{aligned} \quad (3.3)$$

式中， $\varepsilon_{x,k}$ 为真实值与估计值之间的误差。

选择 K_k 的最优标准是使 k 时刻估计误差的方差和最小，该最小方差和称为代价函数，用 J_k 表示：

$$\begin{aligned} J_k &= E[(x_1 - \hat{x}_1)^2] + \cdots + E[(x_n - \hat{x}_n)^2] \\ &= E(\varepsilon_{x1,k}^2 + \cdots + \varepsilon_{xn,k}^2) = E(\varepsilon_{x,k}^T \varepsilon_{x,k}) \\ &= E[\text{Tr}(\varepsilon_{x,k}^T \varepsilon_{x,k})] = \text{Tr} P_k \end{aligned} \quad (3.4)$$

式中， P_k 为估计误差协方差矩阵，其递推计算公式为：

$$\begin{aligned} P_k &= E(\varepsilon_{x,k} \varepsilon_{x,k}^T) \\ &= E\{[(I - K_k H_k) \varepsilon_{x,k-1} - K_k v_k][(I - K_k H_k) \varepsilon_{x,k-1} - K_k v_k]^T\} \\ &= (I - K_k H_k) E(\varepsilon_{x,k-1} \varepsilon_{x,k-1}^T) (I - K_k H_k)^T - \\ &\quad K_k E(v_k \varepsilon_{x,k-1}^T) (I - K_k H_k)^T - (I - K_k H_k) E(\varepsilon_{x,k-1} v_k^T) K_k^T + K_k E(v_k v_k^T) K_k^T \end{aligned} \quad (3.5)$$

$k-1$ 时刻的估计误差 $\varepsilon_{x,k-1}$ 独立于 k 时刻的量测噪声 v_k ，有：

$$E(v_k \varepsilon_{x,k-1}^T) = E(v_k)E(\varepsilon_{x,k-1}) = 0 \quad (3.6)$$

则最小二乘估计误差的协方差递推计算公式为：

$$P_k = (I - K_k H_k) P_{k-1} (I - K_k H_k)^T + K_k R_k K_k^T \quad (3.7)$$

目前需要找出一个 K_k 使得代价函数 J_k (P_k 的迹) 最小，则要对 J_k 求偏导，使其微分等于零：

$$\frac{\partial J_k}{\partial K_k} = 2(I - K_k H_k) P_{k-1} (I - K_k H_k)^T + 2K_k R_k = 0 \quad (3.8)$$

解出 K_k 为：

$$K_k = P_{k-1} H_k^T (H_k P_{k-1} H_k^T + R_k)^{-1} \quad (3.9)$$

经过上述分析，最小二乘估计算法过程主要由式(3.2)、(3.7)和(3.9)组成。

3.2 扩展卡尔曼滤波算法

滤波是从通信理论中演变而来，目前是估计系统状态的一种理论和方法。最优滤波理论主要包括采用频域方法的 Wiener(维纳)滤波理论和采用时域状态空间方法的 Kalman(卡尔曼)滤波理论。维纳滤波于早期被提出，仅适用于较为简单的随机过程，适用范围较窄，且滤波过程中需要存储全部历史数据，对存储容量的要求比较高，计算量也很大。卡尔曼滤波是一种时域方法，主要是通过建立系统状态方程和量测方程以及合适的模型噪声误差，来实现状态估计。由于卡尔曼滤波算法是递推的，可以实时估计非平稳、多维随机状态，因此适用范围较广^[64]。

3.2.1 标准卡尔曼滤波

递推最小二乘估计是卡尔曼滤波算法的理论基础，其最大的特点是可以随着时间向前递推处理测量数据，能够根据当前最新的测量值修正上一时刻的估计值，实现实时处理测量数据，其基本原理如图 3.1 所示。




图 3.1 卡尔曼滤波算法原理图

将离散线性系统描述为：

$$\begin{cases} x_k = A_{k-1}x_{k-1} + w_{k-1} \\ z_k = H_k x_k + v_k \\ w_k \sim (0, Q_k) \\ v_k \sim (0, R_k) \end{cases} \quad (3.10)$$

式中, x_k 表示 k 时刻目标或时间序列数据的状态; A_k 为状态转移矩阵; w_k 为状态噪声, 其噪声方差为 Q_k ; H_k 为量测矩阵; z_k 为量测向量; v_k 为量测噪声, 其噪声方差为 R_k 。

初始化滤波器:

$$\begin{cases} \hat{x}_0 = E(x_0) \\ P_0 = Var[x_0] \end{cases} \quad (3.11)$$

标准卡尔曼滤波算法的计算公式主要由两部分组成: 预测(时间更新)和更新(量测更新)。根据 $k-1$ 时刻的状态估计 k 时刻状态的过程如下:

1. 预测(时间更新)

(1) 利用 $\hat{x}_{k-1|k-1}$ 的状态预测 $\hat{x}_{k|k-1}$:

$$\hat{x}_{k|k-1} = A_{k-1}\hat{x}_{k-1|k-1} \quad (3.12)$$

式中, $\hat{x}_{k|k-1}$ 表示目标在 k 时刻的预测状态; $\hat{x}_{k-1|k-1}$ 表示 $k-1$ 时刻的状态估计值, 也可以表示为 \hat{x}_{k-1} 。

(2) 按照下式完成估计误差协方差的一步预测:

$$P_{k|k-1} = A_{k-1}P_{k-1|k-1}A_{k-1}^T + Q_{k-1} \quad (3.13)$$

式中, $P_{k|k-1}$ 表示目标在 k 时刻状态的估计误差预测协方差; $P_{k-1|k-1}$ 表示 $k-1$ 时刻的目标状态估计误差协方差, 也可以表示为 P_{k-1} ; Q_{k-1} 为系统噪声方差。

2. 更新(量测更新)

(1) 计算滤波器增益:

$$K_k = P_{k|k-1}H_k^T[H_kP_{k|k-1}H_k^T + R_k]^{-1} \quad (3.14)$$

式中, K_k 为卡尔曼滤波器增益; H_k^T 为 k 时刻量测矩阵的转置。

(2) 计算目标当前状态估计值:

$$\hat{x}_{k|k} = \hat{x}_{k|k-1} + K_k[z_k - H_k\hat{x}_{k|k-1}] \quad (3.15)$$

式中, $\hat{x}_{k|k}$ 表示 k 时刻目标的状态估计值, 也可以表示为 \hat{x}_k ; $z(k)$ 为 k 时刻的目标量测值; $z_k - H_k\hat{x}_{k|k-1}$ 被称为新息, 代表指某时刻的实际量测值与滤波器的量测估计值之差, 用 r_k 表示。

(3) 按照下式更新误差协方差的估计值:

$$P_{k|k} = (I - K_kH_k)P_{k|k-1} \quad (3.16)$$

式中, I 是 n 维单位矩阵; $P_{k|k}$ 表示 k 时刻的状态估计误差协方差, 也可表示为 P_k 。

需要指出的是: $\hat{x}_{k|k}$ 代表后验估计, 是使用 k 时刻及其以前各个时刻的测量值 z_k 估计 k 时

刻的状态 x_k ； $\hat{x}_{k|k-1}$ 是先验估计，是不包括 k 时刻在内的各个时刻的测量值得到的 k 时刻的状态估计值。先验估计 $\hat{x}_{k|k-1}$ 和后验估计 $\hat{x}_{k|k}$ 都是同一个量 x_k 的估计，然而 $\hat{x}_{k|k-1}$ 考虑的是测量值 z_k 之前的估计，也称为向前一步预测估计，而 $\hat{x}_{k|k}$ 考虑的是测量值 z_k 之后的估计。

3.2.2 扩展卡尔曼滤波

上一节讨论标准卡尔曼滤波算法仅适用于线性系统，而实际应用中线性系统几乎不存在，基本上都是非线性系统。理论上，只有当其非常接近于线性系统的时候，利用基本卡尔曼滤波算法才能得到较为准确的结果。

扩展卡尔曼滤波是过去几十年里应用最为广泛的非线性系统状态估计方法，其基本思想是利用泰勒级数展开，将非线性方程直接线性化。虽然线性化后的系统模型和系统实际的非线性模型会有差别，非线性越强，差别就会越大，但其由于没有其他附加计算，凭借着计算量小的优势而被广泛应用。

设离散非线性系统动态方程为：

$$\begin{cases} x_k = f(x_{k-1}, w_{k-1}) \\ z_k = h(x_k, v_k) \\ w_k \sim (0, Q_k) \\ v_k \sim (0, R_k) \end{cases} \quad (3.17)$$

式中， $f(\cdot)$ 和 $h(\cdot)$ 是非线性的过程方程和测量方程；系统噪声方差 Q_k 和量测噪声方差 R_k 均为均值为零的高斯白噪声，且假定状态噪声 w_k 和量测噪声 v_k 彼此独立。

泰勒级数展开是将非线性模型转化为线性模型最简单，也是应用最普遍的一种方法。泰勒展开的级数越多，两者就会越接近；当展开为无穷项时，两者就会相同^[65]。但展开阶数越多，其计算量也越复杂。一般情况下，取合适的阶次，对近似的线性化模型采用标准卡尔曼滤波算法进行估计即可。因此，将以上非线性函数 $f(x_{k-1}, w_{k-1})$ 在 $x_{k-1} = \hat{x}_{k-1|k-1}$ 和 $w_{k-1} = 0$ 处进行泰勒级数展开并忽略二阶及二阶以上的高阶项，得到近似线性化状态方程为：

$$x_k = f(\hat{x}_{k-1|k-1}, 0) + \left. \frac{\partial f}{\partial x} \right|_{x=\hat{x}_{k-1|k-1}} (x_{k-1} - \hat{x}_{k-1|k-1}) + \left. \frac{\partial f}{\partial w} \right|_{x_k=\hat{x}_{k-1|k-1}} w_{k-1} \quad (3.18)$$

设 $\left. \frac{\partial f}{\partial x} \right|_{x=\hat{x}_{k-1|k-1}} = \Phi_{k-1}$ ， $\left. \frac{\partial f}{\partial w} \right|_{x=\hat{x}_{k-1|k-1}} = L_{k-1}$ 为则上式可变为：

$$\begin{aligned} x_k &= f(\hat{x}_{k-1|k-1}, 0) + \Phi_k (x_{k-1} - \hat{x}_{k-1|k-1}) + L_k w_{k-1} \\ &= \Phi_k x_{k-1} + [f(\hat{x}_{k-1|k-1}, 0) - \Phi_k \hat{x}_{k-1|k-1}] + L_k w_{k-1} \end{aligned} \quad (3.19)$$

其中， Φ_k 称为离散状态转移矩阵； L_k 称为系统噪声驱动阵。

由于过程噪声也附加了系数，所以经过泰勒级数展开后，过程噪声方差不再是原来的 Q_k ，

而变成了 $L_k Q_k L_k^T$ 。同样，在 $x_k = \hat{x}_{k|k-1}$ 及 $v_k = 0$ 处将量测方程展开泰勒级数并取一阶近似，得：

$$z_k = h(x_{k|k-1}, 0) + \left. \frac{\partial h}{\partial x} \right|_{x_k = \hat{x}_{k|k-1}} (x_k - \hat{x}_{k|k-1}) + \left. \frac{\partial h}{\partial v} \right|_{x_k = \hat{x}_{k|k-1}} v_k \quad (3.20)$$

设 $\left. \frac{\partial h}{\partial x} \right|_{x = \hat{x}_{k|k-1}} = H_k$ ， $\left. \frac{\partial h}{\partial v} \right|_{x = \hat{x}_{k|k-1}} = M_k$ ，则量测方程变为：

$$\begin{aligned} z_k &= h(\hat{x}_{k|k-1}, 0) + H_k (x_k - \hat{x}_{k|k-1}) + M_k v_k \\ &= H_k x_k + [h(\hat{x}_{k|k-1}, 0) - H_k \hat{x}_{k|k-1}] + M_k v_k \end{aligned} \quad (3.21)$$

其中， H_k 称为量测矩阵； M_k 称为量测噪声驱动阵。

同样，由于量测噪声也附加了系数，量测噪声方差由原来的 R_k 变成了 $M_k R_k M_k^T$ 。至此，已经将非线性动态方程线性化，扩展卡尔曼滤波模型便可以通过将线性化后的式(3.19)和式(3.21)应用卡尔曼滤波基本方程得到。将标准卡尔曼滤波与扩展卡尔曼滤波算法过程进行对比，如表 3.1 所示。

表 3.1 标准卡尔曼滤波与扩展卡尔曼滤波算法过程对比

算法过程	标准卡尔曼滤波	扩展卡尔曼滤波
系统模型描述	$\begin{cases} x_k = A_{k-1} x_{k-1} + w_{k-1} \\ z_k = H_k x_k + v_k \\ w_k \sim (0, Q_k) \\ v_k \sim (0, R_k) \end{cases}$	$\begin{cases} x_k = f(x_{k-1}, w_{k-1}) \\ z_k = h(x_k, v_k) \\ w_k \sim (0, Q_k) \\ v_k \sim (0, R_k) \end{cases}$
初始条件设定	$\begin{cases} \hat{x}_0 = E(x_0) \\ P_0 = Var[x_0] \end{cases}$	$\begin{cases} \hat{x}_0 = E(x_0) \\ P_0 = Var[x_0] \end{cases}$
状态预测	$\hat{x}_{k k-1} = A_{k-1} \hat{x}_{k-1 k-1}$	$\hat{x}_{k k-1} = f(\hat{x}_{k-1 k-1}, 0)$
误差协方差预测	$P_{k k-1} = A_{k-1} P_{k-1 k-1} A_{k-1}^T + Q_{k-1}$	$P_{k k-1} = \Phi_{k-1} P_{k-1 k-1} \Phi_{k-1}^T + L_{k-1} Q_{k-1} L_{k-1}^T$
卡尔曼增益	$K_k = P_{k k-1} H_k^T [H_k P_{k k-1} H_k^T + R_k]^{-1}$	$K_k = P_{k k-1} H_k^T [H_k P_{k k-1} H_k^T + M_k R_k M_k^T]^{-1}$
状态更新	$\hat{x}_{k k} = \hat{x}_{k k-1} + K_k [z_k - H_k \hat{x}_{k k-1}]$	$\hat{x}_{k k} = \hat{x}_{k k-1} + K_k [z_k - h(\hat{x}_{k k-1}, 0)]$
误差协方差更新	$P_{k k} = (I - K_k H_k) P_{k k-1}$	$P_{k k} = (I - K_k H_k) P_{k k-1}$

3.3 无迹卡尔曼滤波算法

EKF 算法是应用最广泛的非线性系统状态估计算法，为了提高滤波精度，可以增加保留的阶数，将泰勒级数展开到二阶或者更高阶，但这样做的代价是计算量会大大增加。当系统的非线性较强时，EKF 算法依赖线性化传播来的均值和协方差误差也会更大，会导致滤波器性能下降甚至发散。

无迹卡尔曼滤波(UKF)是另一种针对非线性系统应用的滤波算法，它没有从线性化的角度对模型进行近似，而是从统计特性的角度出发，通过一些变换的采样点，最大程度接近于状态概率密度分布，从而对系统状态进行估计。UKF 没有忽略高阶项，所以相对于 EKF 算法，其估计精度较高^[66]。

3.3.1 无迹变换

UKF 的理论基础是无迹变换(Unscented Transform, UT)，UKF 算法原理如图 3.2 所示。无迹变换是对概率分布进行近似，即在需要估计的状态点附近采样，将这些接近于状态真值的采样点称为 Sigma 点，用这些 Sigma 点集的高斯密度来逼近真实状态的概率密度函数。




图 3.2 UKF 算法原理图

设非线性变换为 $y = f(x)$ ，状态向量 x 为 n 维随机变量，并已知其均值 \bar{x} 和方差 P 。通过以下无迹变换得到 $2n+1$ 个 Sigma 点集 X 和相应的权值 W 来计算 y 的统计特征，过程如下：

1. 计算 $2n+1$ 个 Sigma 点：

$$\begin{cases} X^{(0)} = \bar{x}, i = 0 \\ X^{(1)} = \bar{x} + (\sqrt{(n+\lambda)P})_i, i = 1, 2, \dots, n \\ X^{(i)} = \bar{x} - (\sqrt{(n+\lambda)P})_i, i = n+1, n+2, \dots, 2n \end{cases} \quad (3.22)$$

式中， $\lambda = \alpha^2(n+\kappa) - n$ ； α 为比例因子，典型取值范围为 $10^{-4} \leq \alpha \leq 1$ ； κ 为调节因子，用来保证 $(n+\lambda)P$ 的半正定性，当状态维数 $n \geq 3$ 时，一般选取 κ 为 0，当状态维数 $n < 3$ 时，取 $3-n$ 。

2. 计算这些采样点相应的权值 $W_m^{(i)}$ ：

$$\begin{cases} W_m^{(0)} = \frac{\lambda}{n + \lambda} \\ W_c^{(0)} = \frac{\lambda}{n + \lambda} + (1 - \alpha^2 + \beta) \\ W_m^{(i)} = W_c^{(i)} = \frac{\lambda}{2(n + \lambda)}, i = 1, 2, \dots, 2n \end{cases} \quad (3.23)$$

式中， m 代表均值； c 代表协方差； i 代表第 i 个采样时刻； β 为常数，主要用来避免高阶的误差损失，对于高斯分布， β 取 2，对于其他分布，需要通过试验得到。

3. 将这些 Sigma 点带入函数式 $y = f(x)$ 即可得到非线性变换后的 y_i 值：

$$y_i = f(X^{(i)}), i = 1, 2, 3, \dots, n \quad (3.24)$$

基于这些值，可以得到近似的期望值和协方差矩阵：

$$\begin{cases} \bar{y} = \sum_{i=0}^{2n} W_i y_i \\ P_y = \sum_{i=0}^{2n} W_i (y_i - \bar{y})(y_i - \bar{y})^T \end{cases} \quad (3.25)$$

以上便是无迹变换的过程，由第一个式子可知，采样的 Sigma 点为 $2n + 1$ 个，是以期望为中心，对称采样。因此，Sigma 点集的样本均值与样本方差均与状态向量的均值和方差相同。

3.3.2 无迹卡尔曼滤波

UKF 的结构与 EKF 相同，也包括时间更新和量测更新两个过程。无迹变换主要体现在算法的时间更新过程中。

对 3.2.2 节中的离散非线性系统方程采用 UKF 算法的过程如下^[67]：

1. 初始化滤波器：

$$\begin{cases} \hat{x}_0 = E(x_0) \\ P_0 = Var[x_0] \end{cases} \quad (3.26)$$

2. 时间更新

(1) 当 $k > 1$ 时，按照式(3.22)构造 $2n + 1$ 个 Sigma 点集 $X_{k-1|k-1}^{(i)}$ ，即：

$$\begin{cases} X_{k-1|k-1}^{(i)} = \hat{x}_{k-1|k-1} + \tilde{x}^{(i)}, i = 1, 2, \dots, 2n \\ \tilde{x}^{(i)} = (\sqrt{(n + \lambda)P_{k-1|k-1}})_i, i = 1, 2, \dots, n \\ \tilde{x}^{(n+i)} = -(\sqrt{(n + \lambda)P_{k-1|k-1}})_i, i = 1, 2, \dots, n \end{cases} \quad (3.27)$$

(2) 将 Sigma 点 $X_{k-1|k-1}^{(i)}$ 带入系统状态方程，得：

$$X_{k|k-1}^{(i)} = f(X_{k-1|k-1}^{(i)}, 0) \quad (3.28)$$

(3) 合并向量 $X_{k|k-1}^{(i)}$ 获得 k 时刻的向前一步状态估计以及协方差。UKF 的这一步算法不同于 EKF。EKF 算法只需要通过上一时刻的状态带入状态方程，而 UKF 则由 Sigma 点集的加权均值得到一步预测值：

$$\begin{cases} \hat{x}_{k|k-1} = \sum_{i=1}^{2n} W^{(i)} X_{k|k-1}^{(i)} \\ P_{k|k-1} = \sum_{i=1}^{2n} W^{(i)} [\hat{x}_{k|k-1} - X_{k|k-1}^{(i)}][\hat{x}_{k|k-1} - X_{k|k-1}^{(i)}]^T + Q_{k-1} \end{cases} \quad (3.29)$$

3. 量测更新

(1) 根据上一步得到的预测值，第二次使用 UT 变换，以构造新的 $2n+1$ 个 Sigma 点集 $X_{k|k-1}^{(i)}$ ：

$$\begin{cases} X_{k|k-1}^{(i)} = \hat{x}_{k|k-1} + \tilde{x}^{(i)}, i=1, 2, \dots, 2n \\ \tilde{x}^{(i)} = (\sqrt{(n+\lambda)P_{k|k-1}})_i, i=1, 2, \dots, n \\ \tilde{x}^{(n+i)} = -(\sqrt{(n+\lambda)P_{k|k-1}})_i, i=1, 2, \dots, n \end{cases} \quad (3.30)$$

这里也可以重复利用刚才产生的那些点，而不产生新的 Sigma 点，这样虽然会损失一定的精度，但可以减小计算负担。

(2) 将产生的新的 Sigma 点代入量测方程 $Z_k = h(x_k, 0)$ 中，得到量测量的预测值：

$$Z_{k|k-1}^{(i)} = h(X_{k|k-1}^{(i)}, 0) \quad (3.31)$$

(3) 合并向量 $Z_{k|k-1}^{(i)}$ 获得 k 时刻的量测预测以及量测预测的协方差：

$$\begin{cases} \hat{z}_{k|k-1} = \sum_{i=1}^{2n} W^{(i)} Z_{k|k-1}^{(i)} \\ P_z = \sum_{i=1}^{2n} W^{(i)} [\hat{z}_{k|k-1} - Z_{k|k-1}^{(i)}][\hat{z}_{k|k-1} - Z_{k|k-1}^{(i)}]^T + R_k \end{cases} \quad (3.32)$$

(4) 再估计 $\hat{x}_{k|k-1}$ 与 $\hat{z}_{k|k-1}$ 之间的协方差：

$$P_{xz} = \sum_{i=1}^{2n} W^{(i)} [\hat{x}_{k|k-1} - X_{k|k-1}^{(i)}][\hat{z}_{k|k-1} - Z_{k|k-1}^{(i)}]^T \quad (3.33)$$

(5) 计算卡尔曼滤波增益：

$$K_k = P_{xz} P_z^{-1} \quad (3.34)$$

(6) 更新系统的状态和协方差：

$$\begin{cases} \hat{x}_{k|k} = \hat{x}_{k|k-1} + K_k (z(k) - \hat{z}_{k|k-1}) \\ P_{k|k} = P_{k|k-1} - K_k P_z K_k^T \end{cases} \quad (3.35)$$

可以看出，UKF 是对状态的概率分布进行近似，而 EKF 算法中是对非线性函数进行近似。对概率分布进行近似比对非线性函数进行近似要更容易实现，且近似精度也更高。

3.4 自适应扩展卡尔曼滤波算法

飞行数据在传感器测量、记录、传输的过程中，由于外部环境干扰或仪器不稳定等原因，存在数据突变、数据缺失等各种异常情况，各飞行数据之间的相关性及其方差等统计特性都是不确定和变化的。若按照传统的扩展卡尔曼滤波算法，将噪声协方差设定为常量，误差很容易随着滤波递推越来越大，最后导致滤波结果精度低，甚至发散。

由 EKF 算法的滤波原理可以知道最优估计值是在预测值和测量值之间进行权衡处理，权重则由卡尔曼滤波增益决定。值得注意的是，测量噪声包含在新息协方差矩阵中，卡尔曼滤波增益又与新息协方差有着直接的关系，同时状态噪声也反映在卡尔曼滤波增益中。因此，理论上通过实时估计新息协方差矩阵可以反映系统噪声统计特性的变化，提高 EKF 的滤波性能^[68]。

3.4.1 自适应扩展卡尔曼滤波算法的极大似然估计准则

将模型描述为：

$$\begin{cases} x_k = f[x_{k-1}, u_{k-1}, w_{k-1}] \\ z_k = h[x_k, v_k] \end{cases} \quad (3.36)$$

线性化和离散化后为：

$$\begin{cases} x_k = \Phi_{k-1}x_{k-1} + G_{k-1}u_{k-1} + L_{k-1}w_{k-1} \\ z_k = H_kx_k + v_k \end{cases} \quad (3.37)$$

式中， Φ_{k-1} 为离散状态转移矩阵， $\Phi_{k-1} = \frac{\partial f}{\partial x_{k-1}}$ ； G_{k-1} 为控制输入矩阵， $G_{k-1} = \frac{\partial f}{\partial u_{k-1}}$ ； u_{k-1} 为控

制输入向量； L_{k-1} 为系统噪声驱动阵， $L_{k-1} = \frac{\partial f}{\partial w_{k-1}}$ ； w_{k-1} 为系统噪声，其方差为 Q_k ； H_k 为量

测矩阵， $H_k = \frac{\partial h}{\partial x_k}$ ； v_k 为量测噪声，其方差为 R_k 。

新息 r_k 这部分信息主要是由量测量 z_k 带来的，滤波器无法进行提前预测^[69]，其计算公式为：

$$r_k = z_k - H_k \hat{x}_{k/k-1} \quad (3.38)$$

新息 r_k 的理论协方差 C_{rk} 为：

$$C_{rk} = E[r_k r_k^T] = H_k P_{k/k-1} H_k^T + R_k \quad (3.39)$$

极大似然准则(Maximum Likelihood Criterion, MLC)是从 z_k 出现概率最大的角度出发，对状态进行估计^[70]，其最大的特点是考虑新息 r_k 和新息协方差 C_{rk} 的变化，主要针对 C_{rk} 进行实时估计和调整，保证 k 时刻 z_k 在调整参数 l_k 下的条件概率密度函数最大，即：

$$p(z|l) = \frac{1}{\sqrt{(2\pi)^m |C_{rk}|}} e^{-\frac{1}{2} r_k^T C_{rk}^{-1} r_k} \quad (3.40)$$

对式(3.40)求对数:

$$\ln p(z|l) = -\frac{1}{2} [m \times \ln(2\pi) + \ln(|C_{rk}|) + r_k^T C_{rk}^{-1} r_k] \quad (3.41)$$

假设自适应滤波器的估计窗口长度为 N , 对上式进行累加计算, 求取和式的极大值转化为:

$$D = \sum_{j=j_0}^k [\ln |C_{rj}| + r_j^T C_{rj}^{-1} r_j] \rightarrow \min \quad (3.42)$$

式中, k 为当前时刻; j 为估计窗口 N 内第 j 个值, j_0 为初始值, $j_0 = k - N + 1$ 。

目前的问题转化为: 求取在 k 时刻通过对调整参数 l_k 的实时选择, 使式(3.42)最小。令式(3.42)对 l_k 求导为零, 有:

$$\sum_{j=j_0}^k [tr(C_{rj}^{-1} \frac{\partial C_{rj}}{\partial l_k}) - r_j^T C_{rj}^{-1} \frac{\partial C_{rj}}{\partial l_k} C_{rj}^{-1} r_j] = 0 \quad (3.43)$$

进一步可简化为:

$$\sum_{j=j_0}^k tr[C_{rj}^{-1} (C_{rj} - r_j r_j^T) C_{rj}^{-1}] = 0 \quad (3.44)$$

求解上式可得:

$$\hat{C}_{rk} = \frac{1}{N} \sum_{j=j_0}^k r_j r_j^T \quad (3.45)$$

即 \hat{C}_{rk} 为 C_{rk} 在窗口长度为 N 的滑动采样的最优估计值。

3.4.2 基于极大似然准则的自适应扩展卡尔曼滤波算法

依据 MLC 得到了新息协方差的最优估计值 \hat{C}_{rk} , 但从式(3.45)可以看出来 k 时刻的最优估计新息协方差为当前所有时刻的新息协方差的算术平均值, 且每个时刻具有相同的权值, 并没有突出新近数据的作用。另外, 如果系统变化较为急速, 也不能很好的反映出估计的动态性能。

因此, 当 $k > N$ 时, 采取一种基于限定记忆指数衰减加权的新息协方差估计算法^[71], 该算法能够对滑动窗口内新近的数据赋予更大的权值, 通过依次对窗口内的数据进行指数衰减加权, 得到更准确的估计值。指数衰减权重 ϑ 为:

$$\vartheta_i = \xi_k \Upsilon^{k-i}, 0 < \Upsilon < 1, k > N \quad (3.46)$$

式中, $\xi_k = \frac{1-\Upsilon}{1-\Upsilon^N}$; $\sum_{i=k-N+1}^k \vartheta_i = 1$; Υ 为衰减因子。

将衰减权重加入到滑动窗口中的数据，得到新息协方差估计表达式：

$$\hat{C}_{rk} = \vartheta_k r_k r_k^T + \vartheta_{k-1} r_{k-1} r_{k-1}^T + \cdots + \vartheta_{k-N+1} r_{k-N+1} r_{k-N+1}^T \quad (3.47)$$

将式(3.46)带入式(3.47)得到 \hat{C}_{rk} 公式如下：

$$\hat{C}_{rk} = \Upsilon \hat{C}_{rk-1} + [(1 - \Upsilon) / (1 - \Upsilon^N)] (r_k r_k^T - \Upsilon^N r_{k-N} r_{k-N}^T) \quad (3.48)$$

当 $k \leq N$ 时，采用式(3.45)计算新息协方差。

基于极大似然准则的自适应扩展卡尔曼滤波(MLC-AEKF)算法流程，如图 3.3 所示。

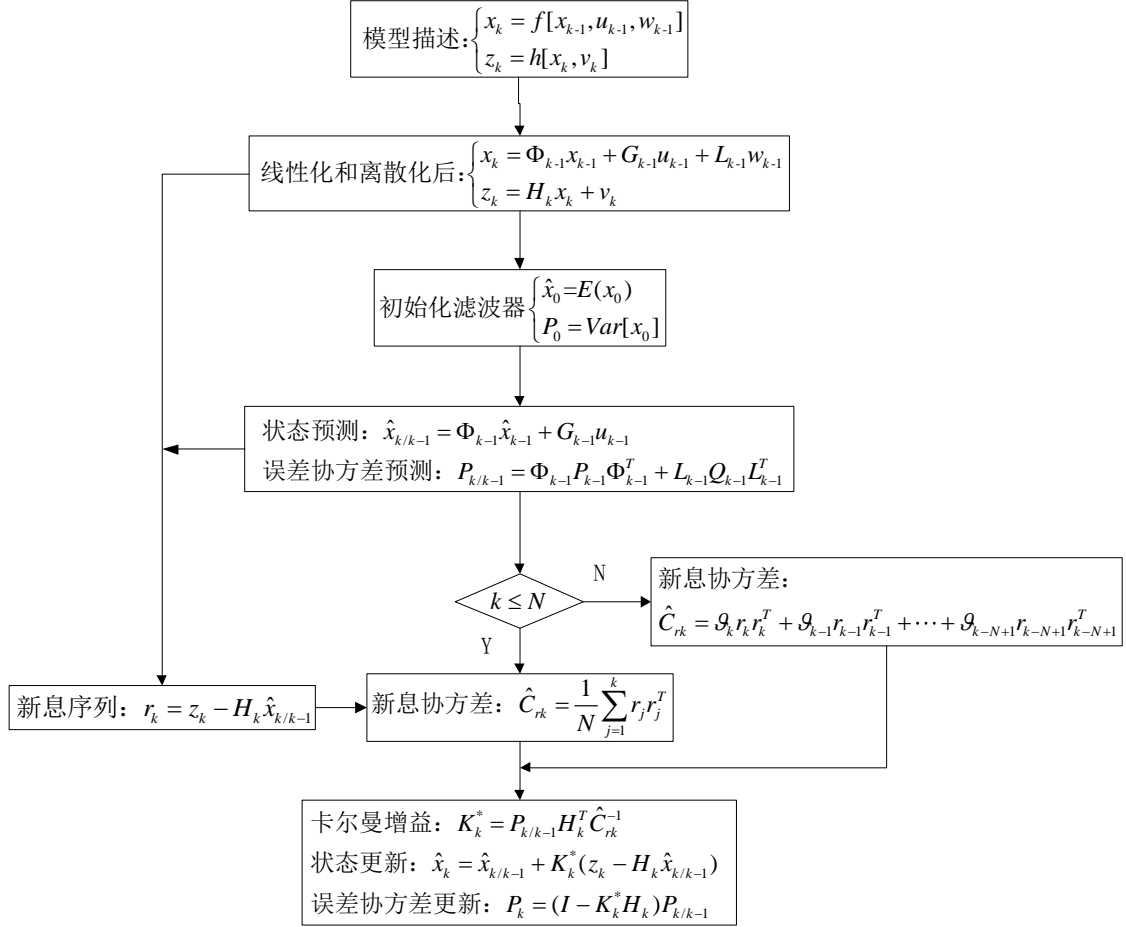


图 3.3 MLC-AEKF 算法流程图

基于极大似然准则的新息自适应卡尔曼滤波算法能够突出新近数据的作用，对新息协方差进行实时估计来代替其理论估计值，并将其传递至卡尔曼滤波增益中，从而更加及时准确地跟踪系统模型的动态变化^[71]。该算法不仅能够加快滤波的收敛速度，而且考虑了实际估计误差的变化，更好地适应噪声统计特性的变化，提高滤波精度^[72,73]。

3.5 飞行器运动状态跟踪

基于以上 EKF、UKF、MLC-AEKF 三种算法，对飞行器状态进行跟踪，估计飞行器位置、速度、加速度三个状态参数，并对比三种算法跟踪物体运行状态的效果。由于位置、速度、加

速度这三个飞行状态参数不涉及转动等状态，因此这里只考虑飞行器的质心的三维坐标即飞行器在 x-y-z 三维平面内运动，并将其简化为一个质点 m 。

3.5.1 建立运动状态方程和量测方程

1. 建立状态方程

飞行器质点 m 在 k 时刻位置、速度、加速度的状态向量可表示为：

$$x(k) = [r_x(k), r_y(k), r_z(k), v_x(k), v_y(k), v_z(k), a_x(k), a_y(k), a_z(k)]^T \quad (3.49)$$

质点 m 可以在 x-y-z 三维平面内做任何运动，该质点的运动状态方程为：

$$x(k) = f_k(x(k-1), w(k-1)) \quad (3.50)$$

将上述方程线性化和离散化后，即能表述为如下方式：

$$x(k) = \Phi \cdot x(k-1) + G \cdot u(k-1) + w(k-1) \quad (3.51)$$

式中，

$$\Phi = \begin{bmatrix} I_3 & \Delta t I_3 & \frac{1}{\lambda^2}(e^{-\lambda \Delta t} + \lambda \Delta t - 1)I_3 \\ 0_3 & I_3 & \frac{1}{\lambda^2}(1 - e^{-\lambda \Delta t})I_3 \\ 0_3 & 0_3 & e^{-\lambda \Delta t} I_3 \end{bmatrix}, \quad G = \begin{bmatrix} -(\Delta t^2/2)I_3 \\ -\Delta t I_3 \\ 0_3 \end{bmatrix}$$

Δt 为采样时间间隔。动态噪声 $w(k-1)$ 为三个方向上运动具有加性高斯白噪声，表示为：

$$\begin{cases} w(k-1) = [0, 0, 0, 0, 0, 0, w_x(k-1), w_y(k-1), w_z(k-1)]^T \\ E[w(k-1)] = 0_{9 \times 1}, E[w(k-1)w^T(k-1)] = Q = \begin{bmatrix} 0_6 & 0_{6 \times 3} \\ 0_{3 \times 6} & 0.1 \times I_3 \end{bmatrix} \end{cases} \quad (3.52)$$

2. 建立量测方程

观测向量为飞行器上的飞行数据记录系统记录的俯仰角和航迹角，其观测方程为

$$z(k) = h[x(k)] + v(k) \quad (3.53)$$

式中， $v(k)$ 为高斯测量白噪声，且

$$\begin{cases} h[x(k)] = [\arctan \frac{r_y(k)}{\sqrt{r_x^2(k) + r_z^2(k)}}, \arctan \frac{-r_x(k)}{r_z(k)}] \\ E[v(k)] = r_1 = 0_{2 \times 1}, E[v(k)v^T(k)] = R \end{cases} \quad (3.54)$$

对于 R ，定义为：

$$\begin{cases} R(k) = D^{-1}(k) x D^{-T}(k), x = 0.1 \times I_2 \\ D(k) = \begin{bmatrix} \sqrt{r_x^2(k) + r_y^2(k) + r_z^2(k)} & 0 \\ 0 & \sqrt{r_x^2(k) + r_y^2(k) + r_z^2(k)} \end{bmatrix} \end{cases} \quad (3.55)$$

3.5.2 滑动窗口长度的选取

通过 MLC-AEKF 算法的滤波方程，可以看出滤波结果与估计窗口长度 N 的取值有较大关系。 N 的选择应当依据载体的运动学和动力学特性。 N 越小，滤波器对系统动力学模型的变化越敏感，但 N 太小，则统计数目过少，不能保证 MLC-AEKF 算法滤波结果的无偏性。 N 越大，滤波估计的无偏性越好，但 N 过大，又会削弱系统模型对于变化的估计效果，导致无法跟踪上运动轨迹的变化。因此，需要在能达到最优估计的情况下选取最小的滑动窗口长度。

滤波器初始参数设置如下：

$$x(1)=[3500,1500,1000,-1100,-150,-50,0,0,0]^T; \quad Q=[0_{6 \times 6}, 0_{6 \times 3}; 0_{3 \times 6}, 0.1 \times I_3];$$

$$xkf(1)=[3500,1500,1000,-1100,-150,-50,0,0,0]^T; \quad P_0 = eye(9);$$

其中， $x(1)$ 为状态向量初始值；将 $x(1)$ 带入 $h[x(k)]$ 得到量测量的初始值；系统噪声方差为 Q ；采样周期为 0.02s；滤波时间为 10s；滤波器初始状态为 $xkf(1)$ ； R 的初始值根据式(3.55)进行计算。

分别选取系统达到稳定状态下和动态数据突变情况下的数据作为样本，选取位置估计误差作为分析对象，对不同滑动窗口长度情况下算法的估计性能进行研究。当滤波器达到稳态情况下，图 3.4 给出了滑动窗口长度分别为 10、30、50 和 100 下的某 5s 位置误差变化曲线。可以看出，当 $N=10$ 、30 时，误差曲线的波动幅度较大； $N=50$ 时，波动幅度较小；而当 $N=100$ 时，波动幅度又变大。




图 3.4 稳态下不同滑动窗口的位置误差对比图

考虑到飞行数据会出现数据突变的情况，在 3s-3.5s 给量测值模拟一个 10% 的数据突变。滑动窗口长度分别为 10、20、30 和 50 下的位置误差曲线如图 3.5 所示。从图 3.5 可以看出， $N=20$

时的突变处的估计误差是较小的, 误差为 15m 左右; 当 $N=10$ 、30、50 时, 突变处的估计误差均超过 30m。由该图也可以得到, 当发生数据突变等情况时, 通过选取合适的滑动窗口, MLC-AEKF 算法可以有效识别并排除外部干扰, 依然能够较为准确地得到估计结果。




图 3.5 数据突变下不同滑动窗口的位置误差对比图

图 3.6 为稳态和数据突变情况下不同滑动窗口长度下位置估计误差的结果。这里取位置估计误差的均方根进行分析。若以前面论述的最优估计下的最小滑动窗口长度为选取原则, 那么从图 3.6 可以得到: 稳态情况下, N 取 50 是最优的; 动态数据突变情况下, N 取 20 是最优的。




图 3.6 稳态和数据突变下位置估计性能随滑动窗口长度的变化曲线

3.5.3 衰减因子的选取

衰减因子 γ 的选取关系到最新数据对估计结果的影响程度。为了研究 γ 对状态估计的影响,

在飞行器运行稳定后, 同样在 3s-3.5s 给量测值添加一个 10% 的数据突变, 分析突变后 3s-5s 时间内位置误差的均方根值。由 3.5.2 节可知, 动态数据突变情况下, 滑动窗口长度最优值为 20。滑动窗口内 20 个数据点的衰减权重变化曲线如图 3.7 所示, 图 3.8 为不同衰减因子下的位置误差的均方根估计结果。可以看出, 随着衰减因子的增大, 位置误差的均方根逐渐减小, 当 $\Upsilon=0.8$ 时, 位置误差均方值最小, 说明此时的估计误差最小; 而当 $\Upsilon>0.8$ 时, 估计误差均方根反而增大, 表明 $\Upsilon=0.8$ 是最优值。




图 3.7 滑动窗口内衰减权重的变化曲线




图 3.8 位置误差性能随衰减因子的变化曲线

3.5.4 MLC-AEKF 算法品质分析

选取完 MLC-AEKF 算法中的滑动窗口长度 N 和衰减因子 Υ , 以上述飞行器运动为实例, 对 MLC-AEKF 算法过程进行品质分析。由于 UKF 算法的滤波理论与 EKF、MLC-AEKF 算法不同, 因此只对 EKF、MLC-AEKF 这两种算法的算法性能进行分析对比。两种算法的初始参数已在 3.5.2 节列出。另外, MLC-AEKF 算法中, 滑动窗口长度取 $N=50$, 衰减因子 $\Upsilon=0.8$ 。

本文对 EKF 和 MLC-AEKF 算法的新息协方差矩阵 C_{rk} 、卡尔曼滤波增益 K_k 、系统噪声方差 Q 、测量噪声方差 R 以及估计误差协方差 P_k 五个参数在整个滤波过程中变化情况进行了对比, 对比结果如图 3.9 所示。注意, 这里取了方阵的迹和非方阵的谱范数进行对比, 迹是矩阵所有特征值的和, 谱范数是矩阵与其转置矩阵乘积的最大特征值的平方根, 都可以用来描述一个矩阵。

从图 3.9 可以看出, 当 EKF 算法滤波器逐渐达到稳定状态时, 其 C_{rk} 、 K_k 、 P_k 都会收敛于一个稳态值, 并没有随着系统运动状态的变化而变化; EKF 算法的系统噪声方差 Q 在滤波过程也一直为设定的初值, 测量噪声方差 R 在滤波器达到稳定后, 也收敛于一个稳定的值, 并没有随着外部环境的变化而进行适当的调整。而 MLC-AEKF 算法的 C_{rk} 、 K_k 、 Q 、 R 和 P_k 都是在不断地根据外部环境的影响和系统模型的变化而进行实时调整的。MLC-AEKF 算法通过实时估

计新息协方差 C_{rk} 的值, 然后将其传递至卡尔曼滤波增益 K_k 中, 从而更好地权衡预测值和测量值之间的权重大小, 更加精确地估计出状态值。 C_{rk} 和 K_k 的值又是与噪声方差 Q 和 R 息息相关的。因此, Q 、 R 的调整情况一定程度上也反映了算法的滤波性能。

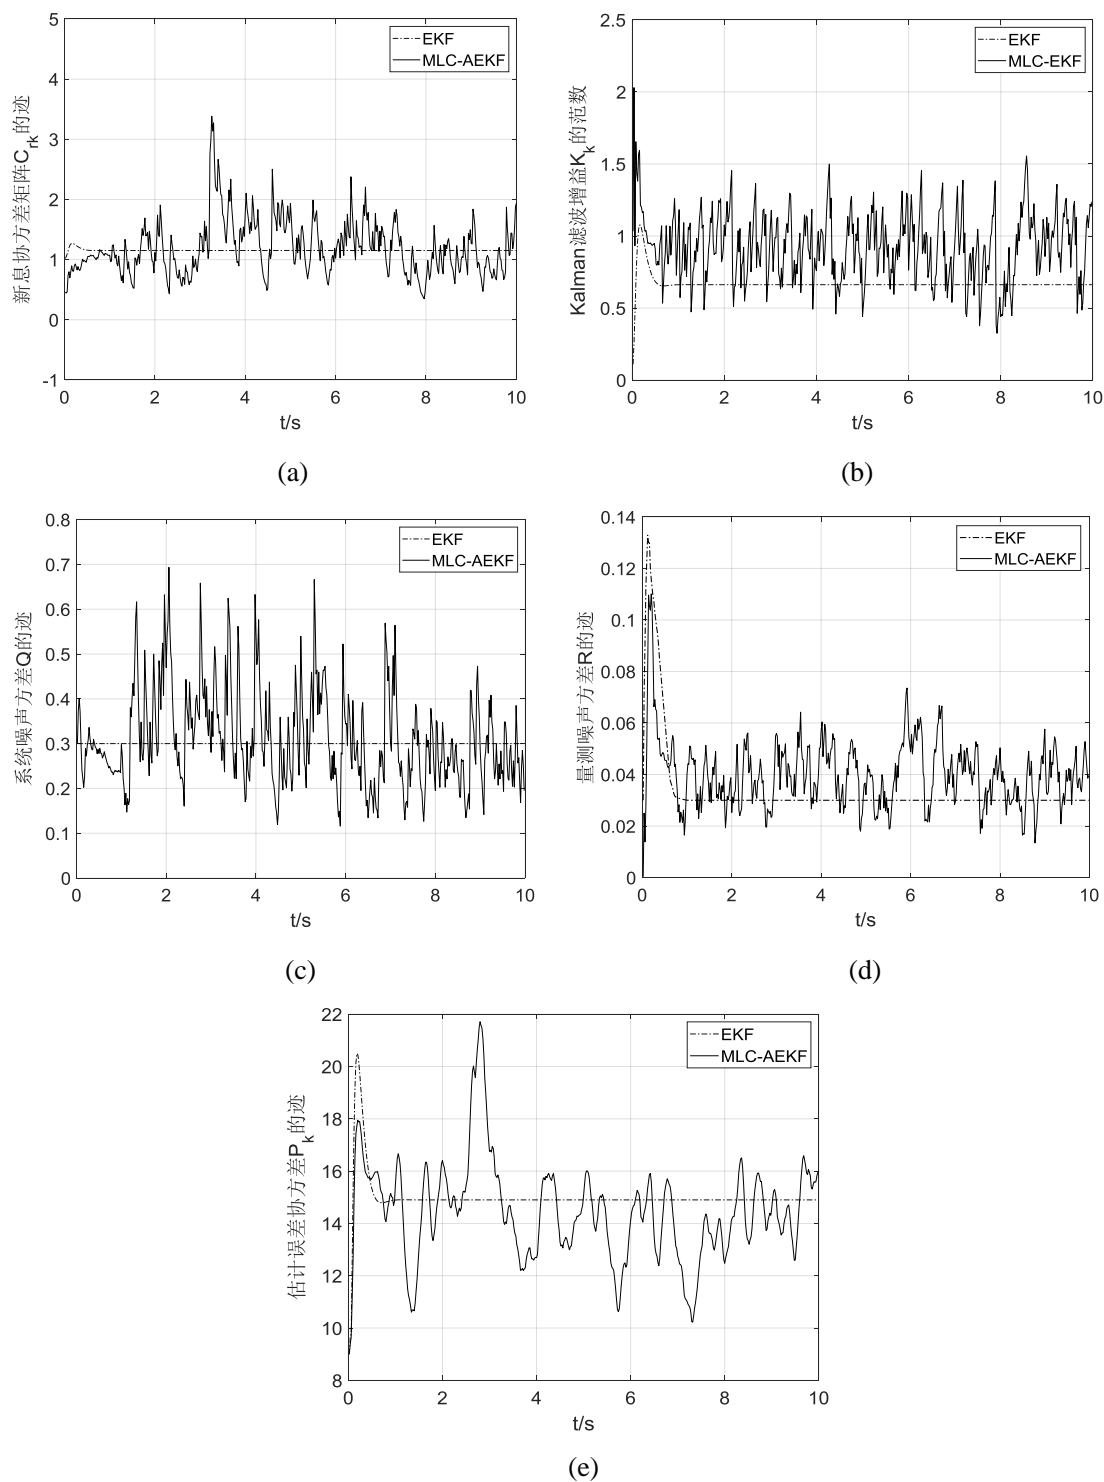


图 3.9 EKF 和 MLC-AEKF 算法的 C_{rk} 、 K_k 、 Q 、 R 、 P_k 对比图

3.5.5 状态跟踪结果分析

对上述飞行器飞行实例，分别应用 EKF、UKF、MLC-AEKF 三种算法，对飞机状态进行跟踪，跟踪效果如图 3.10 所示。可以看出，三种算法中，MLC-AEKF 算法跟踪效果最好，UKF 效果优于 EKF。图 3.11 为 EKF、UKF、MLC-AEKF 三种算法滤波后的状态值与目标真实状态之间的位置估计误差、速度估计误差和加速度估计误差对比图。误差结果图表明，三种算法中，无论位置还是速度，随着滤波的递推，其偏差值都在逐渐减小，最后收敛至 0 左右。其中，MLC-AEKF 算法收敛最快，算法刚开始就收敛至稳定最小值；相比于 EKF 算法，UKF 算法的位置偏差和速度偏差收敛地较快，误差相对也更小；而 EKF 算法在第 7s 附近，误差才开始收敛至稳态值。三种算法的加速度误差一直稳定在特定的值 0.5 附近，并没有较大差别。

所以，从结果分析图中可以看出，MLC-AEKF 算法对于飞行器的状态估计，包括位置、速度、加速度的状态估计效果是最好的，UKF 的估计精度次之，EKF 算法的估算精度在三种算法中效果较差。

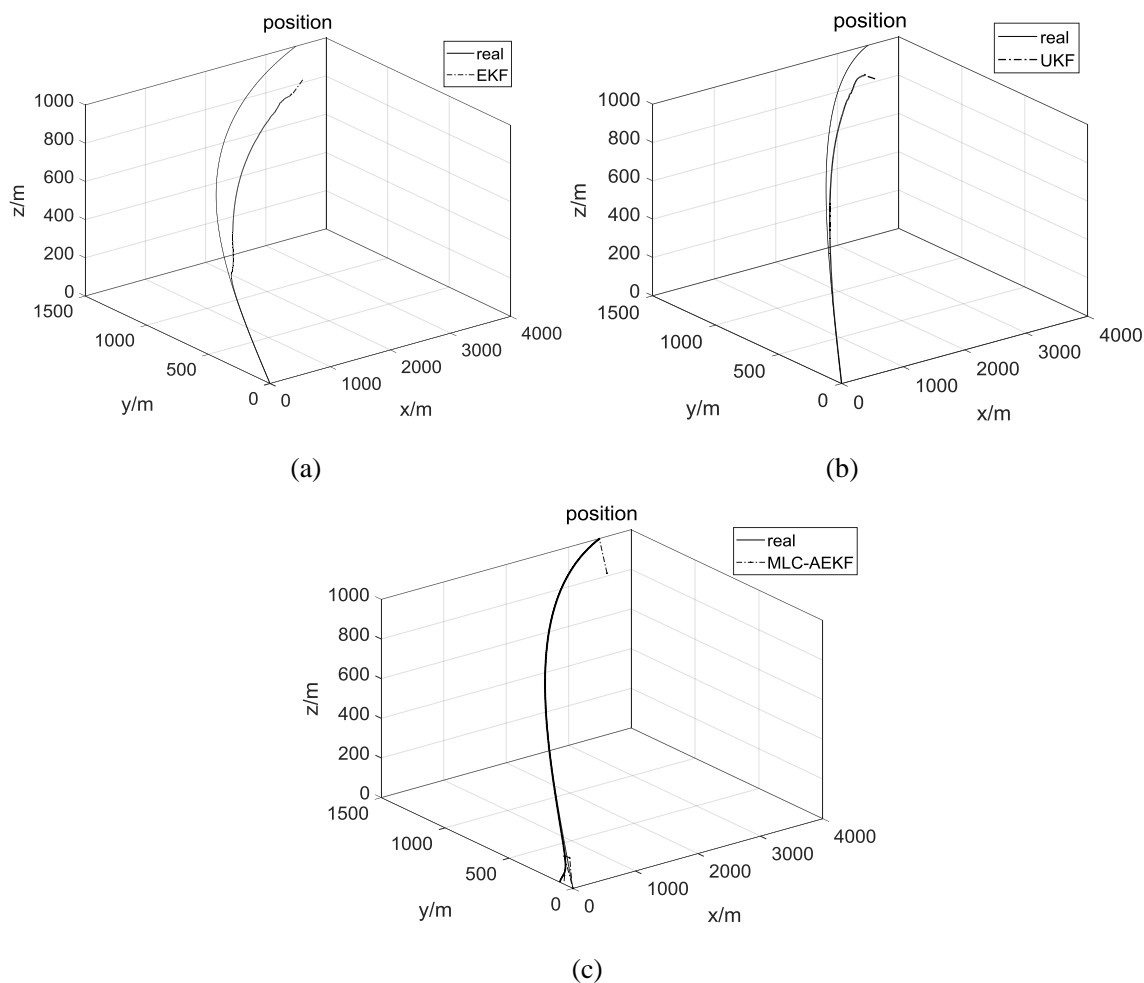


图 3.10 EKF/UKF/MLC-AEKF 三种算法目标轨迹跟踪图

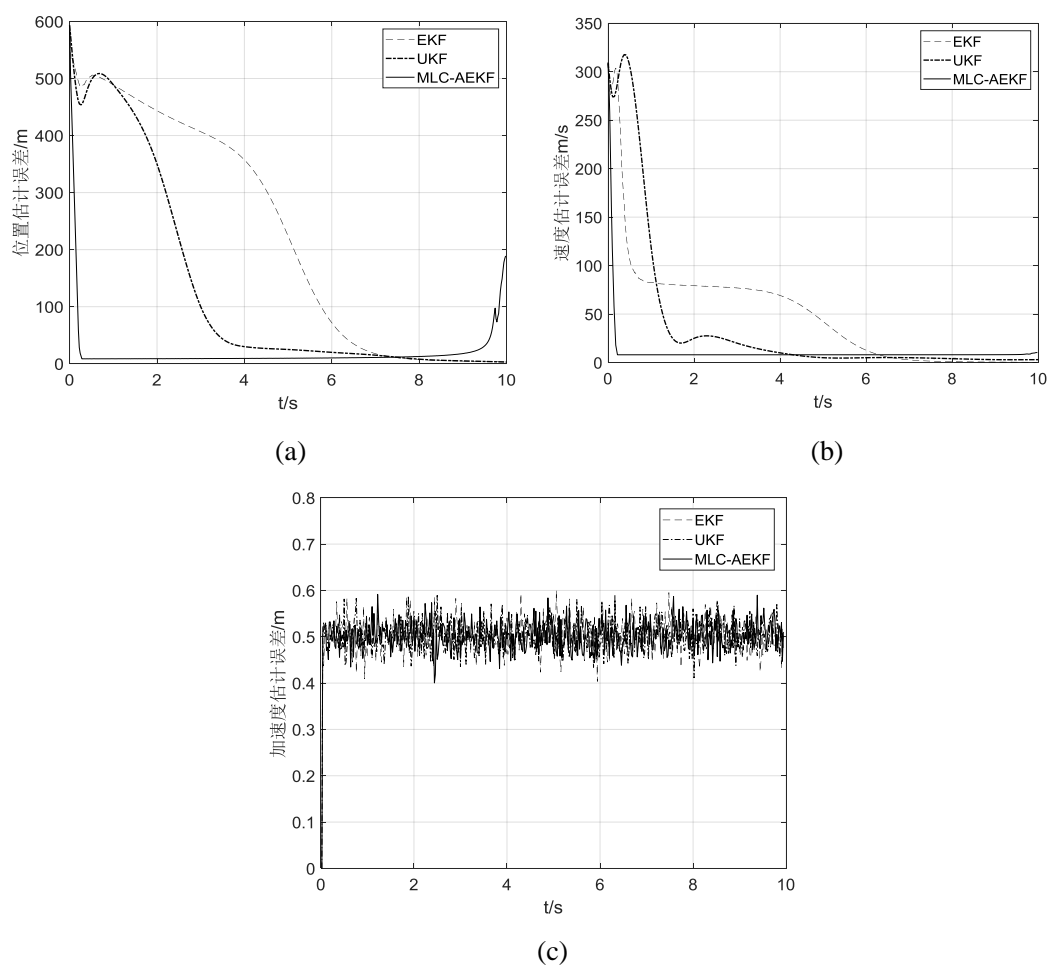


图 3.11 位置、速度、加速度估计误差图

3.6 本章小结

本章主要开展了以下研究：

- (1) 对标准卡尔曼滤波、扩展卡尔曼滤波算法和无迹卡尔曼滤波算法的理论进行了研究和分析；针对系统模型动态变化以及 QAR 测量数据统计特性均未知的情况，研究了一种基于极大似然准则的自适应扩展卡尔曼滤波算法；
- (2) 以对飞行器的位置、速度以及加速度进行状态估计为例，研究了 MLC-AEKF 算法中滑动窗口长度和衰减因子对估计性能的影响以及该算法的性能品质分析，并对比 EKF、UKF、MLC-AEKF 三种算法的状态估计效果。经研究认为，MLC-AEKF 算法的估计效果要好于另外两种算法。

第四章 基于 MLC-AEKF 算法的飞机气流角估计

迎角、侧滑角是飞行动力学与飞行控制系统的两个非常重要的参数，不仅与飞机的飞行品质和飞行安全息息相关，也是湍流估计必不可少的参数。基于第三章的算法研究基础，考虑到飞行数据的数据突变、各参数采样率不同等特点，本章将非等间隔理论与 MLC-AEKF 算法进行融合，基于飞机动力学模型和飞行数据，建立估计飞机迎角、侧滑角的算法模型，并与 EKF、UKF 算法估计结果进行对比，验证融合非等间隔理论的 MLC-AEKF 算法的有效性。

4.1 非线性飞行动力学模型

4.1.1 飞行动力学方程

飞机的非线性动力学模型通常用六自由度模型表示，六自由度模型建立了飞机的飞行状态参数与飞机控制参数之间的非线性函数关系。飞行状态参数主要包括飞行速度、姿态、姿态角速率、迎角和侧滑角等，飞机控制参数包括油门大小和舵面偏转量等。飞机是个非常复杂的动力学系统，若用六自由度模型来表示飞机的非线性飞行动力学模型，需要做如下一些简化假设：

- (1) 飞机为理想刚体，且质量为常数，各轴转动惯量保持不变。
- (2) 忽略地球自转和公转影响，将地面坐标系认为是惯性坐标系。
- (3) 重力加速度不随飞行高度变化而变化。
- (4) 飞机的对称平面为机体坐标系的 O-x-z 平面， $I_{xy} = I_{yz} = 0$ 。

经动力学推导，六自由度模型共包括 12 个微分方程^[74]，可总结为以下四大类：

- (1) 力方程

$$\begin{cases} \dot{u} = vr - wq - g \sin \theta + T_x / m \\ \dot{v} = -ur + wp + g \cos \theta \sin \phi + T_y / m \\ \dot{w} = uq - vp + g \cos \theta \cos \phi + T_z / m \end{cases} \quad (4.1)$$

式中， u 、 v 、 w 为空速 V 在机体坐标系上的三轴分量； T_x 、 T_y 、 T_z 为发动机推力 T 在机体轴系的三轴分量； p 、 q 、 r 为三个姿态角速率； θ 为俯仰角； ϕ 为滚转角。

- (2) 力矩方程

$$\begin{cases} \dot{p} = (c_1 r + c_2 p)q + c_3 \bar{L} + c_4 \bar{N} \\ \dot{q} = c_5 pr - c_6 (p^2 - r^2) + c_7 \bar{M} \\ \dot{r} = (c_8 p - c_2 r)q + c_4 \bar{L} + c_9 \bar{N} \end{cases} \quad (4.2)$$

式中， $c_1 = \frac{(I_y - I_z)I_z - I_{xz}^2}{I_x I_z - I_{xz}^2}$ ； $c_2 = \frac{(I_x - I_y + I_z)I_{xz}}{I_x I_z - I_{xz}^2}$ ； $c_3 = \frac{I_z}{I_x I_z - I_{xz}^2}$ ； $c_4 = \frac{I_{xz}}{I_x I_z - I_{xz}^2}$ ； $c_5 = \frac{I_z - I_x}{I_y}$ ； $c_6 = \frac{I_{xz}}{I_y}$ ；

$$c_7 = \frac{1}{I_y}; \quad c_8 = \frac{I_x(I_x - I_y) + I_{xz}^2}{I_x I_z - I_{xz}^2}; \quad c_9 = \frac{I_x}{I_x I_z - I_{xz}^2}; \quad \bar{L}、\bar{M}、\bar{N} \text{ 为三轴力矩。}$$

(3) 运动学方程

$$\begin{cases} \dot{\phi} = p + (r \cos \phi + q \sin \phi) \tan \theta \\ \dot{\theta} = q \cos \phi - r \sin \phi \\ \dot{\psi} = (r \cos \phi + q \sin \phi) / \cos \theta \end{cases} \quad (4.3)$$

式中, ψ 为偏航角。

(4) 导航方程组

$$\begin{cases} \dot{x}_g = u \cos \theta \cos \psi + v(\sin \phi \sin \theta \cos \psi - \cos \phi \sin \psi) + w(\sin \phi \sin \psi + \cos \phi \sin \theta \cos \psi) \\ \dot{y}_g = u \cos \theta \sin \psi + v(\sin \phi \sin \theta \sin \psi + \cos \phi \cos \psi) + w(-\sin \phi \cos \psi + \cos \phi \sin \theta \sin \psi) \\ \dot{z}_g = u \sin \theta - v \sin \phi \cos \theta - w \cos \phi \cos \theta \end{cases} \quad (4.4)$$

式中, \dot{x}_g 、 \dot{y}_g 、 \dot{z}_g 为飞机在地面坐标系下的三轴速度。

另外, 通过本文所选机型, 通过提取主导气动导数, 可以获得飞机在机体系下的三轴力 L_f 、 D 、 Y 和三轴力矩 \bar{L} 、 \bar{M} 、 \bar{N} 的表达式:

$$\begin{cases} L_f = \bar{q}S(C_{L_0} + C_{L_\alpha} \alpha + C_{L_{\delta_e}} \delta_e) \\ D = \bar{q}S(C_{D_0} + C_{D_i}) \\ Y = \bar{q}S(C_{Y_\beta} \beta + C_{Y_{\delta_r}} \delta_r + C_{Y_{p_a}} p + C_{Y_r} r) \\ \bar{L} = \bar{q}Sb(C_{l_\beta} \beta + C_{l_{\delta_a}} \delta_a + C_{l_{\delta_r}} \delta_r + C_{l_{p_a}} p + C_{l_r} r) \\ \bar{M} = \bar{q}S\bar{c}(C_{m_{\alpha_0}} + C_{m_\alpha} \alpha + C_{m_{\delta_e}} \delta_e + C_{m_q} q) \\ \bar{N} = \bar{q}Sb(C_{n_\beta} \beta + C_{n_{\delta_a}} \delta_a + C_{n_{\delta_r}} \delta_r + C_{n_p} p + C_{n_r} r) \end{cases} \quad (4.5)$$

式中, \bar{q} 为动压; S 为机翼参考面积; \bar{c} 为机翼平均几何弦长; b 为翼展。上式中的各导数项可通过气动数据插值查询获得, 一般与空速 V 、迎角 α 、侧滑角 β 等参数有关。

4.1.2 飞行动力学模型参数值

本文选取某型飞机为研究对象, 根据该机型简化的建模数据包, 得到其结构参数如表 4.1 所示。

表 4.1 某型飞机结构参数

参数 (单位)	数值	参数 (单位)	数值
机翼面积 $S(m^2)$	124.58	机翼展长 $b(m)$	34.31
平均几何弦长 $\bar{c}(m)$	3.96	飞机重量 $m(kg)$	70306.81
绕 x 轴的转动惯量 $I_x(kg \cdot m^2)$	0.920×10^6	绕 y 轴的转动惯量 $I_y(kg \cdot m^2)$	1.81×10^6
绕 z 轴的转动惯量 $I_z(kg \cdot m^2)$	2.61×10^6	惯性积 $I_{xz}(kg \cdot m^2)$	0.108×10^6

本文参考某一航段的飞行数据,对飞机协调转弯时的状态进行跟踪。对非线性动力学方程组进行展开,获得飞机进行转弯状态前的定直平飞的初始配平值,作为各滤波状态量的初始值。飞机定直平飞时,飞机各角速率和滚转角均为0,以此为配平条件,寻优计算其他各参数值^[75],得到各配平值如表4.2所示。图4.1为飞机进行协调转弯时,各状态参数的实际仿真图。

表 4.2 各状态量配平初始值

参数(单位)	数值	参数(单位)	数值
迎角 $\alpha(^{\circ})$	2.25525	俯仰角速率 $q(r/s)$	0
侧滑角 $\beta(^{\circ})$	-2.349×10^{-7}	滚转角速率 $p(r/s)$	0
俯仰角 $\theta(^{\circ})$	2.25525	偏航角速率 $r(r/s)$	0
滚转角 $\phi(^{\circ})$	0	副翼偏转量 $\delta_a(^{\circ})$	-1.2×10^{-7}
偏航角 $\psi(^{\circ})$	0	升降舵偏转量 $\delta_e(^{\circ})$	-0.759
飞行速度 $V(m/s)$	153	方向舵偏转量 $\delta_r(^{\circ})$	6.2×10^{-7}
发动机推力 $T(KN)$	116.0	飞行高度 $H(ft)$	10000

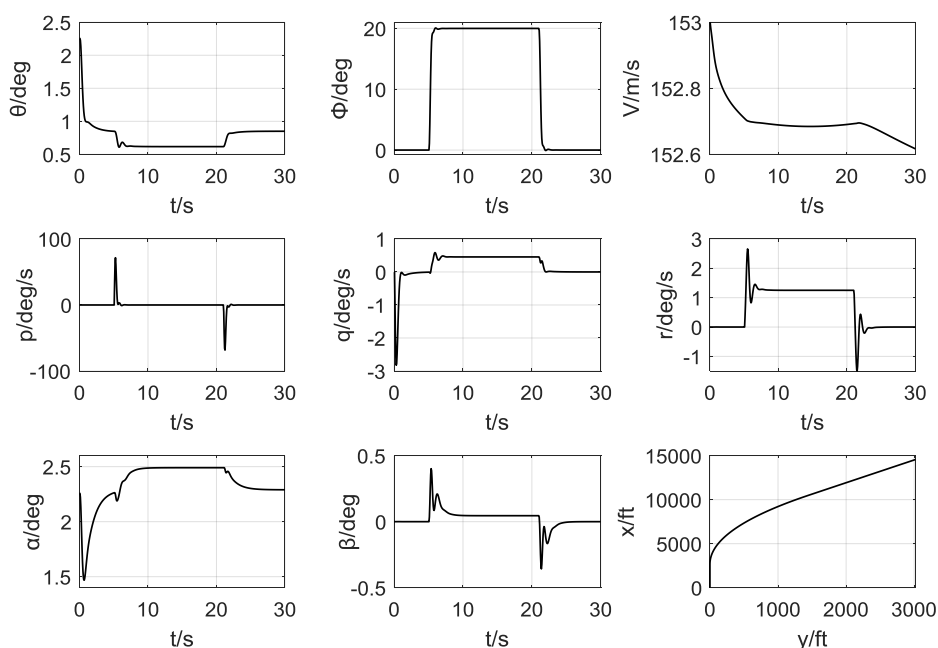


图 4.1 协调转弯状态仿真图

4.2 气流角估计模型

迎角与飞机的升阻特性关系密切,同时也是飞机安全与包线保护系统的输入参数;而侧滑角在飞机转弯和横向运动中偏差较大则会对飞行安全造成较大的隐患。迎角、侧滑角这两个参数主要通过飞机上的风标传感器、压差传感器等进行测量,这些传感器极易受到局部湍流、结冰等外部环境因素的影响,特别是大气扰动情况下,或者在大迎角、机动飞行条件下,大气数

据系统都是难以准确测量出迎角、侧滑角的。

本章对飞机协调转弯时的迎角、侧滑角进行估计，以表征飞机的飞行状态。如果算法模型能够准确估计出飞机在机动飞行状态下的气流角的值，那么在稳态情况下也是可以准确估计的。飞机的运动规律通常采用微分方程的形式来表示，反映了飞行器的运动状态变化。基于飞行数据里关于飞机的飞行状态参数和控制量参数，以及非线性飞行动力学方程，可以建立估计迎角、侧滑角的数学模型。

4.2.1 建立系统状态方程

基于飞机的飞行动力学模型，考虑与迎角和侧滑角有关的飞行状态参数，选取俯仰角 θ 、滚转角 ϕ 、滚转角速率 p 、俯仰角速率 q 、偏航角速率 r 、迎角 α 、侧滑角 β 和空速 V 作为状态量，即 $X = [\theta, \phi, p, q, r, \alpha, \beta, V]^T$ ，副翼偏转量 δ_a 、升降舵偏转量 δ_e 、方向舵偏转量 δ_r 以及发动机推力 T 作为控制向量，即 $U = [\delta_a, \delta_e, \delta_r, T]^T$ ，以机体坐标系为基准，建立状态方程如式(4.6)所示。

$$\begin{bmatrix} \dot{\theta} \\ \dot{\phi} \\ \dot{p} \\ \dot{q} \\ \dot{r} \\ \dot{\alpha} \\ \dot{\beta} \\ \dot{V} \end{bmatrix} = \begin{bmatrix} q \cos \phi - r \sin \phi \\ p + (r \cos \phi + q \sin \phi) \tan \theta \\ (c_1 r + c_2 p)q + c_3 \bar{L} + c_4 \bar{N} \\ c_5 pr - c_6 (p^2 - r^2) + c_7 \bar{M} \\ (c_8 p - c_2 r)q + c_4 \bar{L} + c_9 \bar{N} \\ \frac{1}{mV \cos \beta} [-T_x \sin \alpha + T_z \cos \alpha - L_f + mV(-p \cos \alpha \sin \beta + q \cos \beta - r \sin \alpha \sin \beta) \\ + mg(\sin \alpha \sin \theta + \cos \alpha \cos \phi \cos \theta)] \\ \frac{1}{mV} [-T_x \cos \alpha \sin \beta + T_y \cos \beta - T_z \sin \alpha \sin \beta + Y - mV(-p \sin \alpha + r \cos \alpha \\ + mg(\cos \alpha \sin \beta \sin \theta + \cos \beta \sin \phi \cos \theta - \sin \alpha \sin \beta \cos \phi \cos \theta)] \\ \frac{1}{m} [T_x \cos \alpha \cos \beta + T_y \sin \beta + T_z \sin \alpha \cos \beta - D \\ + mg(-\cos \alpha \cos \beta \sin \theta + \sin \beta \sin \phi \cos \theta + \sin \alpha \cos \beta \cos \phi \cos \theta)] \end{bmatrix} + L(t)w(t) \quad (4.6)$$

其中， $L(t)$ 为系统噪声驱动矩阵：

$$L(t) = \begin{bmatrix} 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ c_3 & 0 & c_4 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & c_7 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ c_4 & 0 & c_9 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & \frac{-1}{mV \cos \beta} & \frac{-\sin \alpha}{mV \cos \beta} & 0 & \frac{\cos \alpha}{mV \cos \beta} \\ 0 & 0 & 0 & 0 & \frac{1}{mV} & 0 & \frac{-\cos \alpha \sin \beta}{mV} & \frac{\cos \beta}{mV} & \frac{-\sin \alpha \sin \beta}{mV} \\ 0 & 0 & 0 & -\frac{1}{m} & 0 & 0 & \frac{\cos \alpha \cos \beta}{m} & \frac{\sin \beta}{m} & \frac{\sin \alpha \cos \beta}{m} \end{bmatrix}$$

式中, 副翼偏转量 δ_a 、升降舵偏转量 δ_e 、方向舵偏转量 δ_r 等控制量主要体现在滚转力矩 \bar{L} 、俯仰力矩 \bar{M} 、偏航力矩 \bar{N} 这三个力矩公式中; D 、 Y 、 L_f 分别表示阻力、侧力和升力; c_1, c_2, \dots, c_9 为常数系数, 由飞行器的转动惯量和惯性积构成, 具体计算方法已在式(4.2)中列出; m 为飞行器的质量; g 是重力加速度, $w(t)$ 为系统建模噪声, 由飞机合外力矩、空气动力以及发动机推力引起, 而它们之间的噪声方差以及相关性都是不确定的, MLC-AEKF 算法理论上是通过新息的变化反映出它们之间的动态关系的。以上滚转、俯仰和偏航三轴力矩、发动机推力以及阻力、侧力和升力都可以根据 4.1.1 节飞机的非线性动力学模型获得。

4.2.2 建立系统量测方程

量测方程反映了量测系统的测量原理以及状态量与量测量之间的关系。在飞行数据记录中, 来自飞机惯性基准系统的数据记录较为准确, 因此选用惯性基准系统提供的俯仰角 θ 、滚转角 ϕ 、三轴加速度 a_x 、 a_y 、 a_z 作为量测量, 即 $Z = [\theta, \phi, a_x, a_y, a_z]^T$, 建立量测方程如下:

$$\begin{bmatrix} \theta \\ \phi \\ a_x \\ a_y \\ a_z \end{bmatrix} = \begin{bmatrix} \theta \\ \phi \\ \frac{1}{m}(T_x + L_f \sin \alpha - Y \cos \alpha \sin \beta - D \cos \alpha \cos \beta) \\ \frac{1}{m}(T_y + Y \cos \beta - D \sin \beta) \\ \frac{1}{m}(T_z - L_f \cos \alpha - Y \sin \alpha \sin \beta - D \sin \alpha \cos \beta) \end{bmatrix} + v(t) \quad (4.7)$$

式中, 量测噪声 $v(t)$ 由惯性器件陀螺仪和加速度计的量测噪声引起, 而两者噪声方差、相关性也都是不确定的。因此, 选用对新息协方差进行实时估计和调整的 MLC-AEKF 算法, 理论上可以提高参数的估计精度。

4.3 融合非等间隔理论的 MLC-AEKF 算法

飞行数据的各类数据参数由不同的传感器传输得到, 由于传感器的类型不同, 其采样频率也就不相同, 再加上系统通信延迟导致的各个滤波器的量测周期不同, 提供的各个参数的估计不能同步, 因此会出现信息的非等间隔问题。

在算法过程中, 需要 QAR 数据中记录的俯仰角 θ 、滚转角 ϕ 、三轴加速度 a_x 、 a_y 、 a_z 五个量测量的值。根据 2.2.1 节的表 2.1 列出的本文所用机型参数的数据记录特点可以得知, 俯仰角、滚转角的采样频率是每秒 4 次, 而三个加速度分量采样频率为每秒 16 次, 所以在滤波过程中必然会出现信息的非等间隔问题。

非等间隔卡尔曼滤波算法是解决采样率不同等非等间隔问题常用的方法。当低采样率的量测量没有信息输出时, 在每一个滤波时刻, 只进行卡尔曼滤波器的时间更新; 当有低采样率的

量测输出的时刻时，则同时进行卡尔曼滤波算法的时间更新和量测更新，从而解决量测量不同采样率的非等间隔问题^[76,77]。

将 MLC-AEKF 算法融合非等间隔滤波理论，其算法过程可以总结如下：

(1) 当低采样率的量测值没有输出，只有高采样率参数输出时，只进行时间更新：

$$\begin{cases} \hat{X}_k = \Phi_{k-1} \hat{X}_{k-1} + G_{k-1} U_{k-1} \\ P_k = \Phi_{k-1} P_{k-1} \Phi_{k-1}^T + L_{k-1} Q_{k-1} L_{k-1}^T \end{cases} \quad (4.8)$$

(2) 当低采样率的量测信息输出时，同时进行时间更新和量测更新：

$$\begin{cases} \hat{X}_{k/k-1} = \Phi_{k-1} \hat{X}_{k-1} + G_{k-1} U_{k-1} \\ P_{k/k-1} = \Phi_{k-1} P_{k-1} \Phi_{k-1}^T + L_{k-1} Q_{k-1} L_{k-1}^T \\ \begin{cases} \hat{C}_{rk} = \frac{1}{N} \sum_{j=j_0}^k r_j r_j^T, k \leq N \\ \hat{C}_{rk} = \Upsilon \hat{C}_{rk-1} + (1 - \Upsilon / (1 - \Upsilon^N)) (r_k r_k^T - \Upsilon^N r_{k-N} r_{k-N}^T), k > N \end{cases} \\ K_k = P_{k/k-1} H_k^T (\hat{C}_{rk})^{-1} \\ \hat{X}_k = \hat{X}_{k/k-1} + K_k (Z_k - H_k \hat{X}_{k/k-1}) \\ P_k = (I - K_k H_k) P_{k/k-1} \end{cases} \quad (4.9)$$

4.4 估计结果分析

将融合非等间隔理论的 MLC-AEKF 算法对飞机迎角、侧滑角进行估计，并将估计结果与 UKF、EKF 算法结果进行对比。在滤波过程中，UKF、EKF 算法同样需要融合非等间隔理论，其融合方法与 MLC-AEKF 算法相同。

本文算法的滤波参数中，算法条件设置中各状态初始值已在表 4.2 中列出。由于加速度的采样频率为每秒 16 次，所以设置采样周期为 0.0625s，滤波时间为 30s。考虑到 QAR 数据中由于记录错误等原因，记录的数值会出现 10 倍偏差。为了验证三种算法对于突变数据的鲁棒性，在 24s-25s 的滤波时段内，模拟俯仰角的记录值出现 10 倍的偏差，即令 $\theta=10\theta$ 。MLC-AEKF 算法参数中，衰减因子取 $b=0.8$ ，滑动窗口长度取 $N=20$ 。滤波器相关初始参数设置如下：

$$Q = \text{diag}[10^{-4}, 10^{-3}, 10^{-3}, 10^{-4}, 10^{-4}, 10^{-4}, 10^{-4}, 10^{-2}]; \quad R = \text{diag}[10^{-2}, 10^{-2}, 10^{-2}, 10^{-2}, 10^{-1}];$$

$$P_0 = \text{eye}(8);$$

将 MLC-AEKF 算法的迎角、侧滑角的估计结果与真实轨迹、EKF 估计结果、UKF 估计结果进行对比，对比结果如图 4.2 所示，三种算法的估计误差如图 4.3 所示。从图 4.3(a)可以看出，在未发生数据突变的前 24s 内，MLC-AEKF 算法的迎角估计误差 $\Delta\alpha$ 基本保持在 $-0.30^\circ \sim 1.00^\circ$ 之间，而 UKF、EKF 算法的 $\Delta\alpha$ 最大可以达到 1.48° 和 2.00° ，均大于 MLC-AEKF 算法的迎角估计误差。侧滑角估计误差如图 4.3(b)所示，同样在前 24s 内，MLC-AEKF 算法侧滑角误差 $\Delta\beta$ 基

本维持在 $-0.12^\circ \sim 0.45^\circ$ 之间，而 UKF、EKF 算法的 $\Delta\beta$ 最大可分别达到 0.91° 和 1.22° 。综上所述可知，MLC-AEKF 算法的估计误差要小于 UKF 算法，而 UKF 算法的估计误差又小于 EKF 算法。另外，在侧滑角动态变化比较大的时间段内，MLC-AEKF 算法虽然也会有小范围波动，但估计效果仍然是明显优于 EKF、UKF 算法的。从结果图 4.2 也可以分析出，MLC-AEKF 算法基本上在第 10 秒开始逐渐收敛，第 15 秒滤波器已基本稳定，EKF、UKF 算法的收敛性和稳定性也都不如 MLC-AEKF 算法。

图 4.4 是 EKF 和 MLC-AEKF 算法的新息协方差矩阵 C_{rk} 、估计误差协方差 P_k 在整个仿真过程中的对比图。由于滤波理论基础的不同，UKF 算法中并没有 C_{rk} ，因此这里只对 EKF 和 MLC-AEKF 算法的 C_{rk} 和 P_k 进行了对比。可以看出，前 24s 内，MLC-AEKF 算法的 C_{rk} 、 P_k 在滤波过程中，不断根据系统模型和噪声统计特性的变化进行调整，从而得到了更加精确的估计值；而 EKF 的 C_{rk} 、 P_k 在滤波器达到稳定状态后，会收敛于一个常值，并没有考虑飞机运动状态和噪声统计特性的动态变化，因此 MLC-AEKF 算法效果要优于 EKF 的估计效果。

从图 4.4 也可以看出，当在 24s-25s 俯仰角发生突变后，EKF 算法的 C_{rk} 、 P_k 值没有做出调整，仍为一个稳态值，EKF 算法不能够识别出突变干扰。此时，EKF 算法的迎角、侧滑角估计误差最大可分别达到 3.90° 和 2.40° 。UKF 算法在发生突变干扰后的滤波效果相比之下优于 EKF 算法，迎角、侧滑角估计误差最大可分别达到 2.39° 和 1.24° 。而 MLC-AEKF 算法的 C_{rk} 、 P_k 针对该突变扰动做出了相应的调整，从而能够较为准确地估计出气流角的值。该算法突变处的误差均小于 EKF、UKF 算法，迎角误差最大只达到 0.65° ，侧滑角估计误差最大达到 0.45° 。由此可见，MLC-AEKF 算法的抗外部干扰突变的鲁棒性能也优于 EKF 和 UKF 算法。




图 4.2 迎角/侧滑角 MLC-AEKF 结果与真实轨迹、EKF、UKF 结果对比图





图 4.3 迎角/侧滑角估计误差

图 4.4 迎角/侧滑角 EKF 和 MLC-AEKF 的 C_{rk} 、 P_k 对比图

4.5 本章小结

本章研究了一种飞机气流角的估计方法。考虑到飞行数据可能受到外部干扰发生数据突变，各数据采样频率不同等情况，将非等间隔理论与 MLC-AEKF 算法相融合，基于飞行动力学模型，建立系统状态方程和量测方程，估计飞机迎角、侧滑角的值。以飞机机动转弯飞行为例，并施加外部干扰进行算法效果验证。经研究表明，该算法的估计精度和抗外部干扰的鲁棒性能均明显优于 EKF 和 UKF 算法。

第五章 颠簸飞行中扰动风估计初步研究

本章对颠簸飞行中的湍流扰动风估计进行初步研究。通过 von Karman 大气湍流模型以及第二章方法得到的真空速，可以建立用于扰动风估计的状态方程；基于地速、真空速与风速之间的矢量关系，以及第四章算法准确估计的气流角，建立用于扰动风估计的量测方程；通过扩展卡尔曼滤波器，可以获得飞机颠簸飞行中扰动风的 x 、 y 、 z 三维空间估计。

5.1 扰动风估计概述

在大气扰动飞行中，受湍流的影响，机载系统难以准确地采集风速、风向数据，从而对湍流诱发的颠簸机理分析造成不利的影响。湍流造成飞机颠簸的实质是垂直风影响飞机沉浮和俯仰运动，而 QAR 数据中只记录了水平风，无垂直风记录。因此，对颠簸飞行下的扰动风进行三维空间建模与估计对于颠簸预测和飞行安全具有重要意义。

目前主流的湍流模型有 Kolmogorov 湍流模型^[78]、Dryden 湍流模型和 von Karman 湍流模型。Kolmogorov 湍流模型是从气象学角度对湍流进行建模，且主要适用于平流层的湍流。Dryden 模型和 von Karman 湍流模型都是从飞行力学的角度对湍流进行建模，但两者的理论体系正好相反。Dryden 模型是先建立湍流函数，再推导出频谱表达式。而 von Karman 模型则是以海量的测量数据为基础来建立高频大气湍流的功率谱模型，再推导出相关函数。由此可见，von Karman 模型更能反映湍流真实情况，更适用于本文研究^[79,80]。

湍流扰动风可以通过以上几种模型获得，考虑到基于地速、真空速与风速之间的矢量关系，又可以通过 QAR 数据的状态冗余计算得到。因此，将 von Karman 湍流模型作为扰动风估计的状态方程，利用速度三角形关系，将 QAR 记录的地速与通过 QAR 数据计算得到的真空速的差值作为卡尔曼滤波器的量测输入，由扩展卡尔曼滤波器输出扰动风的 x 、 y 、 z 三维估计值，估计原理框架如图 5.1 所示。

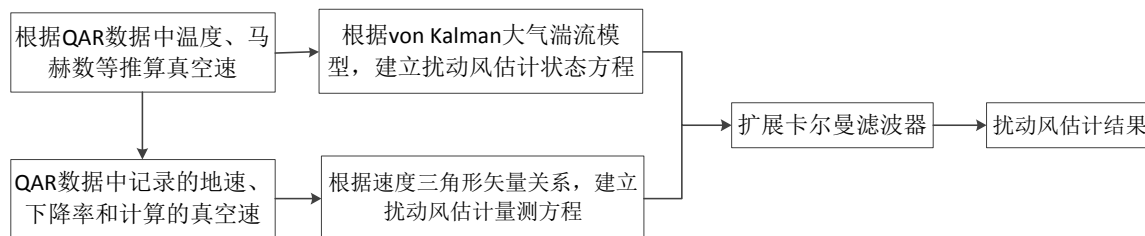


图 5.1 扰动风估计原理框架图

5.2 von Karman 湍流估计模型

von Karman 模型是一种能够高逼真度反映高频湍流特性的大气湍流模型，但其本身表达式

不适于进行飞行仿真，需要将其进行有理化，得到逼真度较高的线性化模型。通过有理化后的 von Karman 线性化模型，可以生成三维大气湍流扰动风^[81]。

根据相应的理论知识和海量数据，von Karman 模型得到大气湍流的能量频谱函数为：

$$E(\Omega) = \sigma^2 \frac{55L}{9\pi} \frac{(aL\Omega)^4}{[1 + (aL\Omega)^2]^{17/6}} \quad (5.1)$$

式中， σ 为湍流强度； L 为湍流尺度； Ω 为空间频率； a 为常数， $a=1.339$ 。当空间频率 $\Omega \rightarrow 0$ 时， $E(\Omega) \rightarrow \Omega^4$ ； $\Omega \rightarrow \infty$ 时， $E(\Omega) \rightarrow \Omega^{-5/3}$ ，是符合湍流理论中的极限条件的。

为便于仿真，根据空间频谱与时间频谱的关系式： $\Phi(\omega) = \Phi(\Omega) / V_T = \Phi(\omega / V_T) / V_T$ ，将 von Karman 模型中大气湍流的三维空间频谱函数转化为时间频谱，如下所示：

$$\left\{ \begin{array}{l} \Phi_1(\omega) = \sigma_1^2 \frac{L_1}{\pi V_T} \frac{1}{[1 + (aL_1 \frac{\omega}{V_T})^2]^{5/6}} \\ \Phi_2(\omega) = \sigma_2^2 \frac{L_2}{\pi V_T} \frac{1 + (8/3)(2aL_2 \frac{\omega}{V_T})^2}{[1 + (2aL_2 \frac{\omega}{V_T})^2]^{11/6}} \\ \Phi_3(\omega) = \sigma_3^2 \frac{L_3}{\pi V_T} \frac{1 + (8/3)(2aL_3 \frac{\omega}{V_T})^2}{[1 + (2aL_3 \frac{\omega}{V_T})^2]^{11/6}} \end{array} \right. \quad (5.2)$$

式中， Φ_1 、 Φ_2 、 Φ_3 分别代表纵向、横向和法向湍流时间频谱； ω 为时间频率； V_T 为真空速。

σ 和 L 随飞行高度变化而变化，可以根据 QAR 记录的飞行高度获得。

便于仿真的实时湍流风场可通过单位强度白噪声激励成型滤波器来产生^[80]，而成型滤波器的传递函数 $G(s)$ 可通过上式的时间频谱函数共轭分解获得：

$$\left\{ \begin{array}{l} G_1(s) = \sigma_1 \sqrt{\frac{L_1}{\pi V_T}} \frac{1}{[1 + \frac{aL_1}{V_T} s]^{5/6}} \\ G_2(s) = \sigma_2 \sqrt{\frac{L_2}{\pi V_T}} \frac{1 + \sqrt{8/3} \frac{2aL_2 s}{V_T}}{(1 + \frac{2aL_2 s}{V_T})^{11/6}} \\ G_3(s) = \sigma_3 \sqrt{\frac{L_3}{\pi V_T}} \frac{1 + \sqrt{8/3} \frac{2aL_3 s}{V_T}}{(1 + \frac{2aL_3 s}{V_T})^{11/6}} \end{array} \right. \quad (5.3)$$

对上式进行有理化逼近,将其简化为便于仿真实现的一阶形式,相应的滤波器及其参数为:

$$\begin{cases} G_1(s) = \frac{K_1}{T_1 s + 1} \\ K_1 = \sigma_1 \sqrt{\frac{L_1}{\pi V_T}}, T_1 = \left(\frac{a L_1}{V_T}\right)^{5/6} \end{cases} \quad (5.4)$$

$$\begin{cases} G_2(s) = \frac{K_2}{T_2 s + 1} \\ K_2 = \sigma_2 \sqrt{\frac{L_2}{\pi V_T}}, T_2 = \frac{(2a L_2 / V_T)^{11/6}}{\sqrt{8/3} \times 2a L_2 / V_T} \end{cases} \quad (5.5)$$

$$\begin{cases} G_3(s) = \frac{K_3}{T_3 s + 1} \\ K_3 = \sigma_3 \sqrt{\frac{L_3}{\pi V_T}}, T_3 = \frac{(2a L_3 / V_T)^{11/6}}{\sqrt{8/3} \times 2a L_3 / V_T} \end{cases} \quad (5.6)$$

对以上成型滤波器进行 z 变换,令 $s = \frac{1-z^{-1}}{T}$, 并采用后向一阶差分法, 获得差分方程形式的离散化模型, 从而将 3 个成型滤波器转换成如下的差分形式^[82]:

$$x(k) = \frac{T_i}{T_i + T_s} x(k-1) + \frac{K_i T_s}{T_i + T_s} y(k), (i=1,2,3) \quad (5.7)$$

式中, T_s 为采样周期。从而可以将湍流扰动风的状态方程表示为:

$$\begin{bmatrix} \dot{W}_x \\ \dot{W}_y \\ \dot{W}_z \end{bmatrix} = \begin{bmatrix} -T_x^{-1} & & \\ & -T_y^{-1} & \\ & & -T_z^{-1} \end{bmatrix} \begin{bmatrix} W_x \\ W_y \\ W_z \end{bmatrix} + \begin{bmatrix} -T_x^{-1} K_1 & & \\ & -T_y^{-1} K_2 & \\ & & -T_z^{-1} K_3 \end{bmatrix} \begin{bmatrix} w_x \\ w_y \\ w_z \end{bmatrix} \quad (5.8)$$

式中, W_x 、 W_y 、 W_z 为扰动风三轴分量; w_x 、 w_y 、 w_z 为三轴风速测量零均值白噪声, 其噪声方差为 Q 。

式(5.8)便构成了三维空间扰动风估计的状态方程。

5.3 矢量三角形建立估计量测方程

5.3.1 计算真空速和地速的三轴分量

QAR 数据中, 由惯导系统测量得到的地速、载荷等数据是准确的, 而在颠簸飞行状态下, 由大气数据系统测量得到的空速等数据可能是不准确的, 且 QAR 数据中只记录了计算空速, 没有真空速的记录。因此, 根据飞行 QAR 数据的冗余记录, 通过马赫数 M 、总温 T 等飞行记录参数来计算真空速 V_T , 具体方法已在 2.2.2 节列出。得到 V_T 后, 根据第四章准确估计的迎角 α 、侧滑角 β 来计算真空速的三轴分量。在机体坐标系下, 对真空速沿三轴分解:

$$\begin{cases} V_{Tx} = V_T \cos \alpha \cos \beta \\ V_{Ty} = V_T \sin \beta \\ V_{Tz} = V_T \sin \alpha \cos \beta \end{cases} \quad (5.9)$$

QAR 数据中记录的地速是飞机相对地面的水平运动的速度。在地面坐标系下，对地速进行水平方向的分解：

$$\begin{cases} V_{Gx} = V_G \cos \chi \\ V_{Gy} = V_G \sin \chi \end{cases} \quad (5.10)$$

式中， χ 为飞机航迹角。地速垂直方向上的速度 V_{Gz} 为 QAR 数据中记录的下降率参数。

5.3.2 建立量测方程

地速、真空速和风速存在如下矢量三角形关系^[83]：

$$W = V_G - V_T \quad (5.11)$$

式中， W 为风速； V_G 为地速； V_T 为真空速。

根据 QAR 数据中记录的地速量测值 $[V_{Gx}, V_{Gy}, V_{Gz}]^T$ 和通过 QAR 数据状态冗余计算得到的真空速量测值 $[V_{Tx}, V_{Ty}, V_{Tz}]^T$ ，两者之差即为风速。因此，观测向量 $z = [z_x, z_y, z_z]^T$ 可写成：

$$\begin{bmatrix} z_x \\ z_y \\ z_z \end{bmatrix} = \begin{bmatrix} V_{Gx} - V_{Tx} \\ V_{Gy} - V_{Ty} \\ V_{Gz} - V_{Tz} \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} x(k) + \begin{bmatrix} v_x \\ v_y \\ v_z \end{bmatrix} \quad (5.12)$$

式中， v_x 、 v_y 、 v_z 为三轴风速测量噪声，其噪声方差为 R 。

根据 PIREPs，分别选取某一航班高空巡航阶段平稳飞行和颠簸飞行两种情况下 50s 的 QAR 数据，对飞机的地速 V_G 和真空速 V_T 的三轴分量以及两者之间的三轴差值进行计算。平稳飞行下的计算结果如图 5.2 所示。第一行分别为真空速在 x 、 y 、 z 三轴的速度分量，第二行分别为地速在 x 、 y 、 z 三轴的速度分量，最后一行为真空速和地速的三轴速度差值，即为没有加量测噪声的测量风速值。

从理论上讲，马赫数、机体总温以及由惯导系统得到的地速是准确记录的，一定程度上，可以说明由速度三角形得到的测量风速是比较可靠的。由于 QAR 数据中只记录了水平风，没有垂直风。因此，分别将两种飞行情况下 QAR 记录的水平风在 x 、 y 轴上进行分解，与根据速度三角形关系得到的 V_G 和 V_T 的 x 、 y 轴差值进行对比，如图 5.3 和图 5.4 所示。从图 5.3 可以看出，平稳飞行时，QAR 数据记录的水平风速与根据速度三角形得到的 x 、 y 轴风速是相差不大的，而在图 5.4 中，颠簸飞行情况下，两者结果是有较大差距的。因此可以认为，在平稳大气条件下，大气数据系统测量得到的风速是相对准确的，而当飞机经过湍流区域发生颠簸时，测量误差较大。

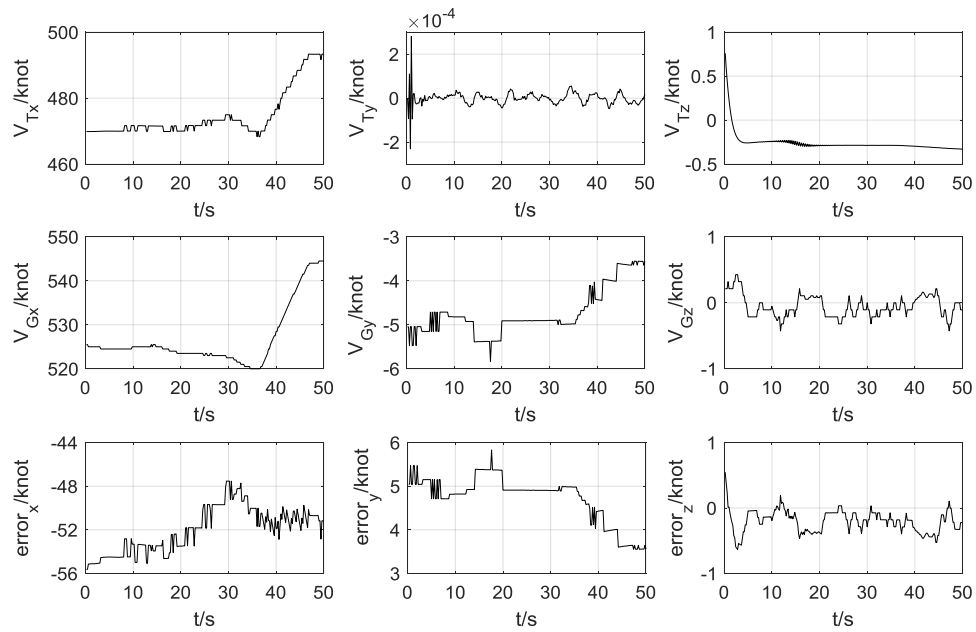


图 5.2 真空速与地速三维量测及其差值

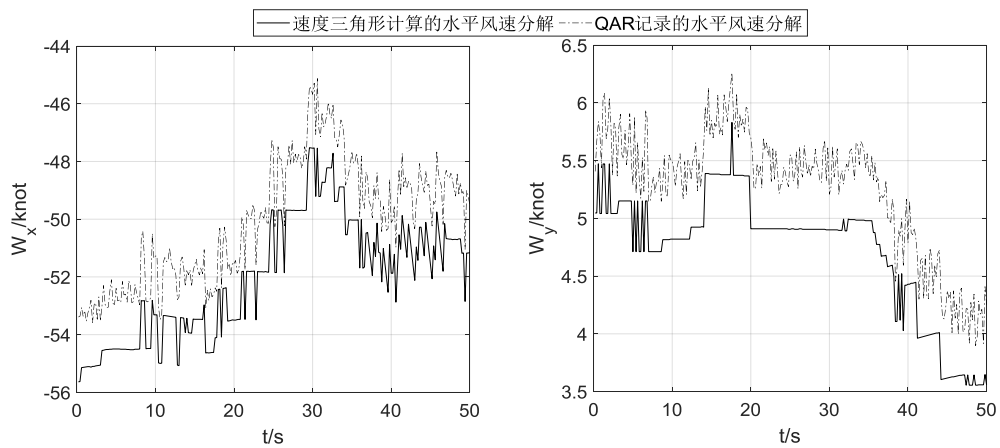


图 5.3 平稳飞行下速度三角形计算的水平风与 QAR 记录的对比图




图 5.4 颠簸飞行下速度三角形计算的水平风与 QAR 记录的对比图

5.4 扰动风估计结果分析

依据 QAR 数据得到的真空速、地速、飞行高度等相关参数记录值, 给定状态向量初始值和量测向量初始值, 以及噪声方差和采样周期, 便可以采用扩展卡尔曼滤波器得到三维空间扰动风的估计。根据 PIREPs, 选取飞机遭遇的颠簸强度分别为轻度、中度、重度的三次航班飞行的 QAR 数据, 对该三次航班高空巡航阶段的三维湍流扰动风进行估计。

通过 MATLAB 平台, 读取三次航班飞行的 QAR 数据, 得到飞行的马赫数 M 、总温 T 、地速 V_G 等飞行记录参数, 同时计算获得真空速值。巡航海拔高度约为 30000ft, Von Karman 模型状态方程中设置湍流强度 $\sigma_1=\sigma_2=\sigma_3=4.5m/s$, $L_1=2L_2=2L_3=540m$ 。考虑到地速和下降率的采样频率均为每秒 4 次, 因此设置采样周期为 0.25s, 滤波时间为 20s。滤波器相关初始参数设置为 $Q=diag[10^{-3}, 10^{-3}, 10^{-3}]$, $R=diag[10^{-2}, 10^{-2}, 10^{-2}]$, $P_0=eye(3)$ 。状态初始值根据 QAR 记录的水平风速分解给出, 垂直风速初值均设为 0, 则湍流颠簸强度为轻度、中度、重度的风速状态初始值分别为 $x_{light}(1)=[45, 5, 0]^T$, $x_{middle}(1)=[75, 7, 0]^T$, $x_{severe}(1)=[101, 11, 0]^T$ 。

图 5.5、图 5.6 和图 5.7 分别为利用扩展卡尔曼滤波器得到的轻度、中度和重度颠簸下的三维扰动风估计结果与扰动风真实轨迹的对比图, 三种颠簸强度下的扰动风估计误差如图 5.8 所示。由图 5.8 可以看出, 该算法对于不同维度和不同颠簸强度下的扰动风的估计效果是不同的。从三维估计效果的角度分析, 可以看出该算法对于水平面的风速估计误差要小于垂直方向的估计误差。在 x 、 y 轴方向上, 轻度、中度、重度三种颠簸强度的风速估计误差分别为 ± 0.3 节、 ± 0.5 节和 ± 1 节, 均在 ± 1 节的范围内; 在垂直方向 z 轴上, 三种颠簸强度的扰动风估计误差均大于水平方向上的误差, 估计误差范围分别为 ± 1 节、 ± 1.5 节和 ± 2.5 节。通过以上分析也可以看出, 颠簸强度越大, 扰动风估计误差也越大。经研究分析, 当飞机在飞行过程中遇到的湍流越强时, 风速变化越为剧烈, 模型本身存在一定的建模误差, 因此算法估计结果就会越不准确。




图 5.5 轻度颠簸下扰动风三维估计结果图




图 5.6 中度颠簸下扰动风三维估计结果图




图 5.7 重度颠簸下扰动风三维估计结果图




图 5.8 轻度、中度、重度颠簸下扰动风三维估计误差对比图

5.5 本章小结

本章主要对颠簸飞行下的三维空间扰动风估计进行初步研究。根据 von Karman 大气湍流模型和真空速、地速与风速之间的矢量三角形关系，建立系统状态方程和量测方程，利用扩展卡尔曼滤波器分别对轻度、中度和重度三种不同程度颠簸下的扰动风进行估计。经初步研究分析，该算法在轻度和中度颠簸飞行情况下能够较为准确地估计出 x 、 y 、 z 三维空间扰动风，重度颠簸下虽然估计误差较大，但依然可以提供一定的参考。该算法主要可以提供 QAR 数据中没有记录的垂直扰动风，为飞机颠簸的建模奠定理论基础。

第六章 总结与展望

6.1 本文研究内容总结

航空安全是民航领域经久不衰的话题。在导致航空不安全事件征候的原因中，天气原因通常占较大比例，特别是大气湍流等大气扰动现象最为常见。大气湍流诱发的飞行颠簸极易产生燃料损失、飞机损毁和人员受伤等各种重大飞行风险。而实际上，并非所有伤害事件都被上报，实际受害人数要高于实际统计数据。因此，对飞机状态和湍流扰动风进行研究，对避免湍流对机组和乘客造成伤害、减少人员与财产损失等方面具有重要意义。飞行数据记录系统记录了飞机实时的飞行状态、发动机状态、驾驶舱操纵等时间、空间多维度的序列信息。因此，本课题基于飞行数据对飞机飞行状态和扰动风估计进行初步研究，课题研究结论总结如下：

(1) 飞行数据的记录、特点及其着陆安全影响因素分析。研究了飞行数据的记录系统、记录格式、记录特点以及状态冗余；考虑飞机进场着陆阶段是飞行任务中的事故多发阶段，采用基于时间序列的灰色接近关联分析和灰典型相关分析方法，探究了关键飞行阶段的飞行状态参数与重着陆和长着陆之间定量的关联性。灰色接近关联分析结果表明，跑道入口至接地段对两个不安全事件的影响最大。进一步的灰典型相关分析结果表明，载荷量达 0.9691 的下降率对长着陆影响最大，载荷量达 0.7670 的地速对重着陆影响最大。

(2) 飞行状态估计算法研究。考虑到系统模型动态变化、飞行数据可能受到外部干扰发生数据突变以及飞行数据之间的噪声方差和相关性等统计特性均未知等情况，研究了一种基于极大似然准则的自适应扩展卡尔曼滤波算法。以对飞行器运动状态估计为例，估计飞行器的位置、速度、加速度状态。结果表明，该算法的收敛性与估计效果均优于扩展卡尔曼滤波算法和无迹卡尔曼滤波算法。

(3) 飞机气流角估计。考虑到飞行数据的采样频率不同，将非等间隔理论与基于极大似然准则的自适应扩展卡尔曼滤波算法相融合，基于飞行动力学模型，建立系统状态方程和量测方程，对飞机气流角进行估计。相比于扩展卡尔曼滤波算法和无迹卡尔曼滤波算法，该算法能够更加准确地估计出飞机迎角、侧滑角的值，且当飞行数据发生突变干扰时，该算法的抗外部干扰突变的鲁棒性能也优于另外两种算法。

(4) 颠簸飞行中扰动风估计初步研究。根据 von Karman 大气湍流模型建立了湍流扰动风的三维空间状态方程；基于前文计算的真空速和准确估计的气流角，对真空速和地速进行三轴分解，然后基于真空速、地速与风速之间的速度三角形关系，建立量测方程；最后，采用扩展卡尔曼滤波器，对空间三维扰动风进行估计。估计结果表明，在轻度和中度颠簸飞行情况下，该算法能够实现三维空间湍流扰动风的初步估计。

简要总结本文的两点创新之处：

(1) 基于对飞行数据记录特点的考虑，研究了一种基于极大似然准则的自适应扩展卡尔曼滤波算法。该算法能够突出新近数据的作用，通过指数衰减加权对新息协方差进行实时估计，并将其传递至滤波器的增益矩阵中，从而及时地反映出系统噪声统计特性的变化，更加准确地跟踪系统模型的变化。将该算法与非等间隔理论相融合，对飞机运动状态及气流角进行估计，估计效果与抗外部干扰的鲁棒性能均优于扩展卡尔曼滤波算法和无迹卡尔曼滤波算法。

(2) 研究了一种估计三维空间湍流扰动风的算法。根据 von Karman 大气湍流模型建立扰动风状态方程；根据真空速、地速与风速之间的速度三角形关系，将空速与地速之间的三轴差值作为量测输入；采用扩展卡尔曼滤波器，估计出三维空间扰动风。结果表明，该算法在轻度和中度颠簸情况下能够较为准确地估计出扰动风。

6.2 未来研究工作展望

受到课题研究时间和实验条件的限制，本文的研究仍存在许多不足之处：

(1) 由于扩展卡尔曼滤波忽略了线性过程中的高阶项，对于非线性较强的系统，随着滤波迭代次数的增加，误差可能会累积，所以基于极大似然准则的自适应扩展卡尔曼滤波算法也存在一定的局限性。而无迹卡尔曼滤波算法，由于其滤波理论的不同，算法精度要高于扩展卡尔曼滤波算法。但由于时间限制，本文只研究了基于极大似然准则的自适应扩展卡尔曼滤波算法，没有继续研究基于极大似然准则的无迹卡尔曼滤波算法。

(2) 没有建立带有扰动风影响的非线性动力学模型。由于课题首先是对飞机气流角进行探究，基于气流角的估计值对湍流扰动风进行估计，受论文研究方法的限制，本文在对飞机运动状态和气流角进行估计时没有考虑扰动风的影响，所建立的状态方程没有加入扰动风的因素项。因此，具有一定的局限性。在后续的研究中，会将扰动风影响加入到状态估计的动力学模型中。另外，考虑到颠簸湍流所诱发的飞机响应极其复杂，本文作为颠簸飞行状态估计的初步探索，所建模型是否完全正确，有待更进一步地实践检验。

参考文献

- [1] 中国民航局. 2018 年民航行业发展统计公报[R]. 北京: 中国民航出版社, 2019: 13-21.
- [2] Federal Aviation Administration. Airplane Upset Recovery Training Aid[R]. Washington, DC: Federal Aviation Administration, 2008: 56-98.
- [3] 中国民航局. 民用航空飞行事故汇编(1949-2010)[R]. 北京: 中国民航出版社, 2011: 12-225.
- [4] Sharman R., Lane T. Aviation Turbulence: Processes, Detection, Prediction[M]. Berlin: Springer, 2016: 23-56.
- [5] Jones W M. A Pilot-Centered Turbulence Assessment and Monitoring System(TAMS)[C]. 10th International Symposium on Aviation Psychology. Columbus, Ohio. 1999: 2-6.
- [6] Boeing Company. Digital Flight Data Acquisition Unit 737-600/-700/-700C/-800/-900 Data Frame Interface Control and Requirements Document[R]. U.S.A.: BC, 2003:3-391.
- [7] Federal Aviation Administration. Flight Operational Quality Assurance (Advisory Circular 120-82)[S]. Washington D C: Federal Aviation Administration, 2004.
- [8] 赵云帆, 李斌. 利用 WQAR 建立中国民航飞行品质监控系统[J]. 中国民用航空, 2012, 10: 57-58.
- [9] WANG L, WU C, SUN R. An Analysis of Flight Quick Access Recorder (QAR) Data and Its Applications in Preventing Landing Incidents[J]. Reliability Engineering & System Safety, 2014, 127(1): 86-96.
- [10] WANG L. Effects of Flare Operation on Landing Safety: a Study Based on ANOVA of Real Flight Data[J]. Safety Science, 2018, 102(1): 14-25.
- [11] WANG L, WU C, SUN R, et al. An Analysis of Hard Landing Incidents Based on Flight QAR Data[C]. International Conference on Engineering Psychology and Cognitive Ergonomics. Springer, Cham, 2014: 398-406.
- [12] WANG L, WU C, SUN R. Pilot Operating Characteristics Analysis of Long Landing Based on Flight QAR Data[C]. International Conference on Engineering Psychology and Cognitive Ergonomics. Springer Berlin Heidelberg, 2013: 157-166.
- [13] Lv H , Yu J , Zhu T . A Novel Method of Overrun Risk Measurement and Assessment Using Large Scale QAR Data[C]. 2018 IEEE Fourth International Conference on Big Data Computing Service and Applications (Big Data Service). IEEE Computer Society, 2018: 213-220.
- [14] 曹海鹏, 舒平, 黄圣国. 基于神经网络的民用飞机重着陆诊断技术研究[J]. 计算机测量与

- 控制, 2008, 16(7): 906-908.
- [15] QIAO X, CHANG W, ZHOU S, et al. A Prediction Model of Hard Landing Based on RBF Neural Network with K-means Clustering Algorithm[C]. IEEE International Conference on Industrial Engineering and Engineering Management. IEEE, 2016: 462-465.
- [16] 许桂梅, 黄圣国. 基于多核支持向量机的飞机重着陆诊断[J]. 计算机工程, 2011, 37(10): 157-159.
- [17] 李晓明. 某航空发动机防喘控制系统故障预测与健康应用研究[D]. 南京航空航天大学, 2018.
- [18] Alvarez-Montoya J, Torres-Arredondo M A, Sierra-Pérez J. Gaussian Process Modeling for Damage Detection in Composite Aerospace Structures by Using Discrete Strain Measurements[C]. 7th Asia-Pacific Workshop on Structural Health Monitoring. Hong Kong, China, 2018: 116-124.
- [19] Z. Pan, C. Chi and J. Zhang, A Model of Aircraft Health Monitoring and Fault Diagnosis Based on Beacon Exception Analysis[C]. 2019 Prognostics and System Health Management Conference (PHM-Paris). Paris, France, 2019: 185-191.
- [20] Gerald Dillingham P D. Aviation Safety: Proposals to Enhance Aircraft Tracking and Flight Data Recovery May Aid Accident Investigation, but Challenges Remain[J]. Fisheries Oceanography, 2015, 24(4): 325-334.
- [21] 中国人民解放军总装备部军事训练教材编辑工作委员会. 飞行器系统辨识学[M].北京: 国防工业出版社, 2003: 79-352.
- [22] Ralph E, Bach Jr, Rodney C Wingrove. Applications of State Estimation in Aircraft Flight-Data Analysis[J]. Journal of Aircraft, 1985, 22(7): 547-554.
- [23] Wanke C, Hansman J. A Data Fusion Algorithm for Multi-sensor Microburst Hazard Assessment[C]. Navigation and Control Conference. AIAA, 1992: 4339.
- [24] 张洪才, 张友民, 贺志斌. 一种鲁棒自适应推广 Kalman 滤波及其在飞行状态估计中的应用[J]. 信息与控制, 1992(06): 343-348.
- [25] 李鹏辉, 刘小雄, 徐恒, 王娟. 基于无迹卡尔曼滤波的迎角/侧滑角估计方法[J]. 测控技术, 2014,33(03): 140-143+147.
- [26] 宋述杰, 邓建华. 应用 INS/GPS 系统数据估计迎角和侧滑角的方法研究[J]. 西北工业大学学报, 2005, 23(2): 231-234.
- [27] 马航帅, 雷廷万, 李荣冰. 大攻角下基于信息融合的攻角/侧滑角估计方法[J]. 电光与控制, 2012, 19(8): 1-5.

- [28] Wenz A, Johansen T A. Moving Horizon Estimation of Air Data Parameters for UAVs[J]. IEEE Transactions on Aerospace and Electronic Systems, 2019: 1.
- [29] 宋宇, 翁新武, 郭昕刚. 基于四元数 EKF 算法的小型无人机姿态估计[J]. 吉林大学学报(理学版), 2015, 53(03): 511-518.
- [30] 朱岩, 付巍. 基于无迹卡尔曼滤波的四旋翼无人飞行器姿态估计算法[J]. 测试技术学报, 2014, 28(03): 194-198.
- [31] Pan C, Lan C. Estimation of Aerodynamic Characteristics of a Jet Transport Using Accident FDR Data[C]. Atmospheric Flight Mechanics Conference and Exhibit. AIAA, 2002: 4494.
- [32] Leung J M, Moszczynski G J, Grant P R. A State Estimation Approach for High Angle-of-Attack Parameter Estimation from Certification Flight Data[C]. AIAA Scitech 2019 Forum. AIAA, 2019: 0013.
- [33] 肖冠平, 陈静杰. 基于 QAR 数据的民航飞机侧滑角估算方法[J]. 电光与控制, 2015, 22(3): 86-89.
- [34] Wang Q , Wu K , Zhang T , et al. Aerodynamic Modeling and Parameter Estimation from QAR Data of an Airplane Approaching a High-altitude Airport[J]. Chinese Journal of Aeronautics, 2012, 25(3): 361-371.
- [35] Bach R E, Wingrove R C. Analysis of Windshear from Airline Flight Data[J]. Journal of Aircraft, 1989, 26(2): 103-109.
- [36] Beal T R. Digital Simulation of Atmospheric Turbulence for Dryden and Von Karman Models[J]. Journal of Guidance Control Dynamics, 1993, 16(1): 132-138.
- [37] Jategaonkar R V, Gopalratnam G. Two Complementary Approaches to Estimate Downwash Lag Effects from Flight Data[J]. Journal of Aircraft, 2001, 38(8): 540-542.
- [38] Jategaonkar R V, M-ogrove W, nnich, et al. Identification of Speed Brake, Air-Drop, and Landing Gear Effects from Flight Data[J]. Journal of Aircraft, 2007, 44(2): 174-180.
- [39] Langelaan J. W., Alley N. and Neidhoefer J. Wind Field Estimation for Small Unmanned Aerial Vehicles[J]. Journal of Guidance, Control, and Dynamics, 2011, 34(4): 1016-1030.
- [40] Cho A., Kim J., Lee S. and Kee C., Wind Estimation and Airspeed Calibration Using a UAV with a Single-Antenna GPS Receiver and Pitot Tube[J]. IEEE Transactions on Aerospace and Electronic Systems, 2011, 47(1): 109-117.
- [41] Velasco-Carrau J, Garc á-Nieto S, Salcedo J V, et al. Multi-objective Optimization for Wind Estimation and Aircraft Model Identification[J]. Journal of Guidance, Control, and Dynamics, 2015, 39(2): 372-389.

- [42] Rhudy M B. Predicting the Parameters of Stochastic Wind Models for Time-Varying Wind Estimation Techniques[J]. Journal of Aerospace Information Systems, 2018, 16(2): 71-76.
- [43] 屈耀红, 邢哲文, 袁冬莉, 张友民. 基于悬停四旋翼位置姿态信息的风场估计方法研究[J]. 西北工业大学学报, 2016, 34(04): 684-690.
- [44] 李斌. 特殊机场 PBN 运行的扰动风场估计及关联分析[J]. 航空计算技术, 2017, 47(01): 5-9+13.
- [45] Deng X, Yang J, Sun Y, et al. Sensorless Effective Wind Speed Estimation Method Based on Unknown Input Disturbance Observer and Extreme Learning Machine[J]. Energy, 2019, 186: 115790.
- [46] Gao Z, Fu J. Robust LPV Modeling and Control of Aircraft Flying Through Wind Disturbance[J]. Chinese Journal of Aeronautics, 2019, 32(7): 1588-1602.
- [47] 俞飞, 王科, 梁爱民等. 华北地区晴空颠簸的分类特征及分析[J]. 气象, 2008, 34(8): 15-21.
- [48] 章澄昌. 飞行气象学(第二版)[M]. 北京: 气象出版社, 2008: 49-129.
- [49] 吴炎成, 周林, 刘科峰等. 基于 AMDAR 资料应用于中国周边海域飞机颠簸的统计分析[J]. 气象科学, 2014, 34(1): 17-24.
- [50] 李子良, 黄仪方. 地形影响的飞机颠簸及其数值仿真实验[J]. 气象, 2006, 32(11): 32-35.
- [51] Kim J H, Chun H Y. Statistics and Possible Sources of Aviation Turbulence over South Korea[J]. Journal of Applied Meteorology and Climatology, 2011, 50(2): 311-324.
- [52] Sherman D J. The Australian implementation of AMDAR/ACARS and the Use of Derived Equivalent Gust Velocity as a Turbulence Indicator[M]. Australian: Department of Defence, Defence Science and Technology Organisation, Aeronautical Research Laboratories, 1985: 418:28.
- [53] International Civil Aviation Organization. Meteorological service for international air navigation: Annex 3 to the Convention on International Civil Aviation[S]. Chicago: International Civil Aviation Organization, 2010.
- [54] Federal Aviation Administration. Revisions to Digital Flight Data Recorder Rules [S]. Washington D C: Federal Aviation Administration, 1997.
- [55] Ya-Zhou D I, Qin Y Y, Shang X L, et al. Research on Data Pre-Processing of Flight Data Recorder System Based on Polynomial Regression[J]. Measurement & Control Technology, 2008, 27(4): 21-22.
- [56] 张浩. QAR 数据译码技术研究与自动译码系统的建立[D]. 中国民航大学, 2016.
- [57] 卢永强, 李宁, 赵晶晶. 民机飞行数据记录系统——ARINC717 规范发展历程[C]. 2013 年度

标准化学术研究论文集. 山东省科学技术协会, 2013: 97-98.

- [58] BENEDETTO A, D'AMICO F, TOSTI F. Improving Safety of Runway Overrun Through the Correct Numerical Evaluation of Rutting in Cleared and Graded Areas[J]. Safety Science, 2014, 62(1): 326-338.
- [59] OJHA S K. Flight Performance of Aircraft[M]. Warshington D C: American Institute of Aeronautics and Astronautics, 1934: 389-391.
- [60] Rao T S . Time Series Analysis Methods and Applications for Flight Data[M]. Berlin, Heidelberg: Springer-Verlag, 2017: 65-85.
- [61] 刘思峰, 杨英杰, 吴利丰等. 灰色系统理论及其应用. 第 8 版[M].北京: 科学出版社, 2017: 63-112.
- [62] 李雪, 林和平, 李迎斌. 灰典型相关分析研究与应用[J]. 计算机工程与科学, 2009, 31(6): 121-125.
- [63] 王可东. Kalman 滤波基础及 MATLAB 仿真[M]. 北京: 北京航空航天大学出版社, 2019: 110-150
- [64] DanSimon, 最优状态估计: 卡尔曼, H^∞ 及非线性滤波[M]. 北京: 国防工业出版社, 2013: 58-63.
- [65] 黄小平. 卡尔曼滤波原理与应用——MATLAB 仿真[M]. 北京: 电子工业出版社, 2015: 77-102.
- [66] Gao B , Gao S , Hu G , et al. Maximum Likelihood Principle and Moving Horizon Estimation based Adaptive Unscented Kalman Filter[J]. Aerospace Science and Technology, 2017, 73: 184-196.
- [67] Zhang H , Dai G , Sun J , et al. Unscented Kalman Filter and Its Nonlinear Application for Tracking a Moving Target[J]. Optik - International Journal for Light and Electron Optics, 2013, 124(20): 4468-4471.
- [68] 高峰涛. 基于极大似然准则自适应 EKF 的感应电机转速辨识方法[D].西安理工大学,2019.
- [69] 郑崴, 张贵宾. 自适应卡尔曼滤波在航空重力异常解算的应用研究[J]. 地球物理学报, 2016, 59(04): 1275-1283.
- [70] 岳晓奎, 袁建平. 一种基于极大似然准则的自适应卡尔曼滤波算法[J]. 西北工业大学学报, 2005(04): 469-474.
- [71] 张玉龙, 王茁, 杨巍. 基于极大似然估计的新息自适应滤波算法[J]. 传感器与微系统, 2018, 37(01): 141-144.
- [72] Karasalo M, Hu X. An Optimization Approach to Adaptive Kalman Filtering[J]. Automatica,

- 2011, 47(8): 1785-1793.
- [73] Xi Y, Li Z, Zeng X, et al. Detection of Voltage Sag Using an Adaptive Extended Kalman Filter Based on Maximum Likelihood[J]. Journal of Electrical Engineering & Technology, 2017, 12(3): 1016-1026.
- [74] 吴森堂. 飞行控制系统[M]. 北京: 北京航空航天大学出版社, 2013: 8-106.
- [75] 桂远洋. 低空风切变下飞机自动着陆安全控制策略研究[D]. 南京航空航天大学, 2013.
- [76] Zhao L, He Z. An In-Coordinate Interval Adaptive Kalman Filtering Algorithm for INS/GPS/SMNS[C]. 10th IEEE International Conference 导航非等间隔滤波算法研究[J]. 宇航学报, 2004(06): 626-631.
- [77] Bulíček M, Málek J. Large Data Analysis for Kolmogorov's Two-Equation Model of Turbulence[J]. Nonlinear Analysis: Real World Applications, 2019, 50: 104-143.
- [78] Cornman L B , Morse C S , Cuning G . Real-time Estimation of Atmospheric Turbulence Severity from In-Situ Aircraft Measurements[J]. Journal of Aircraft, 1994, 32(1):171-177.
- [79] 曹九发, 沈宏良, 王同光. 基于有理谱法的大气紊流仿真及应用研究[J]. 飞行力学, 2013(04): 3-6+18.
- [80] 张峰, 汪沛, 王冲等. 基于 Von Karman 模型的三维大气紊流仿真[J]. 计算机仿真, 2007(01): 45-48.
- [81] Demori M, Ferrari M, Bonzanini A, et al. Autonomous Sensors Powered by Energy Harvesting from von Karman Vortices in Airflow[J]. Sensors, 2017, 17(9): 2100.
- [82] Mutlu T, Hajiyeve C. An Integrated Air Data/GPS Navigation System for Helicopters[J]. Positioning, 2011, 2(02): 103.

致 谢

时光荏苒，光阴似箭。一晃在南京两年半的研究生生涯即将走到尽头，人总是会在即将离开的时候，变得异常感慨。回首两年半的时间，有欢乐，有泪水，更多的还是感恩。感恩在南航遇到的所有人，是你们让我成长，让我的人生更加充实和完整。

首先，最感谢的是我的导师高振兴副教授！可能我不是您最出色的学生，但您是最尊敬的老师！这两年半的时间里，高老师严谨认真的科研精神、精益求精的工作态度以及为人处世的正派作风都时刻感染着我，耳濡目染、潜移默化间让我成长。科研的道路上总是磕磕绊绊，当我遇到困难的时候，高老师总能以他渊博的学识、开阔的思维帮助我分析问题、解决问题，授人以鱼不如授人以渔，并教会我分析和解决问题的方法；当我自我怀疑的时候，高老师也总能用人生的良言和幽默的话语，让我重拾信心！在此，谨向我的导师高振兴老师致以我最诚挚的谢意和崇高的敬意！

其次，感谢顾宏斌教授将我带进飞行模拟与先进培训工程技术研究中心，让我进入这个大家庭，开启我崭新的研究生生涯。作为原 1101 实验室唯一的女生，还要特别感谢实验室唯一的女老师孙瑾老师，感谢孙老师在生活上和科研上给予的无私的帮助和指导。此外，也对实验室刘晖老师、吴东苏老师和陈大伟老师给予的帮助表示诚挚的谢意，也是你们让我看到了团队合作的力量的是无穷的。

同时，也要感谢实验室的各位优秀的师兄和小伙伴，特别感谢王得宝博士、赵江伟博士、赵剑师兄、徐一超师兄，在我遇到问题的时候，他们总能第一时间提供帮助和鼓励；也要感谢杨刘涛、张泽生、张洋洋等实验室小伙伴，感谢他们在科研和生活上给予的帮助和欢乐。感谢实验室的每一个人，让我在这里体会到家的温暖！

感谢我的父母，是你们无条件的爱与支持，悉心的培养与教导，才有今天的我。焉得谖草，言树之背，养育之恩，无以回报，你们是最坚强的后盾，你们永远健康快乐是我最大的心愿。

最后，对评阅本论文和参与我答辩付出辛勤劳动的所有老师表示衷心地感谢！

在学期间的研究成果及发表的学术论文

攻读硕士学位期间发表(录用)论文情况

- [1] 王冉, 高振兴. 基于飞行数据的民机着陆安全影响因素研究[J]. 交通信息与安全, 2019, 37(04):27-34.
- [2] 王冉, 高振兴. 基于自适应卡尔曼滤波的飞机气流角估计研究[J]. 电光与控制.(已录待刊)

攻读硕士学位期间参加科研项目情况

- [1] 基于飞行数据的民机飞行颠簸机理及短时预测研究, 国家自然科学基金项目(U1733122)